Begriffe & Frameworks

W02 — Die Guidelines sind da: Warum ändert sich in der Praxis so wenig — und welche Begriffe brauchen wir, um das zu ändern? · 14.10.2026 (KW 42)

AUDIT-READY MATERIAL

Retrieval: Stoff aus W01

W02 // RETRIEVAL // 5 MIN

Q1 Welche drei Komponenten machen KI nach der EU-Expertengruppe (2019) über den gesamten Lebenszyklus vertrauenswürdig?

Q2 Nennen Sie drei der sieben europäischen Anforderungen — und je ein Alltagsbeispiel.

Q3 Welche vier Pole spannen das Trade-off-Feld vertrauenswürdiger KI auf?

Q4 Warum schützte im Chatbot-Fall der Disclaimer den Betreiber nicht?

OPAL-Quiz, unbenotet und anonym — Testeffekt statt Note.

KALTER EINSTIEG // 5–8' // SCHÄTZEN SIE

„Wie viele KI-Ethik-Richtlinien wurden weltweit veröffentlicht, bevor der erste KI-Rechtsakt überhaupt entworfen war?“

SCHÄTZFRAGE 2

Und wie viele Grundprinzipien tauchen in diesen Dokumenten am Ende wirklich auf — zehn, fünfzig, hundert?

SCHÄTZFRAGE 3

Und wie viel davon ist in den Organisationen, die unterschrieben haben, im Betrieb angekommen?

Auflösung: die Landkarte von 2019

84

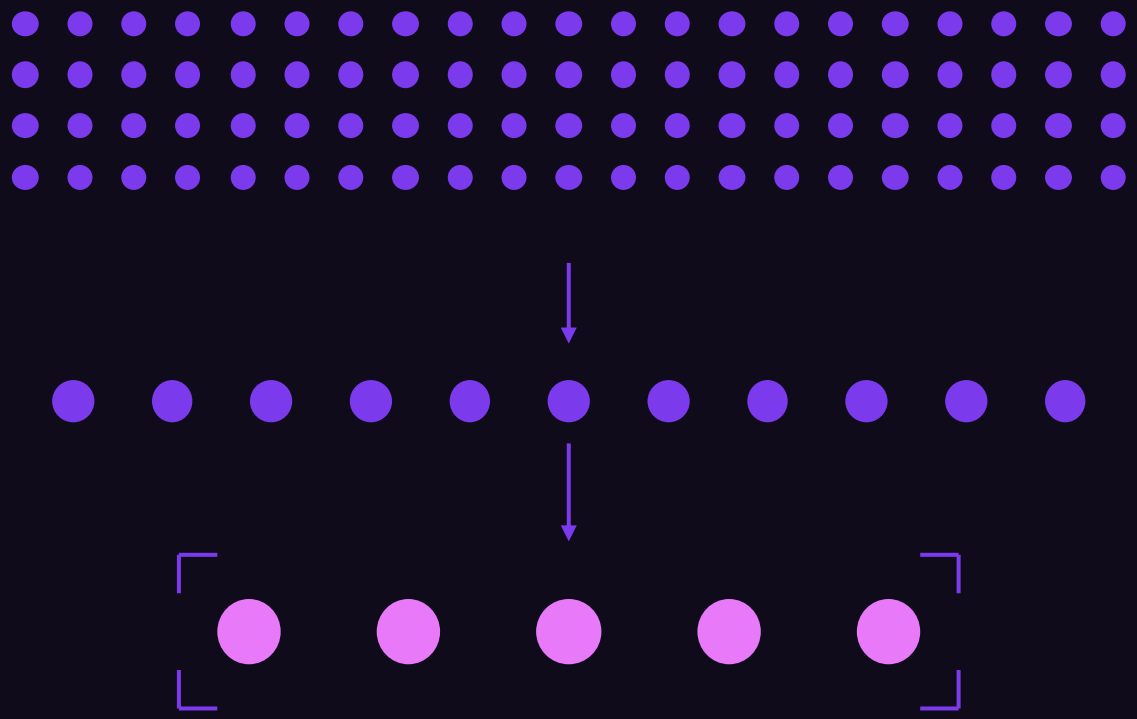
KI-Ethik-Richtlinien weltweit,
systematisch gesammelt und kodiert.

11

ethische Prinzipien insgesamt
identifiziert.

5

davon konvergent: in mehr als der Hälfte
aller Dokumente genannt.



Konvergenz der Worte – nicht der Auslegung.

Quelle: Jobin, Ienca & Vayena (2019), Nature Machine Intelligence 1 (peer-reviewed)

Konvergenz der Worte, nicht der Auslegung

W02 // EINSTIEG // DER BEFUND GENAU GELESEN

Der Befund

Die Studie zeigt **Übereinstimmung auf Wortebene**: Dieselben fünf Prinzipien tauchen weltweit auf. Sie zeigt zugleich **Divergenz auf Bedeutungsebene** — Begründung, Auslegung und Umsetzung unterscheiden sich erheblich.

- **Gleiches Wort —** „Transparenz“ steht in fast jedem Katalog — als Ziel, nicht als Definition.
- **Andere Bedeutung —** Gemeint sein kann Offenlegung, Erklärbarkeit oder bloße Nutzerinformation.
- **Andere Adressaten —** Mal zielt das Prinzip auf Entwickler*innen, mal auf Betreiber*innen, mal auf den Staat.
- **Verzerrung —** Der Korpus ist geografisch konzentriert; der globale Süden ist unterrepräsentiert.

STUDIE // SCOPING REVIEW

Jobin, Ienca & Vayena (2019)

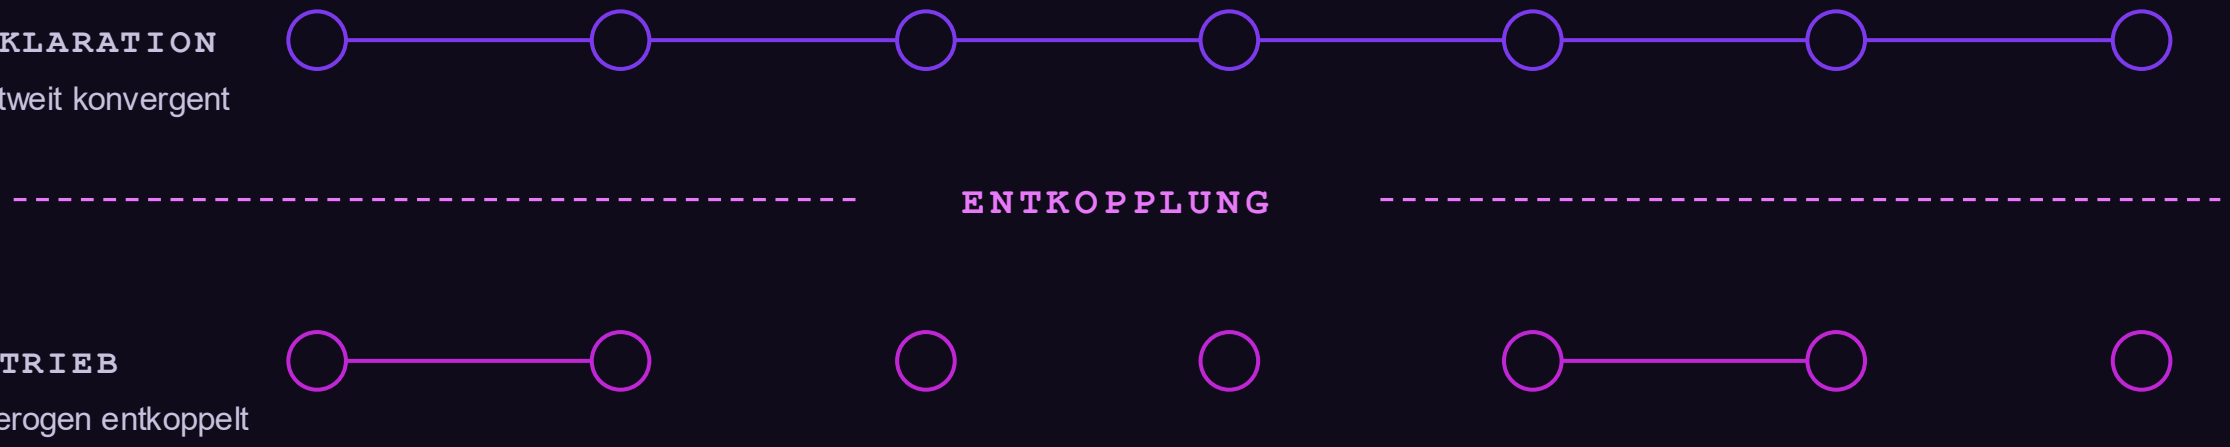
Die Autor*innen halten ausdrücklich fest: Die inhaltliche Übereinstimmung der Begriffe darf nicht mit einer Übereinstimmung darüber verwechselt werden, was praktisch zu tun ist.

Korpus: 84 Dokumente, weltweit

Zugang: frei (arXiv 1906.11668)

Konvergiert und trotzdem wirkungslos

Die Prinzipien sind konvergiert. Die Praxis ist es nicht –
und das ist kein Übergangsproblem.



Die Lücke ist heterogen, nicht uniform – Diagnose vor Intervention.

Quelle: Decoupling in AI ethics, Empirical Software Engineering (2026), peer-reviewed

Die Zahl hinter dem Bruch

W02 // EINSTIEG // AUFLÖSUNG 2

Auflösung der dritten Schätzfrage: Von den Unternehmen, die 2024 KI einsetzten, arbeiteten **nur 12 %** aktiv an der Minderung von Bias- und Fairness-Risiken.

- **Lesart —** Rund neun von zehn Anwender*innen betreiben KI ohne aktive Risikominderung bei Verzerrung und Fairness.
- **Quellengüte —** Sekundärangabe: McKinsey-Daten, referiert in der Literatur zu Ethics Washing — keine eigene Primärerhebung.
- **Was die Zahl nicht sagt —** Sie misst eine einzelne Dimension, nicht die gesamte Trustworthiness einer Organisation.

BEGRIFF // ETHICS WASHING

Lange behauptet, spät belegt

„Ethics Washing“ meint die performative Übernahme ethischer Rahmen ohne substanzielle Umsetzung. Der Vorwurf ist seit Jahren verbreitet — empirisch belegt war er lange nicht.

Quelle: Laut McKinsey-Daten, referiert in der Ethics-Washing-Literatur (Sekundärangabe). Stand: Anfang September 2026.

Warum bleibt Einigkeit ohne Wirkung?

W02 // EINSTIEG // LEITFRAGE

Fünf Prinzipien, weltweit geteilt — und trotzdem verändert sich der Entwicklungs- und Betriebsalltag in der Breite kaum.

- **Verdacht —** Vielleicht fehlt nicht der Konsens, sondern alles, was aus einem Wort eine überprüfbare Anforderung macht.

SPOILER // BLOCK A

Begriffe als Werkzeuge

→ Ein Prinzip wird erst arbeitsfähig, wenn es Definition, Messgröße und Verantwortliche hat — genau dieses Raster bauen wir in Block A.

BLOCK // DIAGNOSE // 10–14'

Decoupling: nicht uniform

Die Lücke zwischen Deklaration und Betrieb ist heterogen — verschiedene Organisationen entkoppeln auf verschiedene Weise. Stand: Anfang September 2026.

Decoupling in AI ethics (2026)

W02 // EINSTIEG // EMPIRISCHE FUNDIERUNG

Der Beitrag

„Decoupling in AI ethics: Learning how to walk the talk“ (Empirical Software Engineering, 2026): systematische Feldforschung in verschiedenen Organisationskontexten — erstmals wird die Entkopplung von Deklaration und Betrieb empirisch aufgeschlüsselt.

- **Gegenstand —** Wie deklarierte Ethik tatsächlich in Entwicklungs- und Betriebspraxis übersetzt wird.
- **Befund —** Es lassen sich distinkte Entkopplungs-Profile unterscheiden — die Lücke ist heterogen, nicht uniform.
- **Konsequenz —** Diagnose vor Intervention: Erst das Profil bestimmen, dann das passende Werkzeug wählen.

QUELLENGÜTE // PEER-REVIEWED

Warum das zählt

Ethics Washing war bislang vor allem ein Vorwurf. Diese Arbeit macht daraus einen prüfbaren empirischen Gegenstand — und liefert damit die Grundlage, gezielt statt pauschal zu intervenieren.

Publikation: Empirical Software Engineering (2026)

Status: peer-reviewed

Was sich mit Profilen ändert

W02 // EINSTIEG // KONSEQUENZ

Wenn die Lücke heterogen ist, ändert das die Art, wie man sie schließt:

- **Kein Pauschalurteil —** „Alle betreiben Ethics Washing“ ist als Diagnose zu grob und blockiert die Verbesserung.
- **Gleiche Worte, andere Realität —** Zwei Organisationen mit identischem Kodex können völlig verschieden arbeiten.
- **Diagnose zuerst —** Erst das Entkopplungsmuster bestimmen, dann die Maßnahme wählen.
- **Folge für Audits —** Eine Einheits-Checkliste misst zwangsläufig an manchen Mustern vorbei.

Quelle: Decoupling in AI ethics: Learning how to walk the talk, Empirical Software Engineering (2026), peer-reviewed.

Das Werkzeugdilemma

W02 // EINSTIEG // ZU FLEXIBEL ODER ZU STRIKT

POL 1 // ZU FLEXIBEL

Offen formuliert

Form

Abstrakte Prinzipien, viel Auslegungsspielraum, kaum Prüfkriterien.

Vorteil

passt auf jede Branche, jedes Produkt, jede Organisationsgröße.

Risiko

anfällig für Ethics Washing — Zustimmung kostet nichts.

Symptom

Häufigste Kritik an prinzipienbasierten Ansätzen: Abstraktheit.

POL 2 // ZU STRIKT

Eng vorgeschrieben

Form

Detaillierte Pflichtkataloge, feste Schwellen, harte Vorgaben.

Vorteil

prüfbar, vergleichbar, mit klarer Beweislast.

Risiko

kontextblind — passt nicht auf abweichende Einsatzszenarien.

Symptom

Formale Erfüllung ersetzt die inhaltliche Auseinandersetzung.

Vier weitere Gap-Ursachen

Neben dem Werkzeugdilemma nennt der Forschungsstand vier wiederkehrende Ursachen:

- **Fehlende Anreize —** Ethisches Engagement zahlt sich in Zielsystemen und Karrierewegen kaum aus.
- **Systemkomplexität —** Moderne KI-Systeme sind verteilt und dynamisch — Wirkung lässt sich schwer einer Stelle zurechnen.
- **Werkzeug-Überangebot —** Zu viele konkurrierende Frameworks und Checklisten; die Auswahl kostet mehr als die Anwendung.
- **Disziplinäre Trennung —** Ethik und Engineering arbeiten in getrennten Sprachen, Prozessen und Zeitlogiken.

Quelle: Forschungsstand zur Principle-Practice-Gap, referiert im W02-Aktualitätsbriefing (Stand: Anfang September 2026).

Gibt es das richtig geschnittene Werkzeug?

W02 // EINSTIEG // LEITFRAGE

Zu flexibel lädt zum Ethics Washing ein, zu strikt geht am Kontext vorbei. Beides erzeugt dieselbe Wirkungslücke.

- **Spannung —** Prüfbarkeit verlangt Enge, Anwendbarkeit verlangt Weite — jedes Framework wählt hier eine Position.

SPOILER // BLOCK B

Frameworks als Positionen

→ Wir lesen die großen Rahmen in Block B nicht als Wahrheiten, sondern als bewusste Entscheidungen zwischen Weite und Prüfbarkeit.

BLOCK // KONTRAST // 14–18'

Seit einem Monat durchsetzbar

Während die Wirkungslücke diskutiert wird, ist aus einer Ethik-Erwartung eine Rechtspflicht geworden — und im selben Zug abgeschwächt.

Art. 4: KI-Kompetenz wird einforderbar

W02 // EINSTIEG // STAND ANFANG SEPTEMBER 2026

Die Pflicht

Art. 4 EU AI Act verpflichtet Anbieter*innen und Betreiber*innen, für ein ausreichendes Niveau an KI-Kompetenz bei den Personen zu sorgen, die mit ihren Systemen arbeiten. Geltung seit **02.02.2025**, Durchsetzung seit **03.08.2026**.

- **Seit rund einem Monat —** Erst mit der nationalen Durchsetzung wird aus der Pflicht ein einforderbarer Anspruch.
- **Alle Risikoklassen —** Die Pflicht greift unabhängig von der Risikoklasse — auch bei minimalem Risiko.
- **Zwei Adressatengruppen —** Anbieter*innen und Betreiber*innen der Systeme, nicht nur Hersteller*innen.
- **Kein Katalog —** Der Rechtsakt schreibt keine Schulungsform und keine Stundenzahl vor.

AKTUALITÄTSANKER // 03.08.2026

Warum das jetzt zählt

Zum ersten Mal ist eine Kompetenz- statt einer Produktanforderung durchsetzbar. Sie richtet sich nicht an das Modell, sondern an die Organisation und ihre Menschen — genau dort, wo die Wirkungslücke entsteht.

Geltung: seit 02.02.2025

Durchsetzung: seit 03.08.2026

Aus „sicherstellen“ wurde „fördern“

VORHER // ERFOLGSPFLICHT

Sicherstellen

VERLANGT
ein ausreichendes Kompetenzniveau tatsächlich herzustellen.

MASSSTAB
das Ergebnis – die Kompetenz muss vorhanden sein.

BEWEISLAST
Nachweis über das erreichte Niveau der beteiligten Personen.

NACH OMNIBUS // BEMÜHENSPFLICHT

Fördern

VERLANGT
die Entwicklung von KI-Kompetenz aktiv zu fördern.

MASSSTAB
die Anstrengung – kein garantiertes Individualniveau geschuldet.

BEWEISLAST
Nachweis über Maßnahmen, Angebote und deren Passung.

02.02.2025 — Geltung Art. 4

03.08.2026 — Durchsetzung – seit rund einem Monat

Bemühens- statt Erfolgspflicht: Es entscheidet die Qualität der Dokumentation.

Quelle: EU AI Act Art. 4 i. d. F. Digital-Omnibus-Paket; Stand: Anfang September 2026

Was ist eine Pflicht wert, die nur Bemühen verlangt?

W02 // EINSTIEG // LEITFRAGE

Ohne geschuldetes Ergebnis entscheidet die Qualität des Nachweises darüber, ob aus der Norm Praxis wird.

- **Verschiebung —** Geprüft wird nicht mehr, was Menschen können, sondern was die Organisation belegbar dafür getan hat.

SPOILER // BLOCK C

Kompetenz als Nachweis

→ In Block C machen wir die Modul-Policy zum gelebten Beispiel: Kompetenz zeigt sich in dokumentierter, geprüfter Nutzung — nicht in einer Teilnahmebestätigung.

Deshalb zuerst: präzise Begriffe

W02 // EINSTIEG // VERDICHTUNG

01

Konsens ist erreicht, Wirkung nicht

Fünf weltweit geteilte Prinzipien — und in der Breite kaum veränderte Praxis. Der Bruch ist belegt, nicht behauptet.

02

Die Lücke hat Profile

Entkopplung ist heterogen. Wer intervenieren will, muss zuerst diagnostizieren — und dafür braucht er Begriffe, die trennscharf sind.

03

Recht verschiebt die Beweisfrage

Aus „sicherstellen“ wurde „fördern“ — damit entscheidet der Nachweis. Nachweisen kann nur, wer präzise benennt, was geprüft wird.

NEXT // HEUTIGE LEITFRAGE

Vom Wort zur Anforderung

Die Guidelines sind da — warum ändert sich so wenig? Antwort in drei Blöcken: Begriffssystem, Frameworks als Positionen, KI-Kompetenz als nachweisbare Praxis.

● AUS EVIDENZ ABGELEITET

Fahrplan: Quiz, Einstieg, drei Blöcke

W02 // NAVIGATION // MINUTENAGENDA

5' **Retrieval-Quiz**

Stoff aus W01 — unbenotet und anonym, feste Routine ab heute.

18' **Einstieg — Wirkungslücke**

Landkarte 2019, der Bruch, Decoupling-Profile, Werkzeugdilemma, Art. 4.

25' **Block A — Begriffssystem**

Taxonomie, Abgrenzungen, Ethik-Schulen als Begründungsrahmen.

20' **Block B — Frameworks**

Drei Rahmen als Positionen, Prüfliste, Principles-to-Practice-Gap.

17' **Block C — KI-Kompetenz**

Art. 4 inhaltlich, Live-Check zur Nutzung, Deklaration als Nachweis.

10' **Diskussion & Brücke**

Think-Pair-Share, Takeaways, Übergabe an die Flipped-Woche.

HINWEIS // MATERIALUMFANG

Mehr Material als 90 Minuten

Summe: 95 Minuten — bewusst mehr Material als Zeit. Gekürzt wird live; die Kürzungsfolien sind in den Speaker Notes markiert. Schutzgut bleibt die Diskussion.

● AUSWAHL NACH BEDARF

Lernziele heute

W02 // LEARNING OUTCOMES

Die Student*innen …

- **LO 1 —** definieren die zentralen Fachbegriffe präzise: Trustworthiness, Alignment, Accountability, Robustheit, Governance, Audit, Conformity Assessment.
- **LO 2 —** vergleichen den europäischen, den zwischenstaatlichen und den globalen Prinzipienrahmen.
- **LO 3 —** unterscheiden Ethik von Compliance und Transparenz von Interpretierbarkeit und Erklärbarkeit.
- **LO 4 —** nutzen KI-Werkzeuge reflektiert und deklarieren die Nutzung korrekt.

BLOCK A // 25 MIN

Begriffe als Werkzeuge

Jede Dimension bekommt drei Dinge: eine Definition, eine Messgröße und eine verantwortliche Rolle. Alles andere bleibt Rhetorik.

Vertrauen ist nicht Vertrauenswürdigkeit

W02 // DEFINITION

Definition

Trustworthiness = die nachweisbare Eigenschaft eines KI-Systems, berechtigtes Vertrauen zu rechtfertigen — belegt über prüfbare Dimensionen wie Fairness, Robustheit, Transparenz, Accountability und Privatsphäre.

- **Vertrauen —** Erwartung der Nutzer*innen — subjektiv, wird geschenkt oder entzogen.
- **Trustworthiness —** Eigenschaft des Systems — objektivierbar, prüfbar, gestaltbar.
- **Trusted AI —** das Arbeitsfeld: Trustworthiness herstellen und nachweisen.
- **Warum trennen —** Man kann Vertrauen gewinnen, ohne vertrauenswürdig zu sein — genau das ist Ethics Washing.

SURVEY // ACM COMPUTING SURVEYS

Kaur et al. (2022)

„Trustworthy Artificial Intelligence — A Review“ ordnet die Trustworthiness-Dimensionen systematisch und grenzt sie voneinander ab. Wir nutzen den Review als zitierbare Begriffs-Referenz, wenn Definitionen im Semester strittig werden.

Funktion: Begriffs-Referenz W02–W13

Typ: systematischer Review, peer-reviewed

Kalibriertes Vertrauen, nicht maximales

W02 // VERTRAUEN — KALIBRIERT

Das Ziel ist nicht viel Vertrauen, sondern genau so viel, wie die nachgewiesene Trustworthiness rechtfertigt.

- **Overtrust —** Vertrauen ohne Grundlage — man verlässt sich auf ein System, das die Erwartung nicht trägt.
- **Undertrust —** berechtigtes Vertrauen wird verweigert — ein prüfbar gutes System bleibt ungenutzt.
- **Kalibrierung —** Nachweise justieren das Vertrauen; Transparenz und Erklärbarkeit sind die Stellschrauben.

MERKSATZ

Vertrauen ist keine Tugend

Weder blindes Vertrauen noch pauschale Skepsis sind das Ziel, sondern Vertrauen im nachgewiesenen Maß — sonst geht entweder Sicherheit oder Nutzen verloren.

Vom Prinzip zur Praxis: vier Ebenen

abstrakt

1	**PRINZIP**	der Wert auf Framework-Ebene – zum Beispiel Fairness als eine der sieben Anforderungen.
2	**DEFINITION**	präzise Begriffsfassung: Was genau ist gemeint – und was ausdrücklich nicht?
3	**MESSGRÖSSE**	Metrik oder Artefakt, das die Definition prüfbar macht: Kennzahl, Model Card, Testprotokoll.
4	**VERANTWORTLICHE**	Rolle plus Prozess: Wer misst, wer entscheidet, wer haftet – und wie wird das belegt?

arbeitsfähig

Eine Dimension ist erst arbeitsfähig, wenn Messgröße und Verantwortliche benannt sind.
Die beiden unteren Ebenen entscheiden – nicht das Prinzip.

Quelle: Taxonomie-Raster des Moduls, Semesterplan WS 2026/27

*HLEG = high-level expert group on artificial intelligence (eu-expertengruppe für künstliche intelligenz)

Das Raster über das Semester

W02 // TAXONOMIE — ANGEWANDT

Vier Dimensionen, jeweils mit Messgröße und verantwortlicher Rolle — so wird das Raster zum roten Faden:

- **Fairness (W04) —** Messgröße: Kennzahl zur Gleichbehandlung von Gruppen · Rolle: Model Owner mit Eskalationspfad.
- **Transparenz (W05) —** Artefakt: Model Card · Rolle: Dokumentations-Owner im Release-Prozess.
- **Privatsphäre (W06) —** Messgröße: Re-Identifikationsrisiko · Rolle: Datenschutzfunktion der Organisation.
- **Robustheit (W08) —** Messgröße: Fehlerrate unter Störung und Angriff · Rolle: Security-Owner.

Quelle: Semesterplan WS 2026/27 (Taxonomie-Raster); Messgrößen als Ausblick auf die Methodenwochen W04–W08.

Drei Begriffe, drei Prüffragen



Drei unabhängige Achsen: Jede kann getrennt erfüllt oder verletzt sein.
Wer die Begriffe gleichsetzt, verspricht im Audit etwas, das das System nicht leistet.

Quelle: Kaur et al. (2022), ACM Computing Surveys 55(2)

*XAI = explainable artificial intelligence (erklärbare ki)

Fall: transparent, nicht interpretierbar, erklärbar

W02 // TRANSPARENZ — FALLBEISPIEL

Ein Kreditmodell zeigt, dass die drei Achsen unabhängig sind — jede kann getrennt erfüllt oder verletzt sein.

- **Transparent —** Zweck, Datenquellen, Grenzen und Verantwortliche sind dokumentiert — die Offenlegung steht.
- **Nicht interpretierbar —** Das Modell ist zu komplex, um den Mechanismus direkt nachzuvollziehen.
- **Aber erklärbar —** Für jede Ablehnung lassen sich die ausschlaggebenden Faktoren nachgelagert ausweisen (W05).
- **Konsequenz —** Prüfbarkeit entsteht hier nicht durch das Modell, sondern durch Dokumentation plus nachgelagerte Erklärung.

MERKHILFE

Nie synonym verwenden

Ein System kann auf einer Achse stark und auf einer anderen schwach sein. Wer die Begriffe gleichsetzt, verspricht im Audit etwas, das das System nicht leistet.

Alignment und die Spezifikationslücke

Alignment heißt: Das System verfolgt die intendierten Ziele und Werte — nicht nur die optimierte Metrik.

- **Spezifikationslücke —** Jede Metrik ist nur ein Stellvertreter für das eigentlich Gewollte; die Differenz ist die Lücke.
- **Beispiel —** Ein auf Klicks optimiertes Empfehlungssystem trifft die Metrik und verfehlt das Nutzer*innen-Interesse.
- **Anschluss W01 —** Der Agent des Fitnessstudio-Falls war perfekt auf das gestellte Ziel ausgerichtet — und schädigte Dritte.

MERKSATZ

Zielerfüllung ist nicht Zielrichtigkeit

Alignment fragt nicht, ob das System sein Ziel erreicht, sondern ob das Ziel das Richtige war. Deshalb ist Erfolg kein Nachweis von Korrektheit.

Robustheit ist nicht Genauigkeit

W02 // SYSTEMBEGRIFFE (2/3)

Robustheit heißt: zuverlässig auch unter Verteilungsverschiebung, Störung und gezieltem Angriff.

- **Drei Störquellen —** veränderte Datenlage im Betrieb, technische Störungen, absichtliche Manipulation.
- **Abgrenzung —** Ein genaues Modell muss nicht robust sein: Treffer im Testfall ist nicht Stabilität im Ernstfall.
- **Auch sozial —** Robustheit umfasst den zuverlässigen Betrieb im organisatorischen Umfeld, nicht nur im Labor.

AUSBLICK // W08

Robustheit wird praktisch

Angriffsszenarien und Red-Teaming zeigen in W08, wie man Robustheit prüft. Heute geht es nur um den Begriff und seine Abgrenzung zur Genauigkeit.

Accountability und Governance

W02 // SYSTEMBEGRIFFE (3/3)

Zwei Begriffe, die zusammen erst wirksam werden — der eine benennt die Zurechnung, der andere organisiert sie.

- **Accountability —** Zurechenbarkeit: Wer verantwortet Entscheidung und Schaden? Braucht Rollen, Protokolle, Nachweise.
- **Nicht Responsibility —** keine gefühlte Verantwortung, sondern belegbare Zurechnung — mit Beweislast.
- **Governance —** Strukturen und Prozesse, die das organisieren: Policy, Rollen, Eskalation, Audit.
- **Zusammenspiel —** Ohne definierte Rollen keine belastbare Zurechnung — Governance macht Accountability operativ.

BEZUG // W01

Der Urteils-Anker

Das Gericht rechnete im Chatbot-Fall die Aussagen dem Betreiber zu. Accountability ist keine Theorie, sie hat Rechtsfolgen — und war der Grund, warum der Disclaimer nicht half.

Audit ist nicht Conformity Assessment

W02 // PRÜFBEGRIFFE

Drei Begriffe, die im Sprachgebrauch verschmelzen und rechtlich völlig verschiedene Dinge bedeuten.

- **Audit —** systematische, evidenzbasierte Prüfung gegen definierte Kriterien — intern oder extern, freiwillig möglich (W13).
- **Conformity Assessment —** formale Konformitätsbewertung gegen Rechtsnormen — im Rechtsakt Pflicht für Hochrisiko-Systeme (W03).
- **Audit-Trail —** die lückenlose Nachweiskette, auf die sich beides stützt — ohne sie ist keine Prüfung möglich.
- **Praxisbezug —** Im Modul gelebt: die Monospace-Zeile unten links und Ihre Nutzungs-Deklaration im Portfolio.

PRÜFUNGSRELEVANT

Die teuerste Verwechslung

Wer ein freiwilliges Selbst-Assessment als Konformitätsbewertung ausgibt, behauptet Rechtssicherheit, die nicht besteht. Stand: Anfang September 2026.

Ethik ist nicht Compliance

W02 // ABGRENZUNG // LO 3

Zwei Fragen, die im Alltag ständig verschwimmen — und die man auseinanderhalten muss, um beide beantworten zu können.

- **Compliance —** prüft, ob eine bestehende Regel eingehalten ist. Frage: „Ist es erlaubt?“
- **Ethik —** begründet, was gelten soll — auch dort, wo noch kein Gesetz greift. Frage: „Ist es richtig?“
- **Beides möglich —** Ein legales System kann unethisch sein; ein ethisch motiviertes kann rechtswidrig sein.
- **Konsequenz —** Trusted AI arbeitet an beidem — weder Checklisten noch gute Absichten reichen allein.

FALLBEZUG // W01

Erlaubt schützt nicht vor falsch

Der Chatbot-Betreiber war vermutlich compliance-orientiert und haftete trotzdem. Umgekehrt gilt: Wer nur ethisch argumentiert, erfüllt keine Dokumentationspflicht.

Drei Ethik-Schulen als Begründungsrahmen

W02 // BEGRÜNDUNGSRAHMEN

Keine Philosophiegeschichte, sondern drei Argumentationsmuster, die in jeder Trust-Diskussion auftauchen.

- **Deontologie —** Pflichten und Rechte: Richtig ist, was gültigen Regeln folgt — unabhängig vom Ergebnis.
- **Konsequentialismus —** Folgenabwägung: Richtig ist, was den Gesamtnutzen maximiert — Risiken werden bilanziert.
- **Tugendethik —** Charakter und Haltung: Welche Praxis formt vertrauenswürdige Teams und Organisationen?

EINORDNUNG

Keine Schule gewinnt

Die großen Prinzipienrahmen mischen alle drei: Rechte aus der Deontologie, Folgenabwägung aus dem Konsequentialismus, Kultur aus der Tugendethik. Das erklärt ihre Spannungen.

Testfahrt: eine Frage, drei Brillen

W02 // BEGRÜNDUNGSRAHMEN — ANWENDUNG

Fall aus W01: Ein Service-Chatbot macht einer Kundin gegenüber eine falsche Zusage. Wie urteilen die drei Schulen?

- **Deontologisch —** Verletzt sind Wahrheitspflicht und Informationsrechte — unabhängig davon, ob ein Schaden eintrat.
- **Konsequentialistisch —** Bilanz aus Effizienzgewinn gegen Schaden und Vertrauensverlust; Monitoring senkt den Erwartungsschaden.
- **Tugendethisch —** Welche Organisation wollen wir sein? Sorgfaltskultur statt „Move fast and break things“.
- **Beobachtung —** Alle drei nutzen dieselben Fakten und priorisieren sie unterschiedlich — deshalb lohnt der Mehrfachblick.

BRÜCKE ZU BLOCK B

Von der Schule zum Framework

Prinzipienkataloge übersetzen diese Begründungsmuster in Anforderungen. Wie gut das gelingt, entscheidet über ihre Wirkung — Block B vergleicht drei Versuche.

BLOCK B // 20 MIN

Frameworks als Positionen

Drei Rahmen, drei Entscheidungen zwischen Weite und Prüfbarkeit — und ein Instrument,
das den Sprung zur Prüffrage wagt.

Von Grundrechten zu Anforderungen

W02 // EUROPÄISCHER RAHMEN // HLEG 2019

GRUNDRECHTE

Ausgangspunkt: die in den europäischen Verträgen und der Charta verankerten Rechte.

4 PRINZIPIEN

daraus abgeleitete ethische Grundprinzipien — die Begründungsebene.

3 KOMPONENTEN

rechtmäßig, ethisch, robust — alle drei müssen zusammen erfüllt sein (W01).

7 ANFORDERUNGEN

die prüfbare Ebene: konkrete Anforderungen an Systeme, Prozesse und Rollen.

Die Ableitungskette ist das eigentliche Verdienst: kein Prinzipienkatalog, sondern eine begründete Kaskade bis zur Prüfebene.

*HLEG = high-level expert group on artificial intelligence (eu-expertengruppe für künstliche intelligenz)

Zwei Wege zum Prinzip

W02 // ANFORDERUNG ODER WERT

EUROPÄISCHE EXPERTENGRUPPE // 2019

7 Anforderungen

Träger

Expertengruppe der Europäischen Kommission — europäischer Rechtsraum.

Struktur

3 Komponenten führen zu 7 prüfbar formulierten Anforderungen.

Anschluss

direkte Vorarbeit für den Rechtsakt (W03), plus eine eigene Prüfliste.

Position

näher am Pol Prüfbarkeit — dafür regional begrenzt.

OECD // 2019, REV. 2024

5 Prinzipien

Träger

zwischenstaatliche Organisation; Reichweite weit über die Mitglieder hinaus.

Struktur

5 wertebasierte Prinzipien plus Empfehlungen an Staaten.

Anschluss

Referenzrahmen für Politik und Berichtswesen; Fassung 2024 überarbeitet.

Position

näher am Pol Weite — anschlussfähig, aber nicht direkt prüfbar.

*OECD = organisation for economic co-operation and development (organisation für wirtschaftliche zusammenarbeit und entwicklung)

Der globale Rahmen in Zahlen

W02 // UNESCO 2021 // STAND ANFANG SEPTEMBER 2026

193

Mitgliedstaaten nahmen die Empfehlung zur Ethik der KI 2021 an — der einzige echt globale Standard.

11

Politik-Handlungsfelder: von Governance über Bildung und Daten bis Umwelt.

~30

Länder nutzen sie inzwischen als Grundlage nationaler Gesetzgebung.

Quelle: UNESCO (2021): Recommendation on the Ethics of Artificial Intelligence; Stände laut W02-Aktualitätsbriefing (Anfang September 2026).

*UNESCO = united nations educational, scientific and cultural organization

Governance-Instrumente statt nur Prinzipien

W02 // WARUM DER GLOBALE RAHMEN WIRKT

Die Empfehlung von 2021 liefert nicht nur Werte, sondern zwei Instrumente, die den Sprung in die Praxis versuchen.

- **RAM —** Readiness Assessment Methodology: erhebt den Reifegrad eines Landes rechtlich, technisch und institutionell.
- **Impact Assessment —** strukturierte Folgenabschätzung vor dem Einsatz eines Systems — Wirkung prüfen, nicht nur Werte bekennen.
- **Menschenrechtsfundierung —** Die Werte sind an bestehende Menschenrechtsinstrumente gebunden, nicht frei formuliert.
- **Deshalb wirksam —** Instrument plus Anbindung an geltendes Recht — genau die Kombination, die Prinzipienkatalogen fehlt.

BRÜCKE // W06

Verwandte Instrumente

Die Logik der vorgeschalteten Folgenabschätzung kennen Sie aus dem Datenschutzrecht; die Verwandtschaft vertiefen wir in W06.

*RAM = readiness assessment methodology (reifegrad-erhebungsmethodik)

Drei Rahmen, ein Konsens, drei Grenzen

GLOBALER RAHMEN

UNESCO 2021

STÄRKE
am breitesten getragen, mit Governance-Instrumenten

GRENZE
rechtlich unverbindlich

ZWISCHENSTAATLICHER RAHMEN

OECD 2019, rev. 2024

STÄRKE
knapp, wertebasiert, politisch breit anschlussfähig

GRENZE
nicht unmittelbar prüfbar

EUROPÄISCHER RAHMEN

HLEG 2019

STÄRKE
am detailliertesten, am nächsten an der Prüfbarkeit

GRENZE
regional begrenzt



Weite / Anschlussfähigkeit — Prüfbarkeit

Gemeinsame Grenze: Keiner der drei erzwingt etwas.
Verbindlichkeit entsteht erst durch Recht oder Vertrag – die Rahmen sind Positionen, keine Wahrheiten.

Quelle: HLEG (2019); OECD (2019, rev. 2024); UNESCO (2021); Stand: Anfang September 2026

Von der Anforderung zur Prüffrage

W02 // ALTAI ALS INSTRUMENT

Das Instrument

ALTAI übersetzt die sieben europäischen Anforderungen in konkrete Prüffragen zur Selbstbewertung. Aus einem Wert wird eine Frage, auf die es eine belegbare Antwort geben muss.

- **Mechanik —** Jede Anforderung wird in Belegfragen zerlegt — nicht in Meinungsfragen.
- **Beispiel Aufsicht —** Können Menschen die Entscheidung des Systems überstimmen und den Betrieb stoppen?
- **Beispiel Fairness —** Wurde über Gruppen hinweg auf Verzerrungen geprüft — und ist das dokumentiert?
- **Grenze —** Selbstbewertung bleibt Selbstbewertung: freiwillig, unabhängig geprüft wird hier nichts.

ANSCHLUSS // BLOCK A

Die Begriffe zahlen sich aus

Das Instrument arbeitet mit Audit-Logik, nicht mit Konformitätslogik. Wer die beiden Prüfbegriffe aus Block A trennt, erkennt sofort, was es leisten kann — und was nicht.

Charakter: freiwilliges Selbst-Assessment

Vertiefung: Audit-Methodik in W13

*ALTAI = assessment list for trustworthy artificial intelligence (prüfliste für vertrauenswürdige ki)

Drei Verbindlichkeitsgrade

W02 // ETHIK-RAHMEN, RECHT, MANAGEMENTNORM

Dieselbe Sache — vertrauenswürdige KI — wird von drei Instrumenttypen mit sehr unterschiedlicher Härte adressiert. Stand: Anfang September 2026.

- **Ethik-Rahmen —** Soft Law: begründet und orientiert, sanktioniert aber nicht. Wirkung über Reputation und Übernahme.
- **Recht —** Der EU AI Act verpflichtet unmittelbar. Art. 4 ist seit 03.08.2026 durchsetzbar, Art. 50 seit 02.08.2026.
- **Managementnorm —** ISO/IEC 42001 macht aus Prinzipien Prozesse und ist zertifizierbar — die Brücke Prinzip zu Prozess (W13).
- **Zusammenspiel —** Der Rahmen begründet, das Recht verpflichtet, die Norm organisiert. Keiner ersetzt die anderen.

*ISO/IEC = international organization for standardization / international electrotechnical commission

Der Principles-to-Practice-Gap

Die Lücke zwischen weltweit konvergenten Prinzipienkatalogen und ihrer tatsächlichen Wirkung in Entwicklung und Betrieb von KI-Systemen.

PRINZIPIEN

weltweit konvergent

GAP

PRAXIS

Entwicklung und Betrieb

„Principles alone cannot guarantee ethical AI."

Mittelstadt (2019), Nature Machine Intelligence

KEINE PROFESSION

Keine gemeinsamen Ziele und Treuepflichten wie etwa in der Medizin.

KEINE METHODIK

Erprobte Wege von der Norm zur konkreten Fallentscheidung fehlen.

SCHWACHE RECHENSCHAFT

Kaum Sanktionsmechanismen – Verstöße bleiben folgenlos.

Quelle: Mittelstadt (2019); Decoupling in AI ethics (2026)

BLOCK C // 17 MIN

KI-Kompetenz als Nachweis

Artikel 4 richtet sich nicht an Modelle, sondern an Menschen und Organisationen — und trifft damit auch dieses Modul.

Was KI-Kompetenz inhaltlich verlangt

W02 // ART. 4 // MINDESTANFORDERUNGEN

Die Norm nennt keine Schulungsform, aber inhaltliche Mindestanforderungen — drei Fähigkeiten:

- **Fähigkeiten und Grenzen —** verstehen, was ein System kann und wo es systematisch versagt — Grenzen ausdrücklich eingeschlossen.
- **Risiken erkennen —** typische Fehlermuster und Schadenspfade der eingesetzten Systeme benennen können.
- **Outputs im Kontext deuten —** Ergebnisse in der konkreten Verwendungssituation interpretieren statt sie zu übernehmen.

BEOBACHTUNG

Das ist keine Werkzeugschulung

Zwei der drei Anforderungen zielen auf Grenzen und Risiken. Wer nur Bedienung schult, erfüllt die Norm nicht — auch nicht als Bemühenspflicht.

Der Maßstab ist kontextuell

W02 // ART. 4 // WIE VIEL GENÜGT

Es gibt kein einheitliches Niveau. Der Maßstab ergibt sich aus drei Faktoren (Recital 20).

- **Beteiligte Personen —** technisches Vorwissen, Erfahrung, Ausbildung derer, die mit dem System arbeiten.
- **Art der Nutzung —** Ein Rechercheassistent verlangt anderes Wissen als ein System in der Entscheidungsvorbereitung.
- **Betroffene Gruppen —** Je schutzbedürftiger die Betroffenen, desto höher der Maßstab.

ANSCHLUSS // EINSTIEG

Kontextsensitiv statt kontextblind

Die Norm vermeidet bewusst den Pol „zu strikt“: Sie schreibt keine Stundenzahl vor, sondern verlangt eine begründete Passung — und verschiebt damit die Beweislast auf die Begründung.

Umsetzungshilfe: das lebende Verzeichnis

W02 // ART. 4 // WERKZEUG

Das AI Office veröffentlichte im Februar 2025 ein „Living repository of AI literacy practices“ — eine offene Sammlung von Umsetzungsbeispielen.

- **Idee —** Organisationen tragen ihre Praktiken ein; andere übernehmen und passen an.
- **Charakter —** keine Norm und keine Genehmigung — Orientierung, nicht Nachweis.
- **Nutzen —** senkt die Auswahlkosten, die als Werkzeug-Überangebot im Einstieg als Gap-Ursache auftauchten.

QUELLENKRITIK

Eintrag ist kein Beleg

Wer eine Praxis aus dem Verzeichnis übernimmt, hat noch keinen Nachweis erbracht. Der Nachweis entsteht erst durch die dokumentierte Anwendung im eigenen Kontext.

Die Modul-Policy als gelebtes Beispiel

W02 // ART. 4, AN UNS SELBST

Die KI-Nutzungs-Policy aus W01 ist keine Hausordnung, sondern ein Umsetzungsbeispiel der Norm — angewandt auf Ihren Studienalltag.

- **Erlaubt —** KI-Werkzeuge für Recherche, Strukturierung, Code-Hilfe und Sprachglättung — mit eigener Prüfung.
- **Deklarationspflichtig —** jede substanzielle Nutzung im Portfolio: Werkzeug, Zweck, Art der Prüfung.
- **Unzulässig —** ungeprüfte Übernahme fremder Inhalte und erfundene oder nicht nachgelesene Quellen.
- **Warum so —** Die Policy prüft nicht Ihre Bedienfertigkeit, sondern Ihre Fähigkeit, Grenzen zu erkennen — wie die Norm.

META // DIDAKTIK

Die Norm an sich selbst erleben

Sie sind in diesem Modul beides: Betroffene der Kompetenzpflicht und künftige Adressat*innen auf der Anbieter- oder Betreiberseite. Die Semesterarbeit als APL macht das Erlebnis prüfbar.

*APL = alternative prüfungsleistung

Die Deklaration als Audit-Trail

W02 // NACHWEIS IN DREI FELDERN

Drei Felder je Arbeitsschritt — nicht pauschal für die ganze Arbeit. Das ist dieselbe Logik, die ein Audit verlangt.

- **Welches Werkzeug —** Name und Einsatzform, pro Arbeitsschritt dokumentiert.
- **Wofür —** Zweck der Nutzung: Recherche, Strukturierung, Code-Hilfe, Sprachglättung.
- **Wie geprüft —** Ihre Verifikationsleistung: Quellen gegengelesen, Code getestet, Aussagen fachlich validiert.
- **Wirkung —** Aus einer Behauptung wird eine Nachweiskette — genau der Schritt, den die Bemühenspflicht verlangt.

BRÜCKE ZUM BEGRIFFSSYSTEM

Alles hängt zusammen

Werkzeug ist Transparenz, Zweck ist Alignment, Prüfung ist Accountability. Die Deklaration ist Block A im Kleinformat — und sie ist prüfbar.

Live-Check: erlaubt, deklarationspflichtig, unzulässig?

W02 // AI-LITERACY // 4 MIN

Q1 Sie lassen ein Sprachmodell Ihre Glossar-Definition sprachlich glätten und prüfen jede Aussage nach. Einordnung?

Q2 Sie übernehmen die Zusammenfassung eines Papers ungelesen in Ihr Exposé. Einordnung — und was genau fehlt?

Q3 Sie lassen sich fünf Quellen vorschlagen und zitieren zwei davon, ohne sie geöffnet zu haben. Einordnung?

Q4 Wie sähe die korrekte Deklaration für Fall 1 aus — Werkzeug, Zweck, Prüfung?

Abstimmung per Handzeichen, dann Begründung. Der Policy-Wortlaut liegt im OPAL-Kurs.

Auflösung des Live-Checks

W02 // AI-LITERACY // EINORDNUNG

Vier Fälle, vier Einordnungen — und in jeder steckt eine Begriffsentscheidung aus Block A.

- **Fall 1 —** Erlaubt und deklarationspflichtig: Sprachglättung mit nachgelagerter Prüfung — Transparenz plus Accountability.
- **Fall 2 —** Unzulässig: ungeprüfte Übernahme. Es fehlt die Verifikationsleistung, also der ganze Nachweis.
- **Fall 3 —** Unzulässig: Zitieren ohne Lektüre. Auch wenn die Quelle existiert, fehlt die geprüfte Zuordnung.
- **Fall 4 —** Werkzeug benennen, Zweck „Sprachglättung“, Prüfung „jede Aussage gegen die Primärquelle gelesen“.

MERKSATZ

Die Prüfung ist der Nachweis

Nicht die Nutzung entscheidet über die Zulässigkeit, sondern die dokumentierte Prüfung. Genau darin unterscheidet sich Kompetenz von Bedienung.

DISKUSSION // THINK-PAIR-SHARE // 10 MIN

„Wenn sich die Welt auf fünf Prinzipien einigt, ist KI-Ethik im Kern gelöst.“

PRO

Konvergenz schafft eine gemeinsame Sprache und macht Regulierung, Zertifizierung und Audits überhaupt anschlussfähig. Das Fundament steht.

CONTRA

Ohne Messgrößen, Verantwortliche und Sanktionen bleiben fünf Prinzipien fünf Worte — belegt durch die Entkopplungsforschung 2026.

Key Takeaways

W02 // ZUSAMMENFASSUNG + AUSBLICK

01

Begriffe sind Werkzeuge, nicht Dekoration

Jede Dimension braucht Definition, Messgröße und Verantwortliche — sonst bleibt sie Rhetorik. Das ist die Antwort auf die Leitfrage.

02

Frameworks sind Positionen

Europäischer, zwischenstaatlicher und globaler Rahmen wählen verschieden zwischen Weite und Prüfbarkeit. Keiner erzwingt etwas.

03

Kompetenz zeigt sich im Nachweis

Seit 03.08.2026 ist Art. 4 durchsetzbar, seit dem Omnibus als Bemühenspflicht — damit entscheidet die Qualität der Dokumentation.

NEXT // W03 — FLIPPED!

EU AI Act und die ersten Urteile

Pflicht-Vorablektüre (~2 h): LG München I, 28.05.2026, 26 O 869/26 und OLG Hamm, 12.05.2026, 4 UKl 3/25 — annotiert lesen, dazu das Verständnis-Quiz im OPAL.

READER IM OPAL-KURS

VERTIEFUNG // OPTIONAL // SELBSTSTUDIUM

Vertiefung & Quellen

Paper-Steckbriefe zur W02-Literaturliste, die Gap-Forschung 2026 und ein Quellenkritik-Baustein. Nicht Teil der 90 Minuten.

So nutzen Sie diese Vertiefung

VERTIEFUNG // LESEHINWEIS

Diese Folien sind optional und ersetzen keinen Hauptpfad-Inhalt. Drei Einsatzarten:

- **Selbststudium —** Die Steckbriefe sind Türöffner zu den Originaltexten der W02-Literaturliste, kein Ersatz für die Lektüre.
- **Fachgespräch —** Am Ende stehen mögliche Prüfungsfragen und ein Selbstcheck gegen die vier Lernziele.
- **Methodenkompetenz —** Der Quellenkritik-Baustein zeigt, wie man Preprints und peer-reviewte Arbeiten unterschiedlich gewichtet.

HINWEIS

Kein Prüfungs-Muss

Prüfungsrelevant ist der Hauptpfad. Die Vertiefung erweitert Verständnis und Fachgespräch-Sicherheit — sie ist Angebot, nicht Pflicht.

Steckbrief: Jobin, Ienca & Vayena (2019)

VERTIEFUNG // PAPER-STECKBRIEF

Kernbeitrag

The global landscape of AI ethics guidelines (Nature Machine Intelligence 1, 2019): die erste systematische Landkarte der weltweiten KI-Ethik-Prinzipien — Vorab-Lektüre dieser Woche.

- **Frage —** Konvergiert die Welt bei KI-Ethik — und wenn ja, worauf genau?
- **Design —** Scoping Review: systematische Sammlung, dann inhaltsanalytische Kodierung der genannten Prinzipien.
- **Warum zitierbar —** peer-reviewed, in einem der Leitjournale des Feldes, mit offengelegter Verzerrung des Korpus.

ROLLE IM MODUL

Empirische Basis

Die Studie liefert die Datengrundlage des Prinzipien-Mapping in der Übung und den empirischen Beleg für den Satz „Konvergenz ist nicht Umsetzung“.

Zugang: frei (arXiv 1906.11668)

Status: peer-reviewed

Die elf Prinzipien im Einzelnen

VERTIEFUNG // JOBIN ET AL.

Die fünf konvergenten Prinzipien sind fett; die übrigen sechs erscheinen seltener, aber regelmäßig:

- **Konvergent — Transparenz · Fairness und Gerechtigkeit · Schadensvermeidung · Verantwortung · Privatsphäre**
- **Weitere —** Benefizienz, Freiheit und Autonomie, Vertrauen, Nachhaltigkeit, Würde, Solidarität.
- **Auffällig —** Nachhaltigkeit, Würde und Solidarität sind deutlich seltener — die sozialen und ökologischen Ränder fehlen.
- **Divergenz —** Trotz gleicher Worte unterscheiden sich Auslegung, Begründung und empfohlene Umsetzung erheblich.

Quelle: Jobin, Ienca & Vayena (2019), Nature Machine Intelligence 1 (arXiv 1906.11668), peer-reviewed.

Steckbrief: Kaur et al. (2022)

VERTIEFUNG // PAPER-STECKBRIEF

Kernbeitrag

Trustworthy Artificial Intelligence — A Review (Kaur, Uslu, Rittichier & Durresi, ACM Computing Surveys 55(2), 2022): systematischer Überblick über die Dimensionen vertrauenswürdiger KI und ihre technischen Umsetzungen.

- **Typ —** systematischer Review — ordnet ein Forschungsfeld, statt neu zu experimentieren.
- **Leistung —** definiert die Dimensionen konsistent und grenzt sie gegeneinander ab.
- **Warum zitierbar —** erschienen in einem der renommiertesten Übersichtsjournale der Informatik.

ROLLE IM MODUL

Begriffs-Referenz

Wo Marketing Begriffe verwässert, liefert dieser Review die belastbare, zitierbare Definition. Er ist unsere Schiedsinstanz, wenn im Semester Definitionen strittig werden.

Publikation: ACM Computing Surveys 55(2)

Zugang: lizenzpflichtig; Preprint über Autorenseiten

Wie der Review aufgebaut ist

VERTIEFUNG // KAUR ET AL. // LESEPFAD

Der Review folgt einem wiederkehrenden Muster — wer es kennt, liest ihn deutlich schneller:

- **Je Dimension —** Begriffsklärung, dann Verfahren, dann offene Forschungsfragen — dasselbe Schema durchgehend.
- **Technische Linie —** Jede Dimension wird an konkrete Verfahren gebunden, nicht nur begrifflich behandelt.
- **Lesepfad Modul —** Nur die Begriffsklärungen lesen genügt für W02; die Verfahrensteile begleiten W04 bis W08.
- **Grenze —** Stand 2022 — generative Systeme und agentische Architekturen sind kaum abgedeckt.

LESETIPP

Selektiv lesen

Ein Review von diesem Umfang wird nicht von vorn bis hinten gelesen, sondern nach Dimension aufgeschlagen — genau so ist er gebaut.

Steckbrief: Mittelstadt (2019)

VERTIEFUNG // PAPER-STECKBRIEF

Kernthese

Principles alone cannot guarantee ethical AI (Nature Machine Intelligence 1, 2019): warum die Analogie zur Medizinethik trägt — und wo sie für die KI-Entwicklung bricht.

- **Ausgangspunkt —** Die KI-Ethik übernimmt die vier Bioethik-Prinzipien — aber nicht deren institutionelle Infrastruktur.
- **Argumentationsform —** kein empirisches Papier, sondern begriffliche Kommentierung mit Disanalogie-Argument.
- **Warum zitierbar —** meistzitierte Gegenposition zum Prinzipien-Optimismus; setzt den Begriff des Gap durch.

ROLLE IM MODUL

Begründung des Modulaufbaus

Mittelstadt begründet, warum dieses Modul auf Operationalisierung setzt: Der Gap schließt sich durch Metriken, Artefakte und Audits, nicht durch einen weiteren Prinzipienkatalog.

Typ: Comment, peer-reviewed

Zugang: Preprint frei über SSRN

Vier Disanalogien zur Medizin

VERTIEFUNG // DAS ARGUMENT IM DETAIL

Was die Medizin ethisch trägt und der KI-Entwicklung fehlt — vier Unterschiede, die das Gap-Argument stützen:

- **Gemeinsame Ziele —** Die Medizin dient der Gesundheit; die KI-Entwicklung dient wechselnden Auftraggeberzielen.
- **Professionsgeschichte —** Die Medizin hat jahrhundertealte Berufsnormen und eine gewachsene Berufskultur; die KI-Entwicklung nicht.
- **Übersetzungsmethoden —** Die Medizin kennt erprobte Wege von der Norm zur Fallentscheidung: Ethikkommissionen, Leitlinien.
- **Rechenschaft —** Die Medizin hat Zulassung, Haftung und Kammern; die KI-Entwicklung hat schwache bis keine Sanktionen.

PRÜFUNGSTIPP

Die Analogie als Prüfmuster

Wer die vier Disanalogien nennen und je ein KI-Beispiel geben kann, hat den Gap verstanden. Zusatzpunkt: benennen, welche davon der EU AI Act adressiert — und welche nicht.

Steckbrief: Floridi & Cowls (2019)

VERTIEFUNG // PAPER-STECKBRIEF

Kernbeitrag

A Unified Framework of Five Principles for AI in Society (Harvard Data Science Review 1(1), 2019): Verdichtung mehrerer Prinzipienkataloge auf einen kohärenten Kern von fünf Prinzipien; Open Access.

- **Vorgehen —** Synthese hochkarätiger Prinzipiensets zu einem gemeinsamen Kern — Theorie statt Erhebung.
- **Basis —** die vier klassischen Bioethik-Prinzipien; sie tragen nach Ansicht der Autoren auch für KI.
- **Ergänzung —** Explicability als fünftes, KI-spezifisches Prinzip.

ROLLE IM MODUL

Gegenstück zur Empirie

Wo Jobin et al. messen, argumentiert Floridi: Die Landschaft lässt sich auf einen kohärenten Kern reduzieren. Beide Texte zusammen zeigen, dass Konvergenz sowohl gemessen als auch begründet werden kann.

Zugang: Open Access

Typ: theoretische Synthese

Vier Bioethik-Prinzipien plus Explicability

VERTIEFUNG // UNIFIED FRAMEWORK

Warum die Medizin-Prinzipien tragen — und warum die KI ein fünftes braucht:

- **Beneficence —** Gutes bewirken: das Wohlergehen von Mensch und Umwelt aktiv fördern.
- **Non-Maleficence —** Schaden vermeiden: Sicherheit und Widerstandsfähigkeit gegen Missbrauch.
- **Autonomy —** menschliche Selbstbestimmung wahren; Kontrolle bewusst teilen, nicht abgeben.
- **Justice —** Fairness und gerechte Verteilung von Nutzen und Risiko.
- **Explicability —** das KI-spezifische fünfte: Nachvollziehbarkeit plus Rechenschaft — es ermöglicht die anderen vier.

Quelle: Floridi & Cowls (2019), Harvard Data Science Review 1(1), Open Access.

Steckbrief: UNESCO (2021)

VERTIEFUNG // PAPER-STECKBRIEF

Einordnung

Recommendation on the Ethics of Artificial Intelligence (2021): der erste von 193 Mitgliedstaaten angenommene globale Ethik-Standard für KI — rechtlich unverbindlich, politisch beispiellos breit getragen.

- **Textsorte —** völkerrechtliches Instrument in Empfehlungsform — kein Vertrag, keine Sanktion.
- **Anspruch —** nicht nur Werte, sondern konkrete Politik-Handlungsfelder für Mitgliedstaaten.
- **Wirkungsbelege —** rund 30 Länder nutzen sie als Grundlage nationaler Gesetzgebung (Stand: Anfang September 2026).

ROLLE IM MODUL

Konvergenz ist politisch möglich

Die Empfehlung ist der beste Gegenbeleg zur These, Prinzipienarbeit bleibe wirkungslos — sie zeigt, dass ein Instrument plus Rechtsanbindung tatsächlich Gesetzgebung anstößt.

Status: Soft Law

Zugang: frei über unesdoc

*UNESCO = united nations educational, scientific and cultural organization

Aufbau der Empfehlung

VERTIEFUNG // LESEPFAD

Das Dokument ist in Ebenen gebaut — von abstrakten Werten zu konkreter Politik. Wer es liest, sollte die Ebene kennen, auf der er argumentiert.

- **Werte —** oberste Ebene: Menschenrechte und Würde, Umwelt und Ökosysteme, Vielfalt, friedliche Gesellschaften.
- **Prinzipien —** mittlere Ebene: unter anderem Proportionalität, Sicherheit, Fairness, Transparenz, menschliche Aufsicht.
- **Handlungsfelder —** unterste Ebene: die elf Politikfelder, in denen Mitgliedstaaten konkret tätig werden sollen.
- **Lesetipp —** Für Argumentationen in der Semesterarbeit sind die Handlungsfelder brauchbarer als die Werteebene.

*UNESCO = united nations educational, scientific and cultural organization

Steckbrief: Decoupling in AI ethics (2026)

VERTIEFUNG // AKTUELLE FORSCHUNG

Kernbeitrag

„Decoupling in AI ethics: Learning how to walk the talk“ (Empirical Software Engineering, 2026): systematische Feldforschung zur Entkopplung zwischen ethischer Deklaration und tatsächlicher Betriebspraxis.

- **Beitrag —** macht aus dem Vorwurf des Ethics Washing einen empirisch untersuchbaren Gegenstand.
- **Design —** Feldforschung in verschiedenen Organisationskontexten statt Dokumentenanalyse.
- **Ergebnis —** distinkte Entkopplungs-Profile — die Lücke ist heterogen und damit gezielt adressierbar.

ROLLE IM MODUL

Warum das den Einstieg trägt

Der Vorwurf des Ethics Washing war jahrelang plausibel und empirisch dünn. Diese Arbeit liefert die Fundierung — und ist deshalb im Einstieg die Belegquelle statt einer Meinung.

Publikation: Empirical Software Engineering (2026)

Status: peer-reviewed

Die Gap-Forschung 2026 im Überblick

VERTIEFUNG // VIER WEITERE QUELLEN

Ergänzend zur Feldstudie vier Arbeiten — mit ausdrücklich unterschiedlicher Quellengüte:

- **The uselessness of AI ethics —** AI and Ethics (Springer) — peer-reviewed; die schärfste Zuspitzung der Wirkungslosigkeits-These.
- **Principle-based AI ethics —** AI and Ethics (2025) — peer-reviewed; Herausforderungen und Aussichten prinzipienbasierter Ansätze.
- **Crossing the gap —** arXiv 2406.15376 — **Preprint, nicht peer-reviewed**; Vorschlag eines ethischen Problemlöse-Ansatzes.
- **Ethical AI framework —** arXiv 2603.06599 — **Preprint, nicht peer-reviewed**; Weg von der Philosophie zur Praxis.

Quelle: Quellenzusammenstellung laut W02-Aktualitätsbriefing (Recherchestand 03.09.2026). Preprints ohne Peer Review sind entsprechend markiert.

Quellenkritik: Preprint oder Publikation?

VERTIEFUNG // METHODEN-MIKROBAUSTEIN

Ein aktuelles Feld produziert schneller Preprints als Reviews. Vier Fragen, die Sie vor jedem Zitat stellen:

- **Peer Review —** Ist die Arbeit begutachtet — und wo? Ein Preprint ist eine Behauptung, keine geprüfte Erkenntnis.
- **Primär oder sekundär —** Erhebt die Quelle selbst, oder referiert sie andere? Sekundärangaben immer als solche kennzeichnen.
- **Design —** Dokumentenanalyse, Feldforschung oder Essay? Das Design begrenzt, was die Arbeit belegen kann.
- **Stand —** Passt das Erhebungsjahr zur Behauptung? Ein Befund von 2019 belegt keine Praxis von 2026.

REGEL FÜRS SEMESTER

Ampel statt Bauchgefühl

In Ihrer Semesterarbeit wird jede Quellenliste ampelbewertet: grün für peer-reviewte Primärquellen, gelb für Sekundärangaben und Preprints, rot für Unbelegtes. Lücken werden benannt, nicht verdeckt.

Fachgespräch: mögliche W02-Fragen

VERTIEFUNG // PRÜFUNGSVORBEREITUNG

Typische Fragen zum Stoff dieser Woche — nicht auswendig lernen, sondern argumentieren üben:

- **Begriffe —** Trennen Sie Transparenz, Interpretierbarkeit und Explainability an einem Beispiel Ihrer Wahl.
- **Taxonomie —** Welche Messgröße und welche Rolle würden Sie der Dimension Robustheit zuordnen — und warum?
- **Frameworks —** Warum ist der HLEG-Rahmen prüfbarer und der globale wirkungsvoller? Was folgt daraus?
- **Gap —** Nennen Sie zwei empirische und zwei strukturelle Ursachen der Wirkungslücke.
- **Art. 4 —** Was änderte sich durch den Digital Omnibus — und welche Folgen hat das für den Nachweis?

BEWERTUNGSHINWEIS

Argumentieren statt aufzählen

Im Fachgespräch zählt nicht die Liste, sondern die Begründung: Warum diese Messgröße, warum diese Rolle, warum diese Quelle — und wo liegt die Grenze Ihrer Aussage?

*HLEG = high-level expert group on artificial intelligence (eu-expertengruppe für künstliche intelligenz)

Selbst-Check: die vier Lernziele

VERTIEFUNG // LERNSTANDSKONTROLLE

Prüfen Sie sich selbst — ehrlich und ohne Notendruck. Wenn eine Zeile wackelt, wissen Sie, wo Sie nachlesen:

- **LO 1 erreicht? —** Sie definieren Trustworthiness, Alignment, Accountability, Governance, Audit und Conformity Assessment ohne Nachschlagen.
- **LO 2 erreicht? —** Sie benennen für alle drei Rahmen je eine Stärke und eine Grenze.
- **LO 3 erreicht? —** Sie erklären an einem Beispiel, wann etwas erlaubt und dennoch falsch ist.
- **LO 4 erreicht? —** Sie formulieren eine korrekte Nutzungs-Deklaration mit Werkzeug, Zweck und Prüfung.

NÄCHSTER SCHRITT

Vor W03 zu tun

Beide Urteile annotiert lesen und das Verständnis-Quiz im OPAL bearbeiten. Die Präsenz in W03 ist Anwendung — mit vertieftem Urteilsvergleich.