Fairness & Bias-Metriken

Leitfrage: Wenn nicht alle Fairness-Metriken zugleich erfüllbar sind, nach welcher entscheiden wir, und wie begründen wir das? · 28.10.2026

Retrieval: Stoff aus W03

RETRIEVAL // 5 MIN

Q1 Welche zwei Achsen unterscheiden die drei KI-Entscheidungen aus W03?

Q2 Ab wann gelten die Anhang-III-Pflichten?

Q3 Wer trägt bei eingekaufter Screening-Software welche Pflichten?

EINSTIEG // PLENUM // 3 MIN

„Ihre Online-Bewerbung wird nach 41 Sekunden abgelehnt. Ohne Begründung, ohne dass ein Mensch sie gelesen hat.“

FRAGE 1

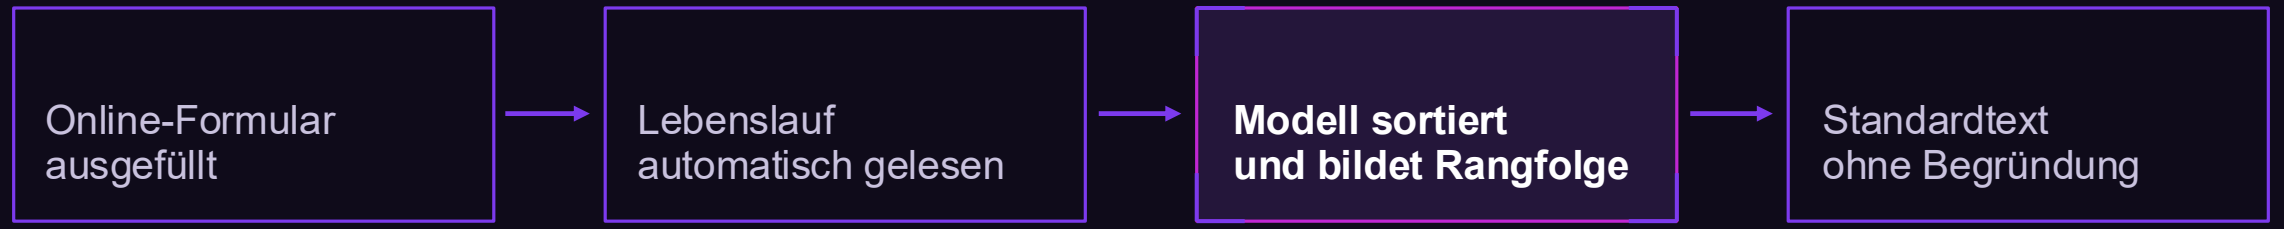
Hat hier jemand etwas falsch gemacht?

FRAGE 2

Woran würden Sie merken, dass Sie benachteiligt wurden?

KONSTRUIERTE VIGNETTE

Sichtbares und Verborgenes im Screening



BLEIBT VERBORGEN

Entscheidungskriterium
Wonach wurde sortiert?

Gewichtung
Welches Merkmal zählte wie stark?

Vergleichsgruppe
Gegen wen wurde verglichen?

Konstruierte Lehrvignette.

Algorithmische Monokultur im Screening

EINSTIEG // BELEG

4 Mio.

Bewerbungen, 156 US-Arbeitgeber, ein Anbieter.

25,9 %

der Bewerbungen schwarzer Bewerbender gingen an Stellen, die ihre Gruppe benachteiligten.

14,7 %

der Bewerbungen asiatischer Bewerbender gingen an Stellen, die ihre Gruppe benachteiligten.

Quelle: Bommasani et al. (2026), FAccT, arXiv 2605.27371

Proxy-Merkmale im Bewerbungsformular

ERHOBENES MERKMAL		GESCHÜTZTES ATTRIBUT
Abschlussjahrgang grenzt das Geburtsjahr auf wenige Jahre ein.	→	**Alter**
Postleitzahl Wohnlagen sind nicht zufällig verteilt.	→	**ethnische Herkunft**
Lücken im Lebenslauf Elternzeit-Lücken treffen häufiger Frauen.	→	**Geschlecht**

Illustration nach Barocas, Hardt & Narayanan (2023).

Was ein Proxy-Merkmal ist

DEFINITION // BAROCAS ET AL. (2023)

Ein **Proxy-Merkmal** hängt so eng mit einem geschützten Attribut zusammen, dass ein Modell es faktisch mitnutzt, ohne es gespeichert zu haben.

Real

Statistisch messbar.

Absichtslos

Niemand hat ihn eingebaut.

Unauffällig

Im Katalog steht Abschlussjahr.

DER BRUCH

„Das Modell hat keinen Fehler gemacht. Es hat gelernt, was in den Daten stand.“

FOLGE 1

Genauigkeit fragt nach Treffern, Fairness nach der Verteilung der Fehler.

FOLGE 2

Fairness braucht eigene Kennzahlen.

Fahrplan und Lernziele

NAVIGATION // 90 MIN

10'	**Ankommen, Retrieval**
12'	**Einstieg: Screening**
12'	**Block A: Bias-Quellen**
18'	**Block B: Messen**
14'	**Block C: Grenzen**
24'	**Diskussion, Abschluss**

LERNZIELE

(1) erklären Bias-Quellen entlang des ML-Lifecycles
(2) berechnen und interpretieren Fairness-Metriken (Demographic Parity, Equalized Odds)
(3) bewerten Trade-offs zwischen Metriken (Unmöglichkeitsresultate).

BLOCK A // 12 MIN

Woher kommt der Bias?

Benennbare Stellen im Lebenszyklus.

Bias: statistisch und sozial

DEFINITION // MEHRABI ET AL. (2021)

Bias ist eine systematische Verzerrung, die bei Wiederholung erneut auftritt.

STATISTISCH // WERTNEUTRAL

Abweichung einer Schätzung

Eignung einer Gruppe zu niedrig geschätzt.

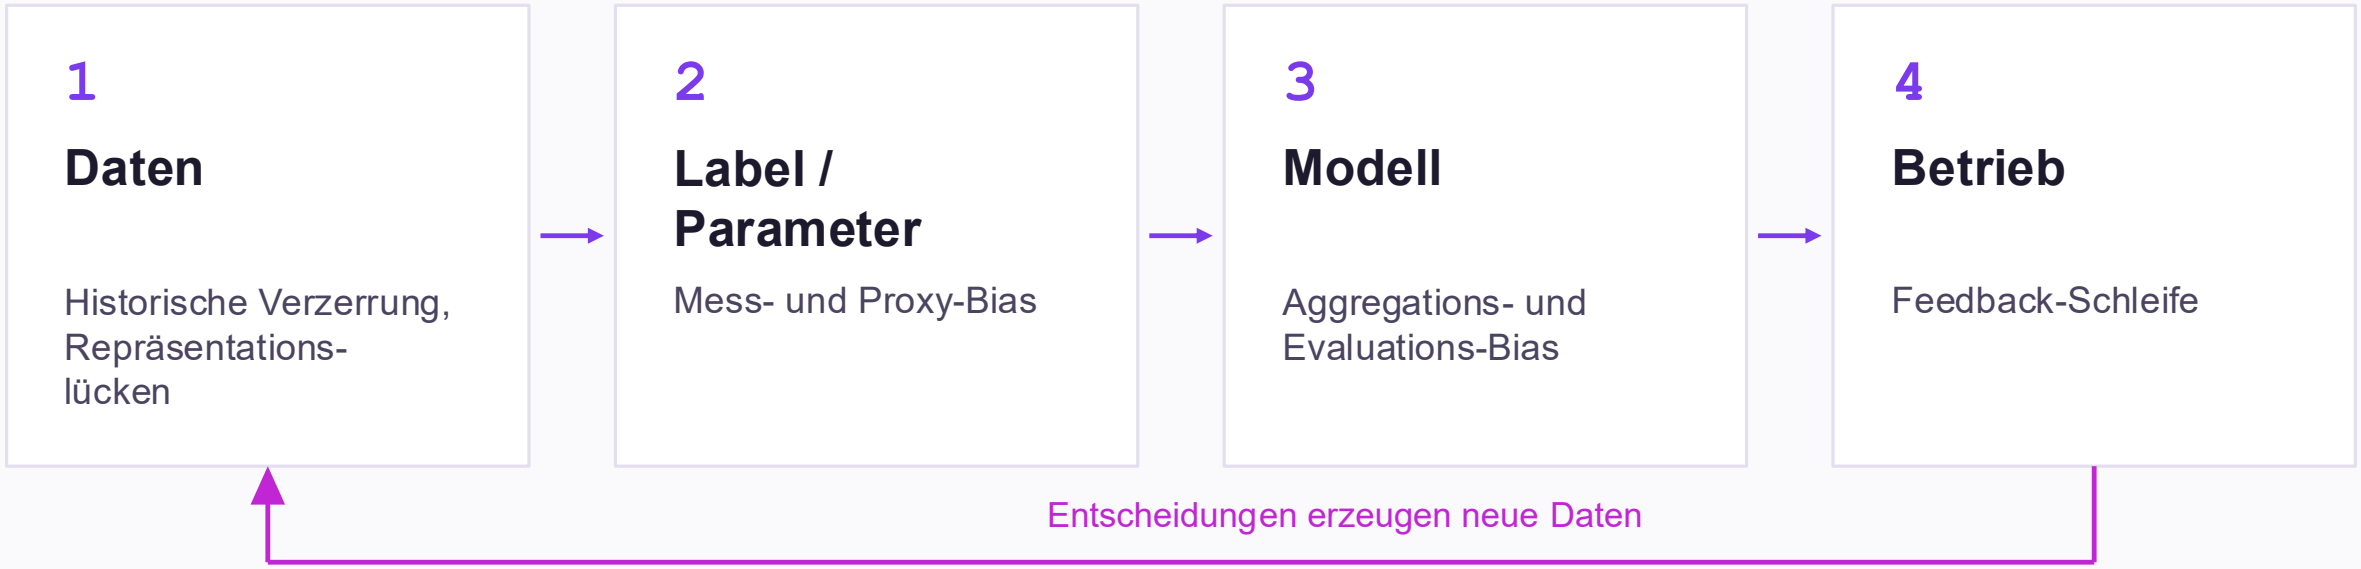
→

SOZIAL // NORMATIV

Ungerechtfertigte Ungleichbehandlung

Diese Gruppe wird seltener eingeladen.

Bias entlang des ML-Lebenszyklus



ZWECK

Erst die Ebene finden, dann gegensteuern.

Quelle: Mehrabi et al. (2021)

BLOCK A

Ebene 1: Daten



HISTORISCHE VERZERRUNG

Korrekt erhobene Daten bilden eine ungerechte frühere Praxis ab.

BEISPIEL

Gelernt wird aus früheren Einstellungen. Wer selten eingestellt wurde, gilt als ungeeignet.

PRÜFFRAGE

Welche Praxis hat diese Daten erzeugt?

Lösung: frühere Einstellungen durch Menschen; diese Praxis lernt das Modell mit.

Ebene 2: Label / Parameter



MESS-BIAS

Eignung ist nicht direkt messbar. Gelernt wird eine Hilfsgröße aus früheren Entscheidungen, bei LLMs über Präferenzdaten in den Parametern.

BEISPIEL

Gelernt wird „wurde eingeladen“ oder „blieb zwei Jahre“.

PRÜFFRAGE

Wie weit ist die Messgröße vom Konstrukt entfernt?

Lösung: weit; „eingeladen“ misst die frühere Auswahl, die Eignung bleibt ungemessen.

BLOCK A

Ebene 3: Modell



AGGREGATIONS-BIAS

Ein gemeinsames Modell optimiert vor allem für die Mehrheit.

BEISPIEL

Hohe Gesamtgenauigkeit, schwache Werte für eine kleine Bewerbergruppe.

PRÜFFRAGE

Wie gut ist das Modell in jeder Gruppe einzeln?

Lösung: Genauigkeit und Fehlerraten je Gruppe ausweisen, nie nur gesamt.

BLOCK A

Ebene 4: Betrieb



FEEDBACK-SCHLEIFE

Die Entscheidungen von heute werden die Trainingsdaten von morgen.

BEISPIEL

Wer eingeladen wird, erzeugt Erfolgsdaten.
Wer aussortiert wird, erzeugt keine.

PRÜFFRAGE

Welche Daten entstehen erst durch unsere Entscheidungen?

Lösung: Erfolgsdaten gibt es nur für Eingeladene; Aussortierte bleiben unsichtbar.

BLOCK B // 18 MIN

Fairness messen

Notation, drei Metriken, ein Referenzfall.

Notation an einem Beispiel

BEISPIEL

Je 100 Bewerbungen aus zwei Altersgruppen a und b. Das Modell lädt ein oder nicht. Später zeigt sich die Eignung.

Auswahlrate: wen das Modell einlädt, in a 40 von 100.
Basisrate: wer tatsächlich geeignet ist, in a 50 von 100.

BEDEUTUNG // BAROCAS ET AL. (2023)

$\hat{Y}$	vorhergesagte Entscheidung oder Klassifikation, z. B. „positiv“, „ausgewählt“, „zugelassen“; hier: eingeladen = 1
A	sensibles oder Gruppenmerkmal, z. B. Geschlecht, Ethnie oder Altersgruppe
a, b	konkrete Ausprägung dieses Merkmals
Y	tatsächliches Ergebnis; hier: geeignet = 1

$P(\hat{Y}=1 \mid A=a)$	**Auswahlrate** der Gruppe a
$P(Y=1 \mid A=a)$	**Basisrate** der Gruppe a

BLOCK B

Demografische Parität

INDEPENDENCE

DEFINITION

Gleiche Auswahlrate: P(Ŷ=1 | A=a) ist für alle a gleich.

BEISPIEL

Merkmal: Altersgruppe, a und b
Metrik: Verhältnis der Auswahlraten
a: 40 von 100 eingeladen
b: 28 von 100 eingeladen
Verhältnis: 0,28 / 0,40 = 0,70

verletzt

GRENZE

Die Metrik zählt nur, wie viele eingeladen werden, nicht wer. Auch eine Zufallsauswahl mit gleicher Quote erfüllt sie.

Fehlerraten an einem Beispiel

BEISPIEL // GRUPPE a

	eingeladen	aussortiert
geeignet	**35**	**15**
ungeeignet	**5**	**45**

ABLEITUNG

TPR **35/50 = 0,70** eingeladene Geeignete

FNR **15/50 = 0,30** aussortierte Geeignete

FPR **5/50 = 0,10** eingeladene Ungeeignete

PPV **35/40 = 0,88** Geeignete unter Eingeladenen

TPR True Positive Rate, Richtig-Positiv-Rate · **FNR** False Negative Rate, Falsch-Negativ-Rate
FPR False Positive Rate, Falsch-Positiv-Rate · **PPV** Positive Predictive Value, positiver Vorhersagewert

Angeglichene Chancen (Equalized Odds)

SEPARATION

DEFINITION

Gleiche Behandlung bei gleicher Eignung:
TPR und FPR sind für alle Gruppen gleich.

BEISPIEL

	TPR	FPR
a	35/50 = 0,70	5/50 = 0,10
b	21/30 = 0,70	7/70 = 0,10

erfüllt

GRENZE

„Geeignet“ muss stimmen. Stammt das Label aus alten Einstellungsentscheidungen, misst die Metrik gegen einen verzerrten Maßstab.

Kalibrierung über Gruppen

SUFFICIENCY

DEFINITION

P(Y=1 | Ŷ, A=a) ist für alle a gleich: Eine Einladung bedeutet überall dasselbe.

BEISPIEL

	UNGEEIGNETE × FPR	PPV
a	50 × 0,10 = 5	35/(35+5) = 0,88
b	70 × 0,10 = 7	21/(21+7) = 0,75

verletzt

MERKSATZ

Gleiche Fehlerraten und ungleiche Basisraten ergeben ungleichen PPV.

GRENZE

Sagt nichts über die Verteilung der Fehler.

Weglassen geschützter Merkmale schützt nicht

FAIRNESS DURCH UNKENNTNIS

Das Modell erhält das geschützte Merkmal A nicht, zum Beispiel das Alter.

FOLGE 1

Proxys rekonstruieren A

Der Abschlussjahrgang verrät das Alter.

FOLGE 2

Messung unmöglich

Ohne A gibt es keine Auswahlrate je Gruppe.

Messen braucht geschützte Merkmale

BEISPIEL

Wer Auswahlraten nach Herkunft prüft, braucht die Herkunft.

Ausweg: Messen und Entscheiden trennen.

RECHTSLAGE

Art. 9 DSGVO

Besondere Kategorie: Verarbeitung grundsätzlich untersagt

Art. 4a KI-VO

Seit 27.07.2026: zur Bias-Erkennung erlaubt, wenn unbedingt erforderlich und pseudonymisiert

GEPRÜFT 23.10.2026

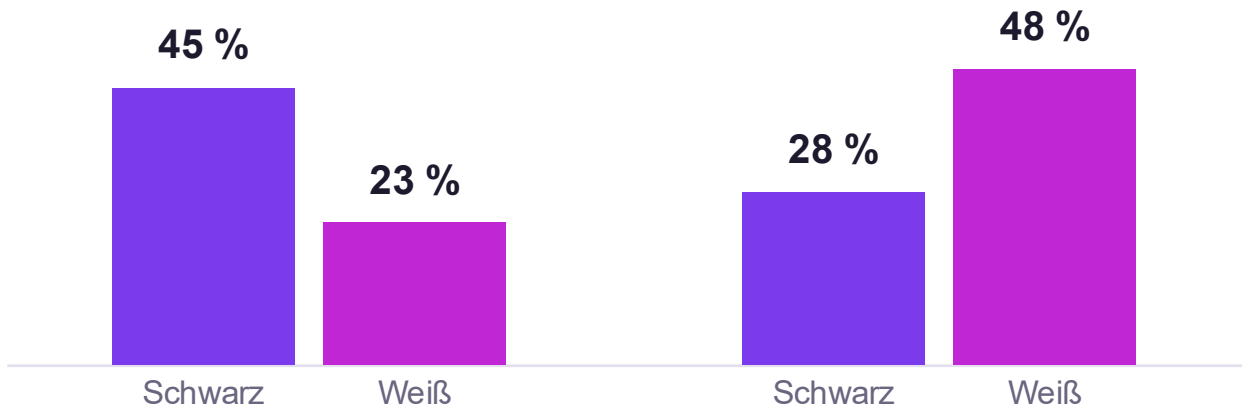
COMPAS: Score und Fehlerraten

FALL

COMPAS sagt vorher, ob Angeklagte binnen zwei Jahren erneut festgenommen werden. Broward County, Florida, entschied damit vor dem Prozess über Haft oder Freilassung. ProPublica prüfte 7.214 Prognosen.

$\hat{Y}$ = 1: mittleres oder hohes Risiko
Y = 1: rückfällig

FEHLERRATEN NACH GRUPPE, IN %



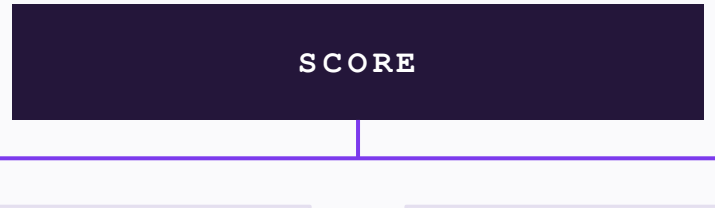
LESART

Schwarze ohne Rückfall galten fast doppelt so oft als riskant. Weiße mit Rückfall galten häufiger als niedriges Risiko.

Quelle: Larson et al., ProPublica (23.05.2016), Werte gerundet

COMPAS = Rückfallprognosealgorithmus

Der COMPAS-Streit: Separation gegen Sufficiency



LESART 1 // PROPUBLICA

Gleiche Fehlerraten?

FPR 45 % gegenüber 23 %

Anspruch verletzt

LESART 2 // NORTHPOINTE

Gleicher Vorhersagewert?

PPV je Gruppe ähnlich

Anspruch erfüllt

HANDZEICHEN

Welcher Anspruch wiegt für Sie schwerer?

Quelle: Larson et al. (2016); Chouldechova (2017)

BLOCK C // 14 MIN

Grenzen der Messung

Unmöglichkeit, Forschung, Recht.

Unvereinbare Ansprüche bei ungleichen Basisraten

UNGLEICHE BASISRATEN

ANSPRUCH 1

Kalibrierung

Im Beispiel: In b nur 3 Ungeeignete einladen, damit der PPV wie in a 0,88 beträgt.

Dann: FPR 0,04 gegenüber 0,10

ANSPRUCH 2

Gleiche Fehlerraten

Im Beispiel: TPR 0,70 und FPR 0,10 in a und b.

Dann: PPV 0,88 gegenüber 0,75

AUSNAHMEN

Perfekte Vorhersage oder gleiche Basisraten.

Quelle: Kleinberg et al. (2016); Chouldechova (2017)

BLOCK C

Was ungleiche Basisraten bewirken

BEISPIEL

	a	b
Basisrate	0,50	0,30
TPR	0,70	0,70
FPR	0,10	0,10
PPV	**0,88**	**0,75**

WARUM

1. **Mehr Ungeeignete in b**
   70 gegenüber 50
2. **Gleiche FPR 0,10**
   7 gegenüber 5 eingeladen
3. **Niedrigerer PPV in b**
   0,75 gegenüber 0,88

VORSICHT

Ungleiche Basisraten sind oft selbst Folge früherer Ungleichbehandlung.

Quelle: Chouldechova (2017); eigene Rechnung

BLOCK C

Metrikwahl ist eine Wertentscheidung

FALSCH-NEGATIV

Geeignete Person aussortiert

Beispiel: Die Person verliert die Chance und erfährt nicht, warum.
Wiegt das schwerer: gleiche TPR fordern.

FALSCH-POSITIV

Ungeeignete Person eingeladen

Beispiel: ein Gespräch ohne Passung, Aufwand auf beiden Seiten.
Wiegt das schwerer: gleiche FPR fordern.

PAARFRAGE // 2 MIN

Wen trifft welcher Fehler, und was ist schwerer umkehrbar?

Eigene Einschätzung: Metrik festlegen, bevor gemessen wird.

BLOCK C

Mitigation im Überblick

DEFINITION // HORT ET AL. (2023)

Bias-Mitigation: Eingriffe, die eine gemessene Verzerrung verringern, vor, im oder nach dem Training.

PRE-PROCESSING

Daten

Umgewichten, bis Gruppe und Eignung in den Trainingsdaten unabhängig sind.

IN-PROCESSING

Training

Eine Fairness-Bedingung mitoptimieren, etwa gleiche TPR.

POST-PROCESSING

Ausgabe

Schwelle je Gruppe setzen, bis die TPR gleich ist.

Die Wahl folgt dem Zugriff auf Daten, Training oder Ausgabe.

BLOCK C

Forschungsstand zur Messung

CHEN ET AL. 2023

Mitigation wirkt ungleich

Abhängig von Aufgabe, Modell und Metrik.

begutachtet

CHEN, ZAHARIA & ZOU 2024

Modelle ändern sich

Im Juni 2023 andere Antworten als im März.

begutachtet

SESHADRI ET AL. 2022

Messwerte schwanken

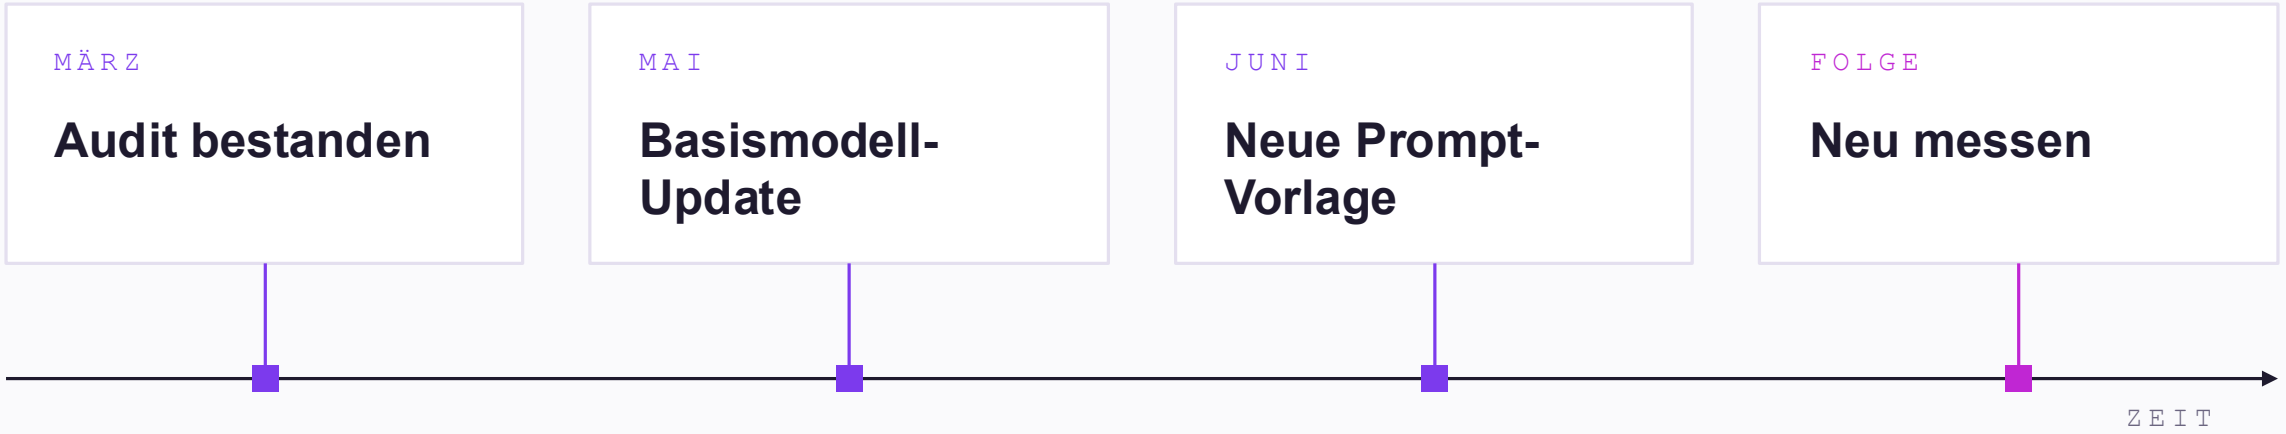
Umformulierte Vorlagen ergeben andere Bias-Werte.

Preprint

BLOCK C // FOLGERUNG

Audits gelten für den geprüften Stand

BEISPIEL // KONSTRUIERT



EIGENE EINSCHÄTZUNG

Jede Modell- oder Vorlagenänderung ist ein Anlass, mit demselben Code neu zu messen.

Rechtsrahmen für Bewerbungs-Screening

BEISPIEL

Ein Online-Händler setzt eingekaufte Software ein, die Bewerbungen vorsortiert.

→

RECHTSLAGE // GEPRÜFT 23.10.2026

Anhang III	Nr. 4 KI-VO: Beschäftigung, also Hochrisiko
02.12.2027	Hochrisiko-Pflichten gelten (VO (EU) 2026/1744)
Art. 10	Anbieter prüft Trainingsdaten auf Verzerrungen
Colorado ⚠	SB 26-189 ab 01.01.2027 (Kanzleiquellen)

Belegstatus dieser Einheit

Primärquelle geprüft	COMPAS-Zahlen, Unmöglichkeit, EU-Fristen, Art. 4a KI-VO
Begutachtet	Monokultur-Studie (US-Daten), Forschungsstand
Preprint	Vorlagen-Studie: vorläufige Effektstärken
Illustration	Vignette, Rechenbeispiel, Formularfelder
Eigene Einschätzung	auf der Folie markiert

ZWECK

Muster für Kapitel 2: Belegstatus an jeder Aussage.

DISKUSSION // THINK-PAIR-SHARE // 12 MIN

„Ein Screening-System darf nur laufen, solange seine Fairness laufend gemessen wird.“

PRO

Ohne laufende Messung ist jede Fairness-Aussage unbelegt.

EINWAND

Dafür müssten Herkunft und Alter aller Bewerbenden dauerhaft gespeichert werden. Ein Datenleck träfe genau diese Daten.

ABSCHLUSS // 10 BEGRIFFE

Begriffe der Woche

Bias — bias

Systematische, ungerechtfertigte Ungleichbehandlung von Gruppen.

Proxy-Merkmal — proxy variable

Merkmal, das ein geschütztes Attribut mitträgt.

Historische Verzerrung — historical bias

Korrekte Daten, die eine ungerechte Praxis abbilden.

Feedback-Schleife — feedback loop

Modellentscheidungen erzeugen die Trainingsdaten von morgen.

Demografische Parität — demographic parity

Gleiche Auswahlrate in allen Gruppen.

Angeglichene Chancen — equalized odds

Gleiche TPR und FPR in allen Gruppen.

Kalibrierung über Gruppen — calibration

Ein Score bedeutet in jeder Gruppe dasselbe.

Unmöglichkeitsresultat — impossibility theorem

Bei ungleichen Basisraten nicht zugleich: Kalibrierung und gleiche Fehlerraten.

Verarbeitungsparadox — processing paradox

Fairness messen verlangt geschützte Daten.

Bias-Mitigation — bias mitigation

Eingriffe vor, im oder nach dem Training.

ABSCHLUSS

Fachgespräch: mögliche W04-Fragen

FRAGE 1

Auf welcher Ebene liegt der Bias Ihres Systems?

FRAGE 2

Welche Metrik wählen Sie, und welchen Fehler akzeptieren Sie?

FRAGE 3

Wann sind Kalibrierung und gleiche Fehlerraten zugleich erfüllbar?

FRAGE 4

Wann muss ein Fairness-Audit wiederholt werden?

ZUSAMMENFASSUNG

Takeaways

ANTWORT AUF DIE LEITFRAGE

Wir wählen die Metrik, deren Fehler wir begründet in Kauf nehmen.

EBENEN

Bias hat Ursachen im System

Erst die Ebene finden, dann mitigieren.

METRIKEN

Metriken stehen für Werte

Bei ungleichen Basisraten muss man wählen.

NEXT // W05

Transparenz und Erklärbarkeit

Lektüre: Molnar, SHAP und Counterfactuals. Vertiefung im Anhang.

FREIWILLIGE VERTIEFUNG

Fairness in der Tiefe

Freiwillig · Selbststudium · nicht prüfungsrelevant

Wozu diese Vertiefung taugt

FREIWILLIGE VERTIEFUNG // LESEHINWEIS

- Für Kapitel 2 der Semesterarbeit: zitierfähige Grundlagen in Steckbriefen.
- Für die Methode: die Unmöglichkeit, nachgerechnet am Beispiel aus Block B.
- Für die Quellenkritik: Preprints der Jahre 2025 und 2026 mit ihrem Status.

HINWEIS

Nicht prüfungsrelevant

Prüfungsrelevant ist der Kern bis zu den Takeaways. Die Vertiefung hilft beim Verstehen und beim Zitieren.

Steckbrief: Mehrabi et al. (2021)

FREIWILLIGE VERTIEFUNG // SURVEY

Steckbrief

A Survey on Bias and Fairness in Machine Learning: Standard-Survey zu Bias-Quellen und Fairness-Definitionen.

- Ordnet Bias-Arten entlang der Schleife aus Daten, Algorithmus und Nutzenden.
- Kapitel 3 und 4 helfen, den eigenen Fall einer Ebene zuzuordnen.
- Stand 2021: Befunde zu Sprachmodellen und Lieferketten fehlen.

REFERENZ

ACM Computing Surveys 54(6)

Mehrabi, Morstatter, Saxena, Lerman & Galstyan (2021). Die Bias-Arten müssen nicht auswendig gelernt werden; die vier Ebenen der Vorlesung genügen.

Güte: begutachtet

Zugang: frei, arXiv 1908.09635

Steckbrief: Barocas, Hardt & Narayanan (2023)

FREIWILLIGE VERTIEFUNG // LEHRBUCH

Steckbrief

Fairness and Machine Learning. Limitations and Opportunities: Referenz-Lehrbuch des Feldes, frei unter fairmlbook.org.

- Leitet Independence, Separation und Sufficiency formal her.
- Kapitel Classification zuerst lesen: Notation und Grenzen jeder Metrik.
- Erste Anlaufstelle für Definitionen in Kapitel 2 der Semesterarbeit.

REFERENZ

MIT Press 2023

Die Notation der Vorlesung (A, $\hat{Y}$, Y) folgt diesem Buch. Wer eine Metrik in der Arbeit definiert, zitiert sie von hier.

Güte: Lehrbuch (MIT Press)

Zugang: frei

Steckbrief: Kleinberg et al. (2016)

FREIWILLIGE VERTIEFUNG // UNMÖGLICHKEIT

Steckbrief

Inherent Trade-Offs in the Fair Determination of Risk Scores: formales Unmöglichkeitsresultat, unabhängig vom Verfahren.

- Bedingung 1: Der Score ist in jeder Gruppe kalibriert.
- Bedingungen 2 und 3: Die mittleren Scores der tatsächlich Positiven und Negativen sind über die Gruppen gleich.
- Alle drei gelten nur bei perfekter Vorhersage oder gleichen Basisraten.

REFERENZ

Kleinberg, Mullainathan & Raghavan

arXiv 1609.05807 (2016); Konferenzfassung ITCS 2017. Die zitierfähige Autorität für die Aussage, dass die Metrikwahl eine Wertentscheidung ist.

Güte: begutachtet (ITCS 2017)

Zugang: frei

Steckbrief: Chouldechova (2017)

FREIWILLIGE VERTIEFUNG // UNMÖGLICHKEIT

Steckbrief

Fair Prediction with Disparate Impact: zweites Unmöglichkeitsresultat, hergeleitet am COMPAS-Fall.

- Bei ungleicher Prävalenz schließt gleicher PPV gleiche FPR und FNR aus.
- Werkzeug: eine Identität aus der Konfusionsmatrix (nächste Folie).
- Ungleiche Wirkung entsteht hier als Folge ungleicher Basisraten.

REFERENZ

Big Data 5(2), 153–163

Chouldechova, A. (2017). Für viele der bessere Einstieg als Kleinberg et al., weil konkret und rechnerisch.

Güte: begutachtet

Zugang: frei, arXiv 1610.07524

FREIWILLIGE VERTIEFUNG // HERLEITUNG

Die Identität hinter dem Befund

IDENTITÄT // CHOULDECHOVA (2017)

$$FPR = p/(1-p) \cdot (1-PPV)/PPV \cdot (1-FNR),\ p = \text{Basisrate}$$

GRUPPE a // p = 0,50

$1 \cdot 0{,}14 \cdot 0{,}70 = \mathbf{0{,}10}$

GRUPPE b // p = 0,30

$0{,}43 \cdot 0{,}33 \cdot 0{,}70 = \mathbf{0{,}10}$

Gleiche FPR und FNR bei ungleichem p: Der PPV muss sich unterscheiden (0,88 gegenüber 0,75).

Steckbriefe: Hort et al. und Chen et al. (2023)

FREIWILLIGE VERTIEFUNG // MITIGATION

ÜBERSICHT // BEGUTACHTET

Hort et al. (2023)

Gegenstand

Verfahren aus 341 Publikationen, geordnet nach Pre-, In- und Post-Processing.

Nutzen

Feinere Systematik als die Drei-Punkte-Ordnung der Vorlesung.

Quelle

ACM Journal on Responsible Computing; arXiv 2207.07068

EMPIRIE // BEGUTACHTET

Chen et al. (2023)

Gegenstand

Vergleich vieler Mitigationsverfahren über Aufgaben, Modelle und Metriken.

Befund

In 53 % der Szenarien sank die Modellgüte deutlich; kein Verfahren war überall am besten.

Quelle

ACM TOSEM; arXiv 2207.03277

Individual- und Kausalfairness

FREIWILLIGE VERTIEFUNG // JENSEITS DER GRUPPE

Zwei Perspektiven

Individualfairness: Ähnliche Personen werden ähnlich behandelt.
Kausalfairness: Über welchen Pfad wirkt ein Merkmal, und ist dieser Pfad legitim?

- Individualfairness braucht ein Ähnlichkeitsmaß, und das ist selbst wertbeladen.
- Gruppenparität kann zwei ähnliche Personen unterschiedlich behandeln.
- Kausalfairness braucht ein Kausalmodell, das selten vollständig vorliegt.

BEISPIEL

Ein Pfad, zwei Bewertungen

Alter wirkt über Berufserfahrung auf die Eignung: Dieser Pfad kann legitim sein. Alter wirkt über den Abschlussjahrgang als Ausschlusskriterium: Dieser Pfad ist es nicht.

Quelle: Barocas et al. (2023), Kap. Causality

Preprint: Lieferketten im KI-Recruiting

FREIWILLIGE VERTIEFUNG // PREPRINT 2026

Steckbrief

Sharma & Molamohammadi: Verantwortung verteilt sich auf Datenanbieter, Modellentwicklung, Plattformen und einsetzende Organisationen.

- Bias entsteht oft erst im Zusammenspiel der Komponenten.
- Informationslücken verhindern eine Gesamtprüfung.
- Vorschlag: Audits auf Systemebene und Dokumentation über die ganze Kette.

PREPRINT // NICHT BEGUTACHTET

arXiv 2604.22679

Schließt an die Monokultur aus dem Einstieg und die Rollenfrage aus W03 an. Als Hinweis lesen, nicht als gesichertes Ergebnis.

Status: Preprint

Stand: 24.04.2026

Preprint: Unsicherheit als Eingriff

FREIWILLIGE VERTIEFUNG // PREPRINT

Steckbrief

Sargeant et al. untersuchen zwei Eingriffe: unsichere Vorhersagen zurückhalten oder mit Warnhinweis zeigen.

- Beide Eingriffe bergen nach britischem Recht ein Diskriminierungsrisiko, wenn Gruppen ungleich unsichere Vorhersagen erhalten.
- Das Zeigen mit Warnhinweis bewerten die Autor*innen als rechtlich vorzugswürdig.
- Fallstudien: Verbraucherkredit und Rückfallprognose.

PREPRINT // NICHT BEGUTACHTET

arXiv 2508.07872

Sargeant, Jorgensen, Shah, Goring, Weller & Bhatt. Präzisiert gegenüber dem Altmaterial: Das Paper untersucht, wie unsicherheitsbasierte Eingriffe selbst diskriminieren können.

Status: Preprint

Stand: v2 vom 07.07.2026

Preprint: Sprache als Filter in LLM-Bewertungen

FREIWILLIGE VERTIEFUNG // PREPRINT

Steckbrief

Rao et al. lassen große Sprachmodelle je 100 britische und indische Interviewtranskripte bewerten.

- Indische Transkripte erhielten auch anonymisiert niedrigere Werte für die Einstellbarkeit.
- Der Abstand hing mit Satzbau und Wortschatz zusammen; ein Tausch der Namen hatte keinen signifikanten Effekt.
- Eigene Einordnung: Solche Effekte zeigt nur systematisches Testen mit variierten Eingaben.

PREPRINT // NICHT BEGUTACHTET

arXiv 2508.16673

Rao, Nagarajan Venkatesan, Cherubini & Jayagopi. Ergänzt die Proxy-Mechanik um die sprachliche Ebene.

Status: Preprint

Stand: 21.08.2025

Preprints richtig zitieren

FREIWILLIGE VERTIEFUNG // QUELLENKRITIK

Drei Regeln

Ein **Preprint** ist eine Vorabfassung ohne Begutachtung. Er zeigt ein Phänomen an; Effektstärken bleiben vorläufig.

- Status im Fließtext nennen: „Preprint, nicht begutachtet“.
- Als Hinweis zitieren, nicht als Beleg für eine Zahl.
- Vor der Abgabe prüfen, ob eine begutachtete Fassung erschienen ist.

BEISPIEL

So im Text

„Jeong, Ma und Houmansadr vergleichen Bias über 30 Sprachmodelle (arXiv 2410.12010, v4 2025, Preprint, nicht begutachtet).“

Bezug: Rubric, Kriterium K5

Recht im Detail: Art. 4a KI-VO und Colorado

FREIWILLIGE VERTIEFUNG // RECHT

EU // EUR-LEX GEPRÜFT 23.10.2026

Art. 4a KI-VO

Wer

Abs. 1: Anbieter von Hochrisiko-Systemen; Abs. 2 erstreckt das auf weitere Fälle ⚠ (Wortlaut nur teilweise geprüft).

Wann

Nur wenn andere, auch synthetische oder anonymisierte Daten nicht reichen.

Wie

Pseudonymisierung, strenge Zugriffskontrolle, keine Weitergabe, Löschung nach der Korrektur.

Neu

Ersetzt Art. 10 Abs. 5; eingefügt durch VO (EU) 2026/1744, in Kraft seit 27.07.2026.

USA // ⚠ KANZLEIQUELLEN

Colorado SB 26-189

Status

Unterzeichnet am 14.05.2026 (Governor of Colorado), ersetzt SB 24-205.

Geltung

Ab 01.01.2027, nur aus Kanzleiquellen ⚠.

Pflichten

Hinweis vor Einsatz, Erläuterung nach Ablehnung, menschliche Überprüfung ⚠.

Quellen

Holland & Knight, Seyfarth; geprüft am 23.10.2026.

FREIWILLIGE VERTIEFUNG // WEITERARBEIT

Selbststudium: Wege und Ressourcen

LESEN

Grundlagen

Mehrabi et al. Kap. 3–4, fairmlbook Kap. Classification, Chouldechova (2017).

RECHNEN

Lab variieren

Das fairlearn-Lab mit anderem Seed und einem zweiten Verfahren wiederholen.

ANWENDEN

Kapitel 2

Skizzieren: Metrik wählen, begründen, Grenzen nennen.

DISKUTIEREN

Rollentausch

Den COMPAS-Streit im Team mit vertauschten Rollen nachstellen.