W04 // ÜBUNG // 28.10.2026 // ARBEITSBLATT IM BROWSER

Fairness am eigenen Thema

Ausgefüllte Ergebnisfassung · G10 · T01 Kreditwürdigkeitsprüfung · synthetische Daten · Trainingseingriff μ=30

Gruppe: G10

Thema: T01 Kreditwürdigkeitsprüfung

TEIL A // PHASE 1 // 25 MIN

Aufgabenkarte 1: Metrik und Baseline festlegen
Ziel: Messgröße und Ausgangslage festlegen.

1. Beschreiben Sie Entscheidung $\hat{Y}$ und Merkmal A.
2. Analysieren Sie die Bias-Quelle: Daten, Label, Modell oder Betrieb.
3. Bewerten Sie, welche Metrik zum Schaden passt.
4. Entwerfen Sie den Eingriff: Daten, Training oder nach dem Training.
5. Nennen Sie die Baseline: Basisrate je Gruppe, Proxy, Fallzahl.

Ergebnis: Teil A ausgefüllt · **Zeit:** 25 Minuten · **Abgabe:** mit der Ergebnisdatei am Ende

1 Entscheidung und Merkmal (VL 18)

$\hat{Y}$ = 1 bedeutet: Der beantragte Kredit wird bewilligt.

Merkmal A (VL 23, 24): Altersgruppe

Gruppe a ist: 35–64 Jahre

Gruppe b ist: 18–34 Jahre

2 Bias-Quelle (VL 11, 12)

Ebene (VL 13, 14, 15, 16): Daten

In einem Satz: woher der Bias kommt: Wenn rückzahlungsfähige 18–34-Jährige in historisch selektierten Kreditdaten unterrepräsentiert sind, kann das Modell über die Kredithistorie als Altersproxy ihre Rückzahlungsfähigkeit systematisch unterschätzen.

3 Zielmetrik (VL 19, 21, 22)

Zielmetrik: Equalized Odds (gleiche TPR und FPR)

Begründung: Wer trägt welchen Fehler? (VL 20, 30): Rückzahlungsfähige 18–34-Jährige sollen nicht häufiger zu Unrecht abgelehnt werden als rückzahlungsfähige 35–64-Jährige (gleiche TPR/FNR). Zugleich sollen Fehlbewilligungen nicht einseitig eine Altersgruppe treffen (gleiche FPR), da sie Ausfallrisiken für die Bank und mögliche Überschuldung für Kreditnehmende bedeuten.

4 Eingriff (VL 31, 47)

Eingriff

Training (Fairness-Bedingung)

Begründung über den Zugriff

Im Laborszenario haben wir Zugriff auf Trainingsdaten, Altersgruppen und das Modelltraining. Daher ergänzen wir das Training um eine Fairness-Bedingung mit dem Ziel Equalized Odds. Die Altersgruppe dient der Fairness-Optimierung und Auswertung, nicht als direktes Modellmerkmal; für beide Gruppen bleibt die Entscheidungsschwelle gleich.

5 Baseline

Annahmen, keine Recherche. Sie steuern die Daten in Teil B.

Basisrate Gruppe a (Anteil tatsächlich Geeigneter) (VL 18, 29)

0.85

Basisrate Gruppe b

0.65

Proxy: Merkmal, das die Gruppe verrät (VL 6, 7, 23)

Index kurzer Kredithistorie

Proxy-Stärke (0 verrät nichts, 1 verrät die Gruppe fast sicher)

0.8

Fallzahl

5.000

Anteil der Gruppe b

0.4

Label-Bias: Anteil Geeigneter in b, in den Altdaten als ungeeignet erfasst (VL 14, 21)

0

Zufallswert (Seed)

42

Fachmerkmal 1 (hängt mit der Eignung zusammen)

Haushaltsüberschuss

Fachmerkmal 2

Zahlungszuverlässigkeit

TEIL B // PHASE 2 // 35 MIN

Aufgabenkarte 2: Erzeugen, messen, mitigieren
Ziel: Ungleichbehandlung zeigen, gezielt verringern, Preis beziffern.

1. Nennen Sie Ihre Baseline in Teil A, erzeugen Sie die Daten.
2. Analysieren Sie Auswahlrate, TPR und FPR je Gruppe.
3. Analysieren Sie Ihren Eingriff aus Teil A.
4. Bewerten Sie den Preis: Genauigkeit und zweite Metrik, vorher und nachher.

Ergebnis: Teil B ausgefüllt, Zeile in der Vergleichsmatrix · **Zeit:** 35 Minuten · **Abgabe:** Ergebnisdatei ins OPAL

1 Daten erzeugen

5.000 Fälle erzeugt, davon 2019 in Gruppe b. Anteil Geeigneter in den Altdaten: a 0,85, b 0,65. Training: 3500 Fälle, Messung: 1500 Fälle.

2 Basismodell messen (VL 15, 19, 20, 21)

GRUPPE	FÄLLE	BASISRATE	AUSWAHLRATE	TPR	FPR
a (35–64 Jahre)	900	0,85	0,92	0,97	0,60
b (18–34 Jahre)	600	0,65	0,73	0,91	0,41

0,850	0,183	0,800	0,184
Genauigkeit	Differenz Parität	Verhältnis Auswahlraten	Differenz Chancen

3 Eingriff (VL 31)

Ihr Eingriff aus Teil A: Training (Fairness-Bedingung) · Zielmetrik: Equalized Odds. Ändern Sie beides in Teil A, Schritte 3 und 4.

Stärke der Fairness-Bedingung im Training

30

Training mit Fairness-Bedingung, Stärke 30.

GRUPPE	FÄLLE	BASISRATE	AUSWAHLRATE	TPR	FPR
a (35–64 Jahre)	900	0,85	0,90	0,96	0,57
b (18–34 Jahre)	600	0,65	0,81	0,95	0,54

	GENAUIGKEIT	DIFFERENZ PARITÄT	VERHÄLTNIS	DIFFERENZ CHANCEN
Basismodell	0,850	0,183	0,800	0,184
Nach Eingriff	0,840	0,096	0,893	0,030

4 Preis bewerten (VL 28, 30)

Preis in einem Satz

Mit dem Trainingseingriff (μ=30) sinkt die Differenz Chancen von 0,1842 auf 0,0301 und die Differenz Parität von 0,1833 auf 0,0961; die Genauigkeit fällt von 85,00 % auf 84,00 % (15 zusätzliche Fehler), während bei jüngeren Personen die falschen Ablehnungen von 37 auf 20 sinken und die Fehlbewilligungen von 87 auf 113 steigen.

Grenze der Messung (VL 32, 33)

Synthetisches Szenario mit Basisraten 0,85 und 0,65, Seed 42 und nur einem Split; die historische Selektionslücke wird nicht nachgebildet. Die FPR beruht auf 132 nicht rückzahlungsfähigen Personen in a und 210 in b. Nach dem Eingriff bleiben die FPR mit 56,82 % und 53,81 % hoch. Die wahre Eignung entspricht bei Label-Bias 0 den Altdatenlabels. μ=30 wurde beibehalten, aber nicht unabhängig validiert. Die kleineren Gruppenabstände allein rechtfertigen keinen realen Einsatz.

ABGABE

Zeile für die Vergleichsmatrix:

```
G10 · T01 · Equalized Odds · Training · Differenz Chancen 0,18 → 0,03 · Genauigkeit 0,85 → 0,84
```

Ins OPAL: Ergebnisdatei und Datensatz (CSV). W05 arbeitet mit dem Datensatz weiter.

WAS IM HINTERGRUND PASSIERT

- **Daten:** je Fall Gruppe, wahre Eignung nach Basisrate, zwei Fachmerkmale, ein Proxy. Label-Bias erfasst Geeignete in b als ungeeignet.
- **Basismodell:** logistische Regression auf 70 Prozent der Fälle, ohne A; gemessen auf den übrigen 30 Prozent. (VL 23)
- **Daten-Eingriff:** entfernt den linearen Zusammenhang der Merkmale mit A, wie `CorrelationRemover` in fairlearn. (VL 31)
- **Training:** logistische Regression mit Strafterm für ungleiche mittlere Scores; Ziel wie `ExponentiatedGradient`, anderes Verfahren.
- **Nach dem Training:** eigene Schwelle für Gruppe b, gewählt auf den Trainingsdaten; Ziel wie `ThresholdOptimizer`, aber ohne Zufallsanteil.
- **Kennzahlen:** Differenz Parität = Abstand der Auswahlraten; Verhältnis = kleinere durch größere Rate; Differenz Chancen = größerer Abstand von TPR oder FPR, wie `equalized_odds_difference`. (VL 19, 21)

G10 · Ergebnisfassung W04 · Statische Momentaufnahme der ausgeführten Simulation. Daten synthetisch; ursprüngliches Arbeitsblatt: Fassung 27.10.2026.