Transparenz & Erklärbarkeit

Leitfrage: Welche Erklärung schulden wir einer Person, die ein Modell abgelehnt hat, und wann trägt sie? · 04.11.2026

Retrieval: Stoff aus W04

RETRIEVAL // 5 MIN

Q1 Was ist ein Proxy-Merkmal? Ein Beispiel aus dem Bewerbungsformular?

Q2 Was verlangt demografische Parität, was verlangen angeglichene Chancen?

Q3 Wann sind Kalibrierung und gleiche Fehlerraten nicht zugleich erfüllbar?

EINSTIEG // THESE // 3 MIN

„Wer von einem Modell abgelehnt wird, muss erfahren können, warum.“

DAFÜR

Nur wer den Grund kennt, kann widersprechen oder etwas ändern.

DAGEGEN

Begründungen können Geschäftsgeheimnisse offenlegen und Umgehung erleichtern.

Bewerbung 17: eine Absage und drei Fragen

ANGABEN

FACHTEST

74 Punkte

ERFAHRUNG

3 Jahre

LÜCKE

14 Monate

→

SCREENING-MODELL

p = 0,19

EINLADUNG AB

p = 0,50

ERGEBNIS

Absage

→

DIE PERSON FRAGT

1 **Welche Angabe gab den Ausschlag?**

2 **Was hätte ich ändern müssen?**

3 **Gilt das auch morgen?**

p: vom Modell geschätzte Einladungswahrscheinlichkeit

Konstruiert, eigene Rechnung

Art. 86 KI-VO: Recht auf Erläuterung

ART. 86 ABS. 1, AUSZUG

Betroffene Personen haben gegenüber dem Betreiber das Recht auf „eine klare und aussagekräftige Erläuterung zur Rolle des KI-Systems im Entscheidungsprozess und zu den wichtigsten Elementen der getroffenen Entscheidung“.

PAARFRAGE // 2 MIN

Was gehört in die Erläuterung für Bewerbung 17?

STATUS

Gesetz, formal ab 02.08.2026

⚠ Verhältnis zu Anhang-III-Pflichten ab 02.12.2027 offen

Quelle: VO (EU) 2024/1689, Art. 86, 113 · geprüft am 28.10.2026

Drei Arten, dieselbe Absage zu erklären

BEITRÄGE

„Die Lücke im Lebenslauf senkte Ihren Wert am stärksten.“

WENN-DANN

„Mit 10 Testpunkten und 2 Jahren Erfahrung mehr wären Sie eingeladen.“

VERFAHREN

„Das Modell bewertet Test, Erfahrung und Lebenslauf, gelernt aus Entscheidungen 2024.“

Alle drei stimmen, für verschiedene Fragen.

Konstruiert, eigene Rechnung

Erklärbarkeit

DEFINITION

Eine bestimmte Person kann verständlich erfahren, wie ein Modell zu einem Ergebnis kam.

BEISPIEL

Bewerbung 17 erfährt, was den Wert senkte und was zur Einladung führte.

GRENZE

Sie beschreibt das Modell, nicht ob die Gründe gerecht sind.

Arbeitsdefinition nach Molnar (2025)

Fahrplan und Lernziele

NAVIGATION // 90 MIN

10'	**Ankommen, Retrieval**
12'	**Einstieg: Bewerbung 17**
12'	**Block A: Ordnen**
18'	**Block B: Erklärverfahren**
14'	**Block C: Grenzen und Recht**
24'	**Diskussion, Abschluss**

LERNZIELE

(1) Erklärverfahren einordnen
(2) SHAP-Werte und Counterfactuals lesen und interpretieren
(3) Erklärungen auf Treue, Stabilität und Handlung prüfen
(4) Erläuterungspflichten den Adressaten zuordnen

BLOCK A // 12 MIN

Was heißt hier erklären?

Interpretierbar gebaut oder nachträglich erklärt

INTRINSISCH INTERPRETIERBAR

Modell selbst lesbar

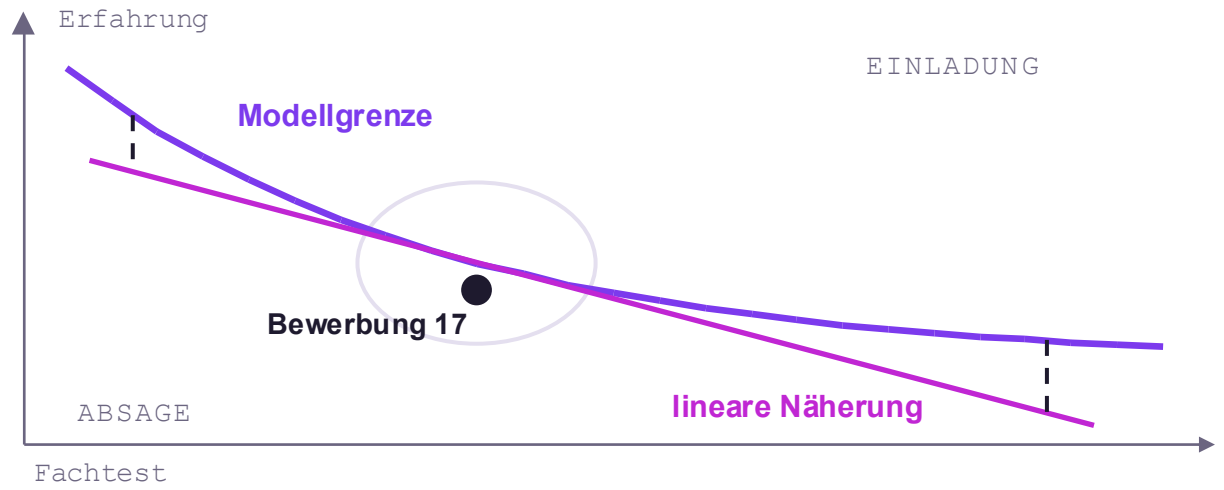
z. B. logistische Regression, unser Screening-Modell

POST-HOC ERKLÄRT

Zweite Rechnung beschreibt es von außen.

z. B. SHAP, LIME, Counterfactuals[1]

SCHEMA



GRENZE

Die Näherung stimmt nur nahe am Fall; beim linearen Modell exakt.

[1] SHAP: Anteile je Merkmal · LIME: lokales Ersatzmodell · Counterfactual: kleinste entscheidende Änderung

Quelle: Molnar (2025); Schema ohne Daten

SHAP

DEFINITION // LUNDBERG & LEE (2017)

SHAP (SHapley Additive exPlanations) verteilt den Modellwert eines Falls auf seine Angaben: Jeder Beitrag zeigt, wie weit eine Angabe vom Durchschnittsfall wegführt.

BEISPIEL

- Bewerbung 17: Lücke −0,71, stärkster Beitrag
- Fachtest +0,33

GRENZE

Werte gelten für ein Modell und seine Trainingsdaten.

Quelle: eigene Rechnung

Lokal oder global

LOKAL

Warum diese eine Entscheidung?

Bewerbung 17: Lücke −0,71

GLOBAL

Wie entscheidet das Modell?

300 Altfälle: Lücke im Mittel 0,33

ein Fall → |SHAP| je Fall, gemittelt → **das Modell**

PRÜFFRAGE // 2 MIN

Benachteiligt das Modell Lücken? Lokal oder global?

LÖSUNG

Global: betrifft alle Fälle.

Quelle: eigene Rechnung; Molnar (2025)

Wer fragt, bestimmt die Erklärung

BETROFFENE PERSON

„Was kann ich tun?“

lokal, mit Handlungsoption

BETREIBER

„Wann darf ich dem Ergebnis trauen?“

global, Grenzen je Gruppe

AUFSICHT, AUDIT

„Ist das belegt und wiederholbar?“

Dokumentation, Versionen, Protokolle

Rollen: KI-VO Art. 3; eigene Zuordnung

Vier Prüfkriterien einer Erklärung

TREUE

Trifft sie das Modell?

BEISPIEL F06:

Alle drei treffen das Modell.

VERSTÄNDLICHKEIT

Versteht der Adressat sie?

BEISPIEL F06:

Alle drei sind Alltagssprache.

STABILITÄT

Bleibt sie nach Neutraining gleich?

BEISPIEL F06:

„Wenn-dann“ verfehlt sie (Folie 29).

HANDLUNG

Zeigt sie einen Weg?

BEISPIEL F06:

Nur „Wenn-dann“ zeigt einen Weg.

Quelle: Molnar (2025); Ustun et al. (2019); eigene Zusammenstellung

BLOCK B // 18 MIN

SHAP und Counterfactuals

Notation an einem Beispiel

BEISPIEL

Bewerbung 17: $x_1 = 74$, $x_2 = 3$, $x_3 = 1$

HERKUNFT: LOGISTISCHE REGRESSION

Gewichtete Summe z; Sigmoid-Funktion macht daraus p.

BERECHNET

p eines Falls: z = −1,42, p = 0,19

→

BEDEUTUNG

x_j	Angabe j
w_j	gelerntes Gewicht
b	Achsenabschnitt
z	Modellwert in Log-Odds: $b + \Sigma\, w_j \cdot x_j$
p	Einladungswahrscheinlichkeit: $1/(1 + e^{-z})$
Mittel_j	Mittel der Altfälle
φ_j	SHAP-Wert von j

$p = 0{,}50 \Leftrightarrow z = 0$ **Schwelle**

Quelle: Molnar (2025)

Das Modell hinter Bewerbung 17

MODELL M1

MERKMAL	GEWICHT w	MITTEL	FALL 17
Fachtest Punkte	+0,063	68,68	**74**
Erfahrung Jahre	+0,405	3,73	**3**
Lücke ja = 1	−0,923	0,23	**1**

b = −6,36 · Trainingsgenauigkeit 0,74

KONSTRUIERT

- 300 synthetische Personalentscheidungen aus 2024
- Eignung hängt nicht von der Lücke ab.
- Altentscheidungen strafen sie trotzdem: Label-Bias (W04).

Quelle: eigene Rechnung

Shapley-Werte: ein Ergebnis fair aufteilen

SPIELTHEORIE

Spieler erzielen gemeinsam ein Ergebnis; jeder erhält seinen Grenzbeitrag, gemittelt über alle Reihenfolgen.

AUF MODELLE

- Spieler: die Merkmale
- Ergebnis: Abstand des Falls vom Durchschnittsfall
- Beiträge summieren sich genau dazu.

GRENZE

Aufwand wächst exponentiell; lineare Modelle exakt, sonst Näherung.

Quelle: Shapley (1953); Lundberg & Lee (2017)

SHAP-Wert im linearen Modell

DEFINITION

Eine Angabe verschiebt den Modellwert z um ihr Gewicht mal ihren Abstand zum Mittel der Altfälle.

BEWERBUNG 17

- Fachtest über dem Mittel: **+0,33**
- Erfahrung unter dem Mittel: **−0,29**
- Lücke (nur 23 % der Altfälle): **−0,71**

Formel: Vertiefung, Folie 45

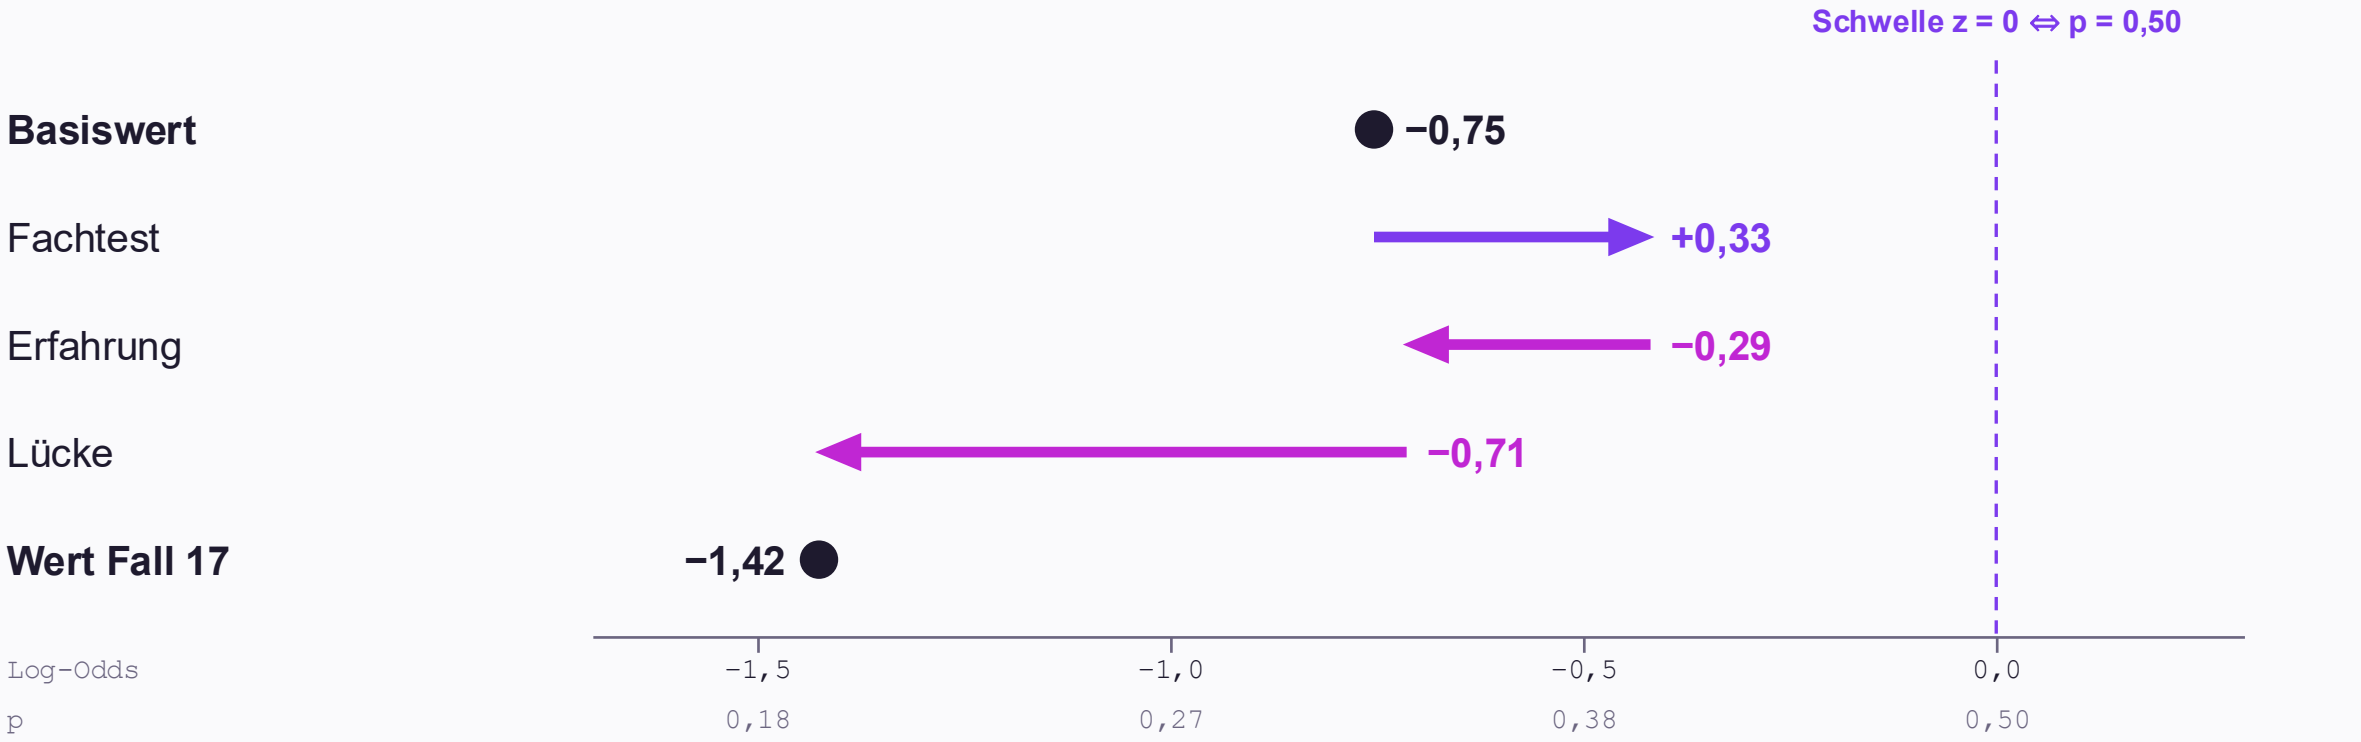
GRENZE

Exakt nur bei unabhängigen Merkmalen.

- Mit Lücke im Mittel 2,7 Jahre Erfahrung, ohne 4,0 (r = −0,25). Aufteilung: Konvention.

Quelle: Lundberg & Lee (2017); eigene Rechnung

Bewerbung 17 als Wasserfall (lokal)



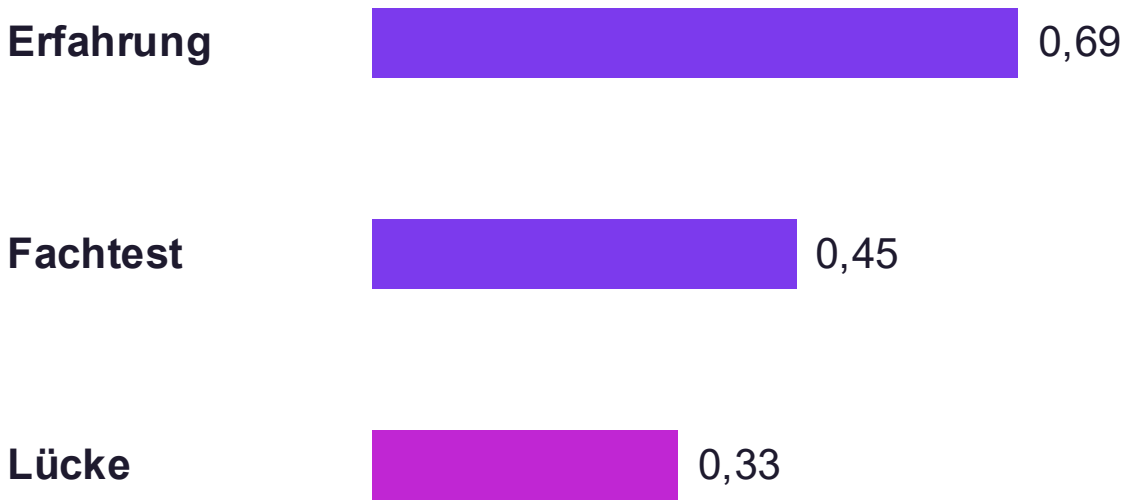
Lesart: von p = 0,32 zu p = 0,19; die Lücke senkt am stärksten.

Beiträge addieren sich in Log-Odds z = ln(p/(1−p)); p = 1/(1+e^−z). Gleicher Beitrag, je nach Ausgangspunkt unterschiedlich viele Prozentpunkte: Lücke hier −13 pp, an der Schwelle −17 pp.

Quelle: eigene Rechnung, gerundet

Global: was im Mittel zählt

MITTLERER SHAP-BETRAG



LESART

Im Mittel zählt die Lücke am wenigsten, für Bewerbung 17 am meisten: Proxy-Effekt.

Quelle: eigene Rechnung

SHAP-Werte richtig lesen

	WAS GILT	AM FALL 17
Skala	Werte addieren sich in Log-Odds.	−0,71 sind keine Prozentpunkte.
Vergleichspunkt	Relativ zu den Hintergrunddaten.	Durchschnitt der 300 Altfälle
Ursache	Beitrag ist keine Ursache in der Welt.	Lücke senkt z, nicht die Eignung.

Quelle: Kumar et al. (2020); Molnar (2025)

Kontrafaktische Erklärung

DEFINITION

Kleinste Änderung der Angaben, die die Entscheidung dreht.

BEWERBUNG 17

- **Ausgangslage:** p = 0,19, Absage
- **Änderung:** Test +10, Erfahrung +2
- **Ergebnis:** p = 0,50, Einladung
- **Bedeutung:** ein Weg, den sie selbst gehen kann

GRENZE

Viele Änderungen möglich; mitgeteilt wird eine Auswahl.

Quelle: Wachter et al. (2018); eigene Rechnung

Vier Änderungen im Vergleich

ÄNDERUNG	ERGEBNIS M1	UMSETZBAR?
Fachtest +22,7	p = 0,50	kaum
Erfahrung +3,5 Jahre	p = 0,50	ja, dauert
Lücke entfernen	p = 0,38	nein
Test +10, Erfahrung +2	p = 0,50	ja, knapp

Rechnung: Vertiefung, Folie 47

Quelle: Ustun et al. (2019); eigene Rechnung

PAARFRAGE // 2 MIN

Welchen Weg teilen Sie mit?

PRÜFLISTE

umsetzbar: nur veränderbare Angaben

sparsam: wenige, kleine Änderungen

mit Abstand: p klar über 0,50

SHAP und Counterfactuals im Vergleich

	SHAP	COUNTERFACTUAL
Frage	Was zählte wie viel?	Was hätte sich ändern müssen?
Grundlage	Aufteilung, exakt im linearen Modell	kleinste Änderung über die Schwelle
Schwäche	Unabhängigkeitsannahme	viele Lösungen, je Modellstand

Quelle: Molnar (2025); Wachter et al. (2018)

EuGH C-203/22: Auskunft über ein Bonitätsscoring

FALL

- Kundin in Österreich gegen Auskunftei Dun & Bradstreet
- Vertrag (10 Euro/Monat) nach automatisierter Bonitätsprüfung verweigert
- Auskunft zur Logik verweigert: Geschäftsgeheimnis
- **Vorlage VG Wien:** Inhalt „aussagekräftiger Informationen über die involvierte Logik“

URTEIL // GEPRÜFT

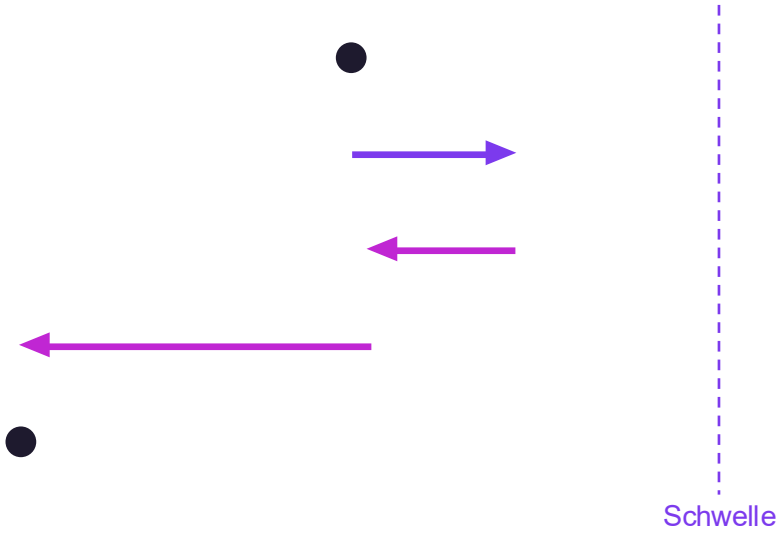
Rn. 58	Verfahren und Grundsätze erläutern
Rn. 59	Formel oder Algorithmus genügt nicht
Rn. 61	welche Daten wie verwendet wurden
Rn. 62	kann genügen: Wirkung abweichender Daten

EuGH 27.02.2025, ECLI:EU:C:2025:117, Vorabentscheidung · geprüft am 28.10.2026

Genügt unsere Erklärung dem Maßstab des EuGH?

Bewerbung 17 erhält den Wasserfall von Folie 20. Genügt das?

ERINNERUNG



A Ja, er zeigt die Wirkung der Daten.

B Nur mit Counterfactual.

C Nein, Verfahren und Grundsätze fehlen.

⚠ *Übertragung: eigene Einordnung · Auflösung: Folie 36*

BLOCK C // 14 MIN

Wenn Erklärung nicht reicht

Neutraining verschiebt die Erklärung

Gleich: Verfahren, Merkmale, Schwelle, Fall 17. **Neu:** Altentscheidungen 2025, gleiches Muster.

	M1 · 2024	M2 · 2025
Trainingsgenauigkeit	0,74	0,74
SHAP Lücke	−0,71	−1,37
p Bewerbung 17	0,19	0,11
CF Erfahrung +3,5	p = 0,50	**p = 0,41**

WARUM

1 Andere Stichprobe, andere Gewichte

2 Handlungsoption gilt nur für ihr Modell

Quelle: eigene Rechnung; Upadhyay et al. (2021)

Stabilität einer Erklärung messen

TEST

1. 20-mal neu trainieren (Bootstrap)
2. Fall neu erklären
3. Zählen, was gleich bleibt

BEWERBUNG 17

Lücke wichtigstes Merkmal	**19/20**
SHAP Lücke: −1,50 bis −0,02	
CF Test +10, Erfahrung +2	**4/20**
CF Test +10, Erfahrung +3	**13/20**

Quelle: eigene Rechnung

Befunde zur Verlässlichkeit

	BEFUND	QUELLE
Fragil	Fast gleiche Eingaben, deutlich andere Erklärungen	Ghorbani et al. (2019)
Täuschbar	Verzerrtes Modell, harmlos wirkende Erklärungen, auch SHAP	Slack et al. (2020)
Ungleich treu	Treue unterscheidet sich zwischen Gruppen	Balagopalan et al. (2022)

Alle peer-reviewed · geprüft am 28.10.2026

Was Erklärungen belastbarer macht

		AM FALL 17
PRÜFEN	**Vor dem Versand testen**	Knappe Kombination: 4/20 gültig
ABSTAND	**Abstand zur Schwelle halten**	Test +10, Erfahrung +3: 13/20
LESBAR BAUEN	**Lesbares Modell, wo es genügt**	Gewicht −0,92 zeigt die Strafe (Folie 52)
DOKUMENTIEREN	**Grenzen in der Model Card**	„Gilt für Stand M1“ (Folie 33)

Quelle: Upadhyay et al. (2021); Rudin (2019); Mitchell et al. (2019)

Model Card

DEFINITION

Kurzbericht zu einem Modell: Zweck, Daten, Leistung je Gruppe, Grenzen.

BEISPIEL

- Erklärungen gelten für Stand M1.
- Die Lücke trägt Label-Bias.
- Nach Neutraining neu prüfen.

GRENZE

Sie dokumentiert, prüft aber nichts.

Ob die Angaben stimmen, zeigt ein Test (Folie 30).

Quelle: Mitchell et al. (2019) · peer-reviewed

Erläuterungspflichten: wer schuldet wem was

ART. 13 KI-VO

Anbieter → Betreiber

Ausgaben „angemessen interpretieren und verwenden“

ANHANG IV KI-VO

Anbieter → Aufsicht

„allgemeine Logik des KI-Systems“

ART. 86 KI-VO

Betreiber → Person

Rolle des Systems, wichtigste Elemente

ART. 15, 22 DSGVO

Verantwortlicher → Person

Logik, ausgelegt in C-203/22

Quelle: KI-VO, DSGVO · geprüft am 28.10.2026

Bewerbung 17 im Rechtsrahmen

EINSTUFUNG	Hochriskant nach Anhang III Nr. 4 lit. a, mit Profiling immer
ART. 86	Formal ab 02.08.2026; Anhang-III-Pflichten ab 02.12.2027 ⚠
DSGVO	Automatisierte Absage: Art. 22, Art. 15 Abs. 1 lit. h
VERHÄLTNIS	⚠ Art. 86 Abs. 3 neben der DSGVO: ungeklärt

Quelle: KI-VO; VO (EU) 2026/1744; DSGVO · geprüft am 28.10.2026

Auflösung und bereinigtes Modell

ABSTIMMUNG

Rn. 58	Verfahren fehlt
Rn. 59	Formel genügt nicht
Rn. 61	Datenwirkung: nur in Alltagssprache
Rn. 62	Counterfactual kann genügen

Ergebnis: C mit Elementen von B

⚠ *Übertragung: eigene Einordnung*

LABELS = EIGNUNG

	M1	M1 BEREINIGT
p Bewerbung 17	0,19	0,39
SHAP Lücke	−0,71	+0,09
Erfahrung +2 Jahre	p = 0,35	**p = 0,61**

Erklärung und Handlungsoption hängen an Modellstand und Labels.

Quelle: C-203/22; eigene Rechnung; Lesart: eigene Einschätzung

Aus der Praxis: zwei Beobachtungen

BEOBACHTUNG 1

Fachabteilungen im Online-Handel fragen selten nach Gewichten, eher was sie ändern können.

FOLGERUNG

Wenn-dann-Erklärungen anbieten (Folie 23).

BEOBACHTUNG 2

Erklärungen entstehen oft einmal zum Start und veralten mit dem nächsten Training.

FOLGERUNG

Stabilitätstest in den Betriebsprozess aufnehmen (Folie 30).

Eigene Einschätzung, nicht empirisch belegt

Belegstatus dieser Einheit

GEPRÜFT

Gesetz: KI-VO, DSGVO
Urteil: EuGH C-203/22
Peer-reviewed: alle Paper

EINORDNUNG

Konstruiert: Bewerbung 17, M1, M2, M1 bereinigt
Eigene Einschätzung: Übertragung des Urteils, Praxis
⚠ **Offen:** Art. 86 vor 02.12.2027; Verhältnis zur DSGVO

Quelle: Aktualitätsbriefing W05 · geprüft am 28.10.2026

THINK-PAIR-SHARE // 12 MIN

„Für das Bewerbungs-Screening genügt ein gut erklärtes Modell. Ein interpretierbares Modell ist nicht nötig.“

DAFÜR

SHAP und Counterfactuals liefern, was Art. 86 und der EuGH verlangen.

DAGEGEN

Erklärungen schwanken und lassen sich täuschen.

Begriffe der Woche

Post-hoc-Erklärung post-hoc explanation

Nachträglich berechnete Erklärung.

Intrinsische Interpretierbarkeit intrinsic interpretability

Modell selbst lesbar.

Lokale und globale Erklärung local/global explanation

Ein Fall oder das Modell.

Treue fidelity

Erklärung trifft das Modell.

SHAP-Wert SHAP value

Beitrag eines Merkmals.

Kontrafaktische Erklärung counterfactual explanation

Kleinste entscheidende Änderung.

Handlungsoption algorithmic recourse

Änderung über veränderbare Merkmale.

Stabilität einer Erklärung explanation stability

Gleich nach Neutraining.

Model Card model card

Kurzbericht zu Zweck, Leistung, Grenzen.

Recht auf Erläuterung right to explanation

Art. 86 KI-VO; Art. 15 DSGVO.

Fachgespräch: mögliche W05-Fragen

FRAGE 1

Was sagt ein SHAP-Wert, was nicht?

FRAGE 2

Wann ist ein Counterfactual eine brauchbare Handlungsoption?

FRAGE 3

Wie prüfen Sie die Stabilität Ihrer Erklärungen?

FRAGE 4

Welche Erläuterung schuldet Ihr Betreiber wem?

ZUSAMMENFASSUNG

Takeaways

ANTWORT AUF DIE LEITFRAGE

Eine verständliche Erklärung von Verfahren und Fall mit Handlungsoption. Sie trägt, solange sie treu ist und nach jedem Training bestätigt wird.

ERKLÄREN

Lokal ist nicht global: Für die Person zählt ihr Fall.

PRÜFEN

Erklärungen gelten für einen Modellstand.

NEXT // W06

AI Agent Design, 11.11.

Lektüre: Bai et al. (2022), Constitutional AI. Vertiefung im Anhang.

FREIWILLIGE VERTIEFUNG

Erklärbarkeit in der Tiefe

Freiwillig · Selbststudium · nicht prüfungsrelevant

Wozu diese Vertiefung taugt

FREIWILLIGE VERTIEFUNG // LESEHINWEIS

- Für Kapitel 3 der Semesterarbeit: zitierfähige Originalarbeiten in Steckbriefen.
- Für die Methode: Rechenwege zu Bewerbung 17, die Shapley-Formel und Robustheit von Handlungsoptionen.
- Für die Quellenkritik: Preprints 2025 und 2026 mit ihrem Status.

HINWEIS

Nicht prüfungsrelevant

Prüfungsrelevant ist der Kern bis zu den Takeaways. Die Vertiefung hilft beim Verstehen und beim Zitieren.

Rechenweg: SHAP-Werte für Bewerbung 17

SCHRITT 1 // BEITRÄGE: $\varphi_j = w_j \cdot (x_j - \text{Mittel}_j)$

Merkmal	w_j	x_j	Mittel_j	$w_j \cdot (x_j - \text{Mittel}_j)$	φ_j
Fachtest	+0,0627	74	68,681	0,0627 · (74 − 68,681)	**+0,33**
Erfahrung	+0,4045	3	3,729	0,4045 · (3 − 3,729)	**−0,29**
Lücke	−0,9234	1	0,230	−0,9234 · (1 − 0,230)	**−0,71**

SCHRITT 2 // PROBE

$z_0 = b + \Sigma\, w_j \cdot \text{Mittel}_j = -0{,}75$
$z_0 + \Sigma\, \varphi_j = -0{,}75 + 0{,}33 - 0{,}29 - 0{,}71 = -1{,}42$
$p = 1/(1 + \exp(1{,}42)) = 0{,}19$

SCHRITT 3 // GLOBAL

Mittel von $|\varphi_j|$ über alle 300 Altfälle:
Erfahrung 0,69 · Fachtest 0,45 · Lücke 0,33

Quelle: eigene Rechnung (w05_rechenbeispiel.py, OPAL), gerundet; Lundberg & Lee (2017), Corollary 1

Shapley-Werte, formal

FREIWILLIGE VERTIEFUNG // HERLEITUNG

- **Koalitionen:** Jede Teilmenge S der Merkmale hat einen Wert v(S): die erwartete Vorhersage, wenn nur S bekannt ist.
- **Grenzbeitrag:** Für Merkmal j: $v(S \cup \{j\}) - v(S)$.
- **Mittelung:** $\varphi_j = \Sigma$ über $S \subseteq N \setminus \{j\}$ von $|S|!\cdot(n - |S| - 1)!/n! \cdot [v(S \cup \{j\}) - v(S)]$, also über alle Reihenfolgen gemittelt.
- **Linearer Fall:** Bei unabhängigen Merkmalen folgt $\varphi_j = w_j (x_j - E[x_j])$, wie auf Folie 19.

Quelle: Lundberg & Lee (2017), NeurIPS 30, Abschn. 4.2; Shapley (1953); Darstellung nach Molnar (2025), Kap. Shapley Values

Rechenweg: Counterfactuals im linearen Modell

MODELL M1, BEWERBUNG 17

Bedingung	Änderung Δ_j verschiebt z um $w_j \cdot \Delta_j$; Einladung ab $z \geq 0$, heute $z = -1{,}424$
Fachtest allein	$\Delta = -z / w_1 = 1{,}424 / 0{,}0627 = 22{,}7$ Punkte
Erfahrung allein	$\Delta = -z / w_2 = 1{,}424 / 0{,}4045 = 3{,}52$ Jahre
Lücke entfernen	$z = -1{,}424 + 0{,}923 = -0{,}50$, $p = 0{,}38$
Test +10, Erf. +2	$z = -1{,}424 + 10 \cdot 0{,}0627 + 2 \cdot 0{,}4045 = 0{,}012$, $p = 0{,}50$
Test +10, Erf. +3	$z = -1{,}424 + 10 \cdot 0{,}0627 + 3 \cdot 0{,}4045 = 0{,}42$, $p = 0{,}60$
Kombination unter M2	$z = -2{,}100 + 10 \cdot 0{,}0693 + 2 \cdot 0{,}4930 = -0{,}42$, $p = 0{,}40$

Quelle: eigene Rechnung (w05_rechenbeispiel.py, OPAL), gerundet; Wachter et al. (2018); Ustun et al. (2019)

Steckbrief: Lundberg & Lee (2017)

FREIWILLIGE VERTIEFUNG // PAPER // BEGUTACHTET

- **Beitrag:** Führt mehrere Erklärverfahren auf additive Merkmalszuschreibungen zurück.
- **Kern:** Lokale Genauigkeit, Missingness und Konsistenz bestimmen die Lösung eindeutig.
- **Folge:** Bei festem Hintergrund und Modell sind SHAP-Werte reproduzierbar.
- **Güte:** NeurIPS 2017, begutachtet.

Quelle: Lundberg & Lee (2017): A Unified Approach to Interpreting Model Predictions, NeurIPS 30

Steckbrief: Wachter, Mittelstadt & Russell (2018)

FREIWILLIGE VERTIEFUNG // PAPER // BEGUTACHTET

- **Beitrag:** Kontrafaktische Erklärungen als Begründungsform ohne Offenlegung des Modells.
- **Zwecke:** Verstehen, anfechten, handeln.
- **Rechtskontext:** Geschrieben zur DSGVO, vor KI-VO und vor C-203/22.
- **Güte:** Harvard Journal of Law & Technology 31(2), 841–887.

Quelle: Wachter, Mittelstadt & Russell (2018), Harv. JOLT 31(2), 841–887

Steckbrief: Ustun, Spangher & Liu (2019)

FREIWILLIGE VERTIEFUNG // PAPER // BEGUTACHTET

- **Beitrag:** Handlungsoption (Recourse) als Prüfgröße für lineare Klassifikatoren.
- **Kern:** Nur veränderbare Merkmale zählen, etwa Einkommen, nicht Alter.
- **Methode:** Ganzzahlige Optimierung findet die günstigste Handlung oder zeigt, dass es keine gibt.
- **Güte:** FAT* 2019, 10–19, begutachtet.

Quelle: Ustun, Spangher & Liu (2019): Actionable Recourse in Linear Classification, FAT '19*

Rashomon, Multiplizität und robuste Handlungsoptionen

FREIWILLIGE VERTIEFUNG // ROBUSTHEIT

- **Rashomon-Effekt:** Viele Modelle mit fast gleichem Fehler, verschiedene Beschreibungen (Breiman 2001).
- **Multiplizität:** Gleich gute Modelle treffen widersprüchliche Einzelentscheidungen (Marx et al. 2020).
- **Modell-Updates:** Updates können empfohlene Handlungsoptionen unwirksam machen (Upadhyay et al. 2021).
- **Unter Multiplizität:** Datennahe Counterfactuals sind robuster, aber teurer (Pawelczyk et al. 2020).

Quelle: Breiman (2001), Stat. Sci. 16(3); Marx, Calmon & Ustun (2020), ICML; Upadhyay, Joshi & Lakkaraju (2021), NeurIPS 34; Pawelczyk, Broelemann & Kasneci (2020), UAI

FREIWILLIGE VERTIEFUNG // GEGENPOSITION

Rudin: interpretierbar bauen, nicht erklären

THESE // RUDIN (2019)

Bei hohem Einsatz interpretierbare Modelle bauen. Black Boxes nicht nachträglich erklären.

ARGUMENT

Unter vielen fast gleich guten Modellen ist oft ein lesbares (Rashomon, Breiman 2001).

STÄRKE

Modell und Erklärung fallen zusammen: Das Gewicht −0,92 zeigt die Strafe für die Lücke.

GRENZE

Gleich gute lesbare Modelle gibt es nicht immer. Auch sie ändern sich nach Neutraining (Folie 29).

Rudin (2019), Nature Machine Intelligence 1(5), 206–215 · peer-reviewed; Grenze: eigene Einschätzung

Steckbriefe: Model Cards und Datasheets

FREIWILLIGE VERTIEFUNG // PAPER // BEGUTACHTET

- **Mitchell et al. (2019):** Neun Abschnitte von Model Details bis Caveats and Recommendations.
- **Kernidee:** Leistung je Gruppe und Einsatzbedingung berichten.
- **Gebru et al. (2021):** Fragenkatalog für Datensätze von Motivation bis Wartung.
- **Bezug:** Ein Datasheet zum eigenen Datensatz spart Arbeit im Audit-Kapitel.

Quelle: Mitchell et al. (2019), FAT '19, 220–229; Gebru et al. (2021), CACM 64(12), 86–92*

Karten jenseits der Model Card

FREIWILLIGE VERTIEFUNG // PREPRINTS

- **Explanation Card:** Dokumentiert das Erklärverfahren; soll Betreiber bei Art. 86 unterstützen (arXiv 2606.16786).
- **Robustness Card:** Protokoll für Zeitreihenmodelle in der Industrie (arXiv 2512.11868).
- **System Card:** Beschreibt Pipelines aus Modellen, Regeln und Menschen; Anbieterpraxis ohne Standard.
- **Status:** Preprints, nicht begutachtet; kein Standard, keine Pflicht.

Quelle: Günther et al., arXiv 2606.16786 (v2 06.10.2026); Windmann et al., arXiv 2512.11868 (v2 12.05.2026); beide Preprints

Drei Preprints zu Erklärungen mit Wahrheitsanspruch

FREIWILLIGE VERTIEFUNG // PREPRINTS

- **Glassbox:** Bayes-Netze strukturieren das Schließen generativer Modelle vor der Ausgabe (Leonelli, arXiv 2606.07113).
- **RENTT:** Neuronale Netze verhaltensgleich in Entscheidungsbäume überführen (Monke et al., arXiv 2511.09299).
- **gSMILE:** Attribution für generative Modelle über Prompt-Änderungen; Abschlussarbeit (Dehghani, arXiv 2602.01206).
- **Status:** Alle drei nicht begutachtet; als Richtungsanzeige zitierbar, nicht als Stand der Technik.

Quelle: arXiv 2606.07113, 2511.09299, 2602.01206; alle Preprints, geprüft am 28.10.2026

Begutachtet: Review zur Betrugserkennung 2026

FREIWILLIGE VERTIEFUNG // QUELLENKRITIK

- **Gegenstand:** Methodische Probleme erklärbarer KI in der Betrugserkennung, systematischer Review.
- **Befund:** Vorhersageleistung dient oft als Ersatz für Erklärungsgüte; Nutzerstudien sind selten.
- **Reichweite:** Eine Domäne; Übertragung auf Screening ist eine Annahme.
- ⚠ **Zahlen:** Studienzahlen nur über die Verlagszusammenfassung geprüft.

Quelle: Zafar & Wu (2026), Artificial Intelligence Review 59, Art. 115, doi 10.1007/s10462-026-11516-7

Erklärungen im Betrieb

FREIWILLIGE VERTIEFUNG // BETRIEB

- **Rechenzeit:** KernelSHAP ist langsam; lineare und baumbasierte Verfahren sind schneller.
- **Wiederholbarkeit:** KernelSHAP schätzt aus Stichproben; Seeds festhalten.
- **Hintergrunddaten:** Wahl und Größe dokumentieren; shap zieht ohne Angabe nur eine Stichprobe.
- **Versionen:** Modell, Bibliothek und Datenstand zu jeder Erklärung speichern.

Quelle: Molnar (2025), 3. Aufl., Kap. SHAP; shap-Dokumentation, LinearExplainer und maskers.Independent

Selbststudium: Wege und Ressourcen

FREIWILLIGE VERTIEFUNG // WEITERARBEIT

- **Lehrbuch:** Molnar (2025), Interpretable Machine Learning, 3. Aufl., frei online.
- **Bibliotheken:** shap, DiCE, scikit-learn; Hintergrund und Seeds dokumentieren.
- **Für Kapitel 3:** Ergebnisdatei der Übung, Absatz Grenzen der Erklärung, Model Card anlegen.
- **Für W06:** Bai et al. (2022), Constitutional AI, Kapitel 1 und 2.

Quelle: Molnar (2025); Kapitelkarte Kapitel 3; Literaturliste W06 (AI Agent Design)