Wo wir im Semester stehen

W	DATUM	VORLESUNG	ÜBUNG	MEILENSTEIN
W01	07.10.	Einführung	Dilemma-Debatte, Teambildung	
W02	14.10.	Aufbau & Fachbegriffe	Prinzipien-Mapping, Glossar	
W03	21.10.	EU AI Act & Rechtsprechung	Risikoklassifikation, Urteile	THEMENVERGABE
W04	28.10.	Fairness & Bias-Metriken	Fairness am eigenen Thema	
W05	04.11.	**Transparenz & Explainability**	**SHAP, Model Card**	**HEUTE**
W06	11.11.	AI Agent Design	Agenten-Verfassung	
	18.11.	*kein Termin (Buß- und Bettag)*		
W07	25.11.	Privacy & Datenschutz	Privacy-Fall vorbereiten	EXPOSÉ
W08	02.12.	Robustheit & Sicherheit	Red-Teaming-Lab	
W09	09.12.	Traceability: Produkte, Roboter	Produktpass und Roboter-ID	
W10	16.12.	Verifizierte KI-Agenten	Trust-Architektur	KURZPITCH
		Weihnachtspause 21.12.–02.01.		
W11	06.01.	Markenmoral & Kundenvertrauen	Trust-Score-Card	
W12	13.01.	Physical AI & Embodied Trust	Roboter-Assessment	ABGABE 17.01.
W13	20.01.	Auditing & Operationalisierung	Peer-Audit	
W14	27.01.	Prüfungsgespräch (Block)	Vortrag und Fachgespräch	PRÜFUNG

RÜCKBLICK // KERNAUSSAGEN

W02 · 14.10. · FACHBEGRIFFE

Ein Prinzip wird erst prüfbar, wenn es Definition, Messgröße und Verantwortliche hat.

ÜBUNG // GLOSSAR ANGELEGT

W03 · 21.10. · EU AI ACT

Zivile Haftung wirkt schon vor den AI-Act-Fristen. Ob sie greift, hängt am Rechtsgebiet und daran, ob die KI eine eigene Aussage erzeugt.

ÜBUNG // THEMEN VERGEBEN

W04 · 28.10. · FAIRNESS & BIAS

Bei ungleichen Basisraten muss man wählen. Wir wählen die Metrik, deren Fehler wir begründet in Kauf nehmen.

ÜBUNG // METRIK, BASELINE, EINGRIFF

UPDATE // PLANÄNDERUNG // STAND 02.11.2026

W06 und W07 sind getauscht

MI 11.11. // W06

AI Agent Design

Übung: Agenten-Verfassung
1-Minute-Paper
Lektüre: Bai et al. (2022), Constitutional AI

MI 25.11. // W07

Privacy & Datenschutz mit Gast Dr. Gunnar Hempel

08:00 Übung: Privacy-Fall vorbereiten
09:45 Vorlesung
Exposé-Abgabe, Midterm-Evaluation

Fristen bleiben: Exposé am 25.11. Kapitel 5 beginnt am 11.11., Kapitel 4 am 25.11.

⚠ *Die Inhalte des 25.11. stimmen wir mit dem Gast noch ab.*

Exposé: was am 25.11. vorliegen soll

INHALT // IN DIESER REIHENFOLGE

1. Arbeitstitel, Thema T<NN>, Team und Teamkürzel
2. Zielsystem: benannt, aus öffentlichen Quellen dokumentierbar
3. Risikoklassifikation aus W03, mit Artikel bzw. Anhang begründet
4. Dachfrage, auf Ihr System bezogen
5. Gliederung nach Kapitel 1–7 (nächste Folie), je ein bis zwei Sätze
6. Methodik: Daten, Werkzeuge, realistischer Umfang
7. Quellen nach APA 7, mit Reifegrad

FORM UND ABGABE

2–3 Seiten Fließtext, 11 pt, 1,15, Ränder 2,5 cm

PDF im OPAL bis Mi 25.11., 23:59
I050_T<NN>_<Teamkürzel>_Expose.pdf

Entwurf zum Peer-Check in der Übung um 08:00 mitbringen

ANHANG // ZÄHLT NICHT MIT

- KI-Deklaration in Kurzform: Werkzeug, Wofür, Wie geprüft, Verantwortlich, Stand
- Model Card aus W05, vervollständigt

Gliederung: das Kapitelraster 1–7

Dachfrage: Wie belastbar ist das Vertrauen in dieses System, und woran ließe sich das von außen überprüfen?

KAPITEL	INHALT	ENTSTEHT IN
1	System- und Kontextbeschreibung, Risikoklassifikation nach KI-VO	W03
2	Fairness- und Bias-Analyse (Python, fairlearn)	W04
3	Transparenz und Erklärbarkeit (SHAP, Counterfactuals, Model Card)	W05
4	Datenschutz- und Sicherheitsbetrachtung	W07, W08
5	Trust-Architektur: drei Maßnahmen mit Trade-off-Diskussion	W06, W09–W12
6	Audit-Bericht nach Mini-Audit-Framework	W10–W12
7	Kritische Reflexion und Forschungsausblick	bis zur Abgabe

Grenzen der Messung im Überblick

MATHEMATISCH

Ungleiche Basisraten: Nicht alle Metriken sind zugleich erfüllbar.

VL-FOLIEN 28, 29

NORMATIV

Mit der Metrik legen Sie fest, welcher Fehler schwerer wiegt.

VL-FOLIE 30

PRAKTISCH

Messwerte schwanken; ein Audit gilt nur für den geprüften Stand.

VL-FOLIEN 32, 33

RECHTLICH

Wer Ungleichbehandlung misst, braucht geschützte Merkmale.

VL-FOLIEN 24, 34

IHR FELD „GRENZE DER MESSUNG“

Was Ihre Zahl nicht zeigt. Beispiel: Die Labels der Altdaten können selbst verzerrt sein.

„Preis“ im Arbeitsblatt

DEFINITION // ARBEITSBLATT TEIL B, SCHRITT 4

„Preis“ ist, was der Eingriff an anderer Stelle kostet. Verglichen werden Basismodell und Ergebnis nach dem Eingriff:

1. die Genauigkeit
2. die zweite Fairness-Metrik, nicht Ihre Zielmetrik
3. TPR oder FPR je Gruppe

BEISPIEL // WOHNUNGSVERGABE, SEED 12

	VORHER	NACHHER
Differenz Chancen (Ziel)	0,10	**0,02**
Genauigkeit	0,78	**0,77**
Differenz Parität	0,16	**0,08**
FPR Gruppe b	0,13	**0,19**

Eingriff: Schwelle b 0,50 → 0,40

MUSTERSATZ

Gleiche Chancen kosten rund 0,01 Genauigkeit; in b steigt die FPR von 0,13 auf 0,19.

Werte: Arbeitsblatt W04, Eingaben wie Übungsfolien 5 und 6

Neu diese Woche: Modell-Edit und Benchmark

MODELL EDITIERT MODELL // MIT CSAIL, 02.11.

GPT-6 Astra ändert 0,016 % der Gewichte von Qwen3.5-0.8B, ohne Training.

- MATH-500: 7,9 % → 48,1 %, vor allem weil Denkschleifen verschwinden
- Bei Gemma 3 270M kein Effekt: Hindernis entfernt, keine neue Fähigkeit
- Blogpost ohne Peer-Review; Nachmessung Dritter: 51,0 %

BENCHMARK // OPENAI LIFEVAL, 02.11.

Alltagsaufgaben als Agent: GPT-6 Astra rund 80 %, kaum vor GPT-5.6.

- Sieben Lebensbereiche, z. B. Finanzen, Gesundheit, Behörden
- Nur OpenAI-Modelle getestet
- Aufgaben, Rubriken und Bewerter nicht veröffentlicht

BEZUG W05

Prüfbar ist nur, was offenliegt: Diff, Prompts und Messung bei Astra, bei LifeVal fehlt das.

⚠ *LifeVal-Detailwerte nur über Sekundärquellen; India-Today-Text nicht abrufbar. Inoffizielle HF-Kopie: sekkit/Qwen3.5-0.8B-Astra-WeightEdit.*

Quellen: Takehi, Teoh, Zhang, Khattab (2026), Blogpost; HF-Modellkarten sekkit, RikiyaT; OpenAI (2026) LifeVal; CNN 02.11.2026 · geprüft am 03.11.2026