W05 // ÜBUNG // 04.11.2026 // ARBEITSBLATT IM BROWSER

Erklärungen prüfen

Keine Installation. Alles läuft in diesem Browserfenster, nichts wird gesendet. Die Daten sind synthetisch.

Gruppe

bitte wählen

Thema

bitte wählen

TEIL A // PHASE 1 // 25 MIN

Aufgabenkarte 1: Erklärbedarf festlegen
Ziel: Festlegen, für wen Ihre Erklärung ist und woran sie sich messen lässt.

1. Nennen Sie Entscheidung $\hat{Y}$ und die Betroffenen.
2. Beschreiben Sie Adressat, Zweck und Rechtsgrundlage.
3. Nennen Sie, welche Merkmale veränderbar sind und wie weit.
4. Erläutern Sie Ihre Gütekriterien für Stabilität und Zielwahrscheinlichkeit.

Ergebnis: Arbeitsblatt Teil A · **Zeit:** 25 Minuten · **Abgabe:** mit der Ergebnisdatei

1 Entscheidung und Betroffene (VL 5)

$\hat{Y}$ = 1 bedeutet

z. B. zum Gespräch eingeladen

Betroffen ist

z. B. Bewerberin oder Bewerber

2 Adressat, Zweck, Rechtsgrundlage (VL 13)

Adressat der Erklärung

bitte wählen

Zweck: was der Adressat mit der Erklärung tun können soll

Rechtsgrundlage (VL 5, 26, 34, 35)

bitte wählen

Begründung der Rechtsgrundlage

Lehrkontext, keine Rechtsberatung.

3 Veränderbarkeit der Merkmale (VL 23, 24)

Namen kommen aus dem Kopf Ihrer W04-CSV, aus den Demodaten oder aus Ihrer Eingabe. Die Grenzen steuern das Counterfactual in Teil B, Schritt 3. Höchständerung in Standardabweichungen (SD) der Trainingsdaten.

Merkmal 1: Name	veränderbar	erlaubte Richtung	Höchständerung (SD)
fachmerkmal_1	ja	beide	1,0

Merkmal 2: Name	veränderbar	erlaubte Richtung	Höchständerung (SD)
fachmerkmal_2	ja	beide	1,0

Merkmal 3 (Proxy): Name	veränderbar	erlaubte Richtung	Höchständerung (SD)
proxy	nein	beide	1,0

4 Gütekriterium (VL 14, 30)

Mindestanteil Bootstrap-Modelle mit gleichem wichtigsten Merkmal

0,80

Mindestanteil, in dem das Counterfactual gültig bleibt

0,80

Zielwahrscheinlichkeit des Counterfactuals (Abstand zur Schwelle 0,50)

0,50

Begründung: warum diese Schwellen für Ihren Adressaten

TEIL B // PHASE 2 // 35 MIN

Aufgabenkarte 2: Erklären und prüfen

Ziel: Abgelehnten Fall erklären, Erklärung prüfen.

1. Analysieren Sie die globale Wichtigkeit der Merkmale.
2. Erläutern Sie den gewählten Fall in einem Satz an Ihren Adressaten.
3. Bewerten Sie das Counterfactual: umsetzbar, sparsam?
4. Analysieren Sie die Stabilität; erhöhen Sie bei Bedarf das Ziel.
5. Entwerfen Sie den Absatz „Grenzen der Erklärung“.

Ergebnis: Teil B, Matrixzeile · **Zeit:** 35 Minuten · **Abgabe:** Ergebnisdatei

0 Datensatz aus W04 oder Demodaten

WEG A // W04-CSV LADEN

Ihre Datei „W04_G?? _Datensatz.csv“ (wird nur in diesem Browser gelesen)

Spaltennamen werden aus dem Kopf übernommen. Tragen Sie unten den Seed aus W04 ein.

WEG B // MIT DEN W04-WERTEN NEU ERZEUGEN

Gleiche Werte wie in W04 Teil A, Schritt 5, ergeben denselben Datensatz.

WEG C // OHNE W04-DATEN

Demodaten Thema

Nur, wenn Ihre W04-CSV und Ihre W04-Werte fehlen. Setzt Werte, Seed und Merkmalsnamen; gleicher Datensatz wie die Datei W05_Demodaten_Txx.csv im OPAL. Synthetisch.

Basisrate Gruppe a

0,50

Basisrate Gruppe b

0,30

Proxy-Stärke

0,80

Fallzahl

5.000

Anteil der Gruppe b

0,40

Label-Bias

0,00

Zufallswert (Seed) des Datensatzes; Bootstrap nutzt Seed + 1000

42

Noch kein Datensatz. Laden Sie Ihre W04-CSV, erzeugen Sie den Datensatz mit Ihren W04-Werten neu oder wählen Sie ohne W04-Daten die Demodaten Ihres Themas.

1 Modell trainieren und global erklären (VL 17, 19, 21)

2 Fall wählen und lokal erklären (VL 20, 22, 45)

Fall-Nr. (Index in den Messfällen, ab 0)

z. B. 17

Ihre Erklärung in einem Satz an den Adressaten aus Teil A

Für diese Entscheidung zählten vor allem … und …; … wirkte dagegen.

3 Counterfactual berechnen (VL 23, 24, 47)

Bewertung: umsetzbar, sparsam?

4 Stabilität testen (VL 29, 30)

5 Grenzen der Erklärung (VL 33)

Absatz für die Model Card und Kapitel 3

Die Erklärung gilt nur …; sie setzt voraus, dass …; nicht geprüft wurde …

ABGABE // BIS SO 08.11.2026, 23:59 UHR // OPAL

Zeile für die Vergleichsmatrix:

```
erscheint nach Schritt 4
```

Abgabe bis Ende KW45, So 08.11.2026, 23:59 Uhr, im OPAL: Ergebnisdatei. Der Absatz aus Schritt 5 geht in die Model Card (bis W07) und in Kapitel 3.

WAS IM HINTERGRUND PASSIERT

- **Modell:** logistische Regression auf den Trainingsfällen mit den drei Merkmalen, ohne das Gruppenmerkmal; Newton-Verfahren mit L2-Strafterm 1 auf die Gewichte. Entspricht `sklearn.linear_model.LogisticRegression(C=1)`. Genauigkeit gegen `y_altdaten` auf den Messfällen, Schwelle 0,5.
- **SHAP:** Für ein lineares Modell sind die SHAP-Werte exakt berechenbar: $\varphi_j = w_j \cdot (x_j - \text{Mittelwert}_j)$, Basiswert = $b + \Sigma\, w_j \cdot \text{Mittelwert}_j$, beides auf der Logit-Skala (Log-Odds). Hintergrund sind die Trainingsfälle. Die Formel unterstellt unabhängige Merkmale; hängen Merkmale zusammen, etwa Proxy und Eignung, teilt sie Beiträge trotzdem einzeln zu. Entspricht `shap.LinearExplainer(model, shap.maskers.Independent(X_train, max_samples=len(X_train)))`; ohne `max_samples` zieht shap nur 100 Hintergrundfälle und weicht deutlich ab: im Kontrollfall (Seed 42, Fall-Nr. 1263) φ +0,60 statt +0,51 und Basiswert −0,56 statt −0,48. (VL 19, 45)
- **Globale Wichtigkeit:** mittlerer Betrag der SHAP-Werte über die Messfälle, wie `shap.plots.bar`.
- **Counterfactual:** kleinste Summe der Änderungen in Standardabweichungen (L1), sodass der Logit mindestens logit(Zielwahrscheinlichkeit) + 0,01 erreicht (bei Ziel 0,50 also 0,01), nur über veränderbare Merkmale, in erlaubter Richtung und bis zur Höchständerung. Beim linearen Modell ist das ein lineares Optimierungsproblem; die Lösung nimmt zuerst das Merkmal mit dem größten $|w_j| \cdot SD_j$ bis zur Grenze, dann das nächste. Entspricht `scipy.optimize.linprog`; DiCE sucht dagegen mehrere, verschiedene Counterfactuals. (VL 23, 24, 47)
- **Robustheit:** Ein Counterfactual knapp an der Schwelle kann seine Gültigkeit schon bei kleinen Modelländerungen verlieren, etwa nach einem Neutraining; eine höhere Zielwahrscheinlichkeit kann Abstand zur Schwelle schaffen, um den Preis größerer Änderungen (Upadhyay, Joshi & Lakkaraju 2021).
- **Demodaten:** je Thema feste Werte, Seed und Merkmalsnamen, erzeugt mit dem Generator aus W04. Das Blatt schreibt den Datensatz wie der W04-Export als CSV (vier Nachkommastellen) und liest ihn wieder ein; deshalb sind Auswahl und Datei W05_Demodaten_Txx.csv identisch. Vollständig synthetisch, nur für Gruppen ohne eigene W04-Daten.
- **Fallauswahl:** Der Knopf wählt den abgelehnten Messfall ($\hat{Y} = 0$), dessen Wahrscheinlichkeit am nächsten an 0,40 liegt, bei Gleichstand den kleinsten Index. So liegt der Fall deutlich, aber nicht weit unter der Schwelle. Jede andere Fall-Nr. lässt sich eintragen.
- **Stabilität:** 20 Bootstrap-Stichproben der Trainingsfälle (Ziehen mit Zurücklegen, Seed des Datensatzes + 1000), je Stichprobe ein neues Modell und neue SHAP-Werte für denselben Fall. Gezählt wird, wie oft wichtigstes Merkmal und Entscheidung gleich bleiben und ob das Counterfactual unter dem neuen Modell noch zur Annahme führt. Geprüft wird die Unsicherheit aus den Trainingsdaten, nicht die aus dem Erklärverfahren.

Lundberg & Lee (2017), NeurIPS · Wachter, Mittelstadt & Russell (2018), Harvard JOLT · Ustun, Spangher & Liu (2019), FAT · Upadhyay, Joshi & Lakkaraju (2021), NeurIPS · Molnar (2025), Interpretable Machine Learning, 3. Aufl.*