W06 // ÜBUNG // 11.11.2026 // ARBEITSBLATT IM BROWSER

# Design-Sprint: Agenten-Verfassung

Keine Installation. Alles läuft in diesem Browserfenster, nichts wird gesendet. Die Daten in Teil B sind synthetisch.

> Fassung 05.11.2026: Abgabefrist ergänzt, Erklärungskästen und Wertebereiche vereinheitlicht, Begriffe an die Vorlesung angeglichen; Rechnung unverändert.

Gruppe: bitte wählen

Thema: bitte wählen

TEIL A // PHASE 1 // 25 MIN

**Aufgabenkarte 1: Agenten-Verfassung entwerfen**
**Ziel:** Festlegen, was der Agent in Ihrem System tun darf und wann ein Mensch entscheidet.

1. Nennen Sie Zweck und Auftraggeber des Agenten.
2. Beschreiben Sie seine Werkzeuge, Rechte und Grenzen (Mandat).
3. Entwerfen Sie die Rangfolge bei Konflikten und die Verbote.
4. Entwerfen Sie Eskalationsregel, Aufsicht, Audit-Trail und sicheren Zustand nach der Stopptaste.

**Ergebnis:** SOUL.md · **Zeit:** 25 Minuten · **Abgabe:** mit der Ergebnisdatei

## 1 Zweck und Auftraggeber (VL 6, 7, 13)

Denken Sie den Agenten in Ihrem System, bei einem System ohne Agenten die agentische Komponente, die es bekäme.

Name des Agenten: Datenaufbereitungsagent

In wessen Auftrag handelt er?: Kreditinstitut

Zweck in einem Satz: Daten aus verschiedenen Quellen aggregieren und die besten Datenpunkte wählen.

Wofür ausdrücklich nicht: Keine eigenen Werte aus den vorhandenen Daten erstellen.

## 2 Werkzeuge und Rechte (Mandat) (VL 14, 17)

Least Privilege: nur die Rechte, die der Zweck verlangt. Je Werkzeug eine Grenze mit Zahl oder Bedingung. Bis zu vier Werkzeuge.

| Werkzeug | Recht | Grenze |
|---|---|---|
| Kreditantragstellerdaten | lesen | Nur offline |
| Daten der Angehörige | lesen | nur offline |

| Werkzeug 3 | Recht | Grenze |
|---|---|---|
| Datenaufbereiten Umgebu | schreiben, umkehrbar | Keine neuen Werte erstellen |

| Werkzeug 4 | Recht | Grenze |
|---|---|---|
| Wissensdatenbank Zugriff | lesen | Schreiben |

## 3 Rangfolge und Verbote (VL 18, 19)

Welcher Wert setzt sich durch, wenn zwei kollidieren? Rang 1 bis 3 wählen, Rang 4 nach Bedarf. Verbote gelten auch auf ausdrückliche Aufforderung.

Rang 1: bitte wählen

Rang 2: bitte wählen

Rang 3: bitte wählen

Rang 4 (optional): kein vierter Wert

Verbot 1: z. B. keine Buchung ohne genehmigten Reisean

Verbot 2:

Verbot 3:

## 4 Eskalation, Aufsicht, Audit-Trail, Stopp (VL 23, 28, 29, 31, 32)

**Was die Eskalationsregel festlegt**

- **Schwelle S:** Aktionen mit höherer Wirkung gehen vor der Ausführung zur Freigabe. Bewirkt in Teil B: wie viele Freigaben je Tag anfallen.
- **Zusatzregel:** Im riskanten Kontext geht jede Aktion zur Freigabe, auch unter S. Bewirkt in Teil B: zusätzliche Freigaben dort, wo Fehler häufiger sind.
- **Aufsichtsmodell:** wie ein Mensch eingebunden ist. Bewirkt in Teil B: nichts; der Simulator rechnet jede eskalierte Aktion als Freigabe vor der Ausführung.
- **Ausfallverhalten:** was geschieht, wenn die Kontrollinstanz nicht antwortet. Bewirkt in Teil B: nichts; es steht in der SOUL.md.
- Legen Sie die Regel vor Teil B fest. Eine spätere Änderung setzt Teil B, Schritte 3 und 4 zurück.

Freigabe vor der Aktion, wenn die Wirkung höher ist als S (in €; leer: keine Betragsschwelle)

100

technisch Min 0 € · Max 1.000.000.000 € oder leer · Standard 100 €; fachlich sinnvoll: Beispiel Agent E 100 €; ob Ihre Schwelle passt, sehen Sie in Teil B, Schritt 1 an kleinster und größter Wirkung. Bewirkt: Aktionen mit höherer Wirkung gehen vor der Ausführung zur Freigabe. 0: jede Aktion; leer: keine Betragsschwelle.

Zusätzlich immer Freigabe im riskanten Kontext?

nein

Bezeichnung des riskanten Kontexts

z. B. außerhalb der Richtlinie

Aufsichtsmodell

bitte wählen

Wenn die Kontrollinstanz ausfällt (in der Vorlesung: Guardian, prüft jede Aktion vor der Ausführung)

bitte wählen

Felder des Audit-Trails, je Schritt an der Werkzeugschnittstelle

- [ ] Agenten-Kennung und Version
- [ ] Auftraggeber (in wessen Auftrag)
- [ ] Vorgangsbezug
- [ ] Werkzeugaufruf mit Argumenten
- [ ] Entscheidung der Kontrollinstanz
- [ ] Freigabe: Rolle und Ergebnis
- [ ] tatsächliches Ergebnis mit Fehlermeldung
- [ ] Zeitstempel, manipulationsgeschützt

Wozu: Mit diesen Feldern lässt sich später rekonstruieren, wer was in wessen Auftrag mit welchem Recht und welchem Ergebnis getan hat. Vorgeschrieben ist die automatische Protokollierung nur für Hochrisiko-KI-Systeme (Art. 12 KI-VO); für andere Systeme ist sie gute Praxis.

Sicherer Zustand nach der Stopptaste: Was passiert mit laufenden und angefangenen Vorgängen?

z. B. Laufende Aufrufe werden beendet oder als fehlgeschlagen markiert; offene Buchungen gehen als „manuell prüfen“ an die Reisestelle; Lesezugriff bleibt für die Rekonstruktion.

Die Matrixzeile übernimmt bis zu 60 Zeichen, bei längerem Text bis zum letzten Satzzeichen davor.

**BEGRIFFE KURZ Model Card, Agent Card, Verfassung**

Die Model Card (Mitchell et al. 2019) dokumentiert ein Modell mit Einsatz und Grenzen als Text für Menschen; eine System Card ist ein Bericht des Anbieters über ein ganzes System mit Tests und Schutzmaßnahmen. Die Agent Card im Protokoll A2A ist eine maschinenlesbare Selbstauskunft eines Agenten als JSON mit Name, Skills, Endpunkt und Authentifizierung, abgelegt unter `/.well-known/agent-card.json`. Die SOUL.md aus Teil A legt Regeln für den Agenten fest; sie dokumentiert ihn nicht.

*Quelle: Mitchell et al. (2019); A2A: Anbieterangabe; geprüft am 04.11.2026 und 09.11.2026 · Vorlesung* `(VL 20, 21, 22)`

Teil B rechnet mit der Eskalationsregel aus diesem Schritt. Lehrkontext, keine Rechtsberatung.

TEIL B // PHASE 2 // 35 MIN

**Aufgabenkarte 2: Eskalationsregel prüfen**
**Ziel:** Prüfen, ob Ihre Regel Schaden senkt, ohne die Aufsicht zu überlasten.

1. Beschreiben Sie Ihr System in Zahlen.
2. Erläutern Sie die Grenzfälle voll autonom und alles freigeben.
3. Analysieren Sie Ihre Regel aus Teil A.
4. Nennen Sie die Minima im Schwellenvergleich.
5. Bewerten Sie, ob Ihre Regel trägt und was sie kostet.

**Ergebnis:** Matrixzeile und Bewertung · **Zeit:** 35 Minuten · **Abgabe:** Ergebnisdatei

---

## 1 Ihr System in Zahlen (VL 24, 25)

Startwerte: Agent E, der Einkaufsagent aus der Vorlesung. Passen Sie die Werte an Ihr System an; geschätzte Werte sind erlaubt, wenn Sie sie begründen können. Unter jedem Feld stehen Min, Max, Standardwert und Wirkung; Werte außerhalb des Bereichs werden gemeldet und nicht gerechnet. Die Kästen „Statistik kurz“ erläutern Statistik-Begriffe, ausführlicher die Statistik-Kurzreferenz im OPAL (`Statistik_Kurzreferenz_I050_2026-11-05.pdf`).

**Was die Parameter festlegen**

| GRUPPE | PARAMETER | LEGT FEST |
|---|---|---|
| Menge und Wirkung | Aktionen je Monat, Median, Streuung σ | wie viele Aktionen es gibt und wie groß ihre Wirkung in € ist |
| Kontext und Fehler | Anteil riskanter Kontext, beide Fehlerraten, Schadensquote | wie oft eine Aktion falsch ist und wie viel ihrer Wirkung dann verloren geht |
| Aufsicht | Grunderkennung r0, Minuten je Freigabe, Prüfkapazität, Arbeitstage | wie viele Fehler eine Freigabe abfängt und ab wann die Prüfenden überlastet sind |
| Kosten | Stundensatz | was eine Prüfstunde kostet |
| Zufall | Seed | welche Stichprobe gezogen wird; gleicher Seed, gleiche Daten |

Aktionen je Monat

1000

Ganze Zahl · technisch Min 1 · Max 100.000 · Standard 1.000; fachlich sinnvoll: Ihre geschätzte Monatsmenge; Beispiel Reisebuchung: 300. Bewirkt: Zahl der simulierten Aktionen je Monat. Mehr Aktionen heißen bei gleicher Regel mehr Freigaben je Tag.

Median der Wirkung je Aktion in € (Betrag oder Schaden im Fehlerfall)

40

technisch Min 0,01 € · Max 10.000.000 € · Standard 40 €; fachlich sinnvoll: der typische Betrag oder Fehlerschaden einer Aktion in Ihrem System. Bewirkt: Typische Wirkung einer Aktion: Die Hälfte der Aktionen liegt darunter, die Hälfte darüber. Ändern Sie ihn, verschieben sich alle Beträge im selben Verhältnis.

**STATISTIK KURZ Median und Mittelwert**

Der Median ist der mittlere Wert: Die Hälfte der Aktionen liegt darunter, die Hälfte darüber. Der Mittelwert ist die Summe geteilt durch die Anzahl; wenige sehr große Beträge ziehen ihn nach oben, den Median kaum. Im Simulator liegt der Mittelwert deshalb über dem Median.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Streuung σ der Wirkung (lognormal)

**0,90**

Min 0,10 · Max 2,00 · Schritt 0,05 · Standard 0,90 · aktuell **0,90**. Bewirkt: Wie stark die Beträge um den Median streuen. Größeres σ: mehr sehr kleine und sehr große Aktionen, der Mittelwert steigt über den Median. Das heißt: Rund 90 % der Wirkungen liegen zwischen 9,10 € und 175,79 €; der Mittelwert ist rund 1,50-mal so groß wie der Median.

**STATISTIK KURZ Lognormalverteilung und σ**

Lognormalverteilt heißt: Der Logarithmus der Beträge ist normalverteilt. Daraus folgen nur positive Beträge, viele kleine und wenige sehr große; σ bestimmt, wie weit sie streuen. Der Mittelwert ist $\exp(\sigma^2/2)$-mal so groß wie der Median, bei σ = 0,9 rund 1,5-mal.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Anteil riskanter Kontext

**0,20**

Min 0,00 · Max 1,00 · Schritt 0,05 · Standard 0,20 · aktuell **0,20**. Bewirkt: Wahrscheinlichkeit, dass eine Aktion im riskanten Kontext liegt. Wirkt auf die Fehlerrate und auf die Zusatzregel aus Teil A. Das heißt: 20 % der Aktionen.

**STATISTIK KURZ Wahrscheinlichkeit und Anteil**

Eine Wahrscheinlichkeit von 0,20 heißt: Auf lange Sicht trifft es 20 von 100 Fällen; in einer einzelnen Stichprobe können es auch 17 oder 23 sein. Anteil und Fehlerraten sind im Simulator solche Wahrscheinlichkeiten je Aktion.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Fehlerrate im normalen Kontext

**0,02**

Min 0,00 · Max 0,30 · Schritt 0,01 · Standard 0,02 · aktuell **0,02**; fachlich sinnvoll: unter der Fehlerrate im riskanten Kontext. Bewirkt: Wahrscheinlichkeit, dass eine Aktion im normalen Kontext fehlerhaft ist. Das heißt: 2 % der Aktionen im normalen Kontext.

Fehlerrate im riskanten Kontext

**0,08**

Min 0,00 · Max 0,50 · Schritt 0,01 · Standard 0,08 · aktuell **0,08**; fachlich sinnvoll: mindestens so hoch wie im normalen Kontext, sonst ist der Kontext nicht riskant. Bewirkt: Wahrscheinlichkeit, dass eine Aktion im riskanten Kontext fehlerhaft ist. Das heißt: 8 % der Aktionen im riskanten Kontext.

Schadensquote: Anteil der Wirkung, der bei einem Fehler verloren geht

0,50

Min 0,00 · Max 1,00 · Schritt 0,05 · Standard 0,50 · aktuell **0,50**. Bewirkt: Anteil der Wirkung, der bei einem Fehler verloren geht. 0: Fehler kosten nichts; 1: die ganze Wirkung ist verloren. Das heißt: 50 % der Wirkung gehen bei einem Fehler verloren.

**STATISTIK KURZ Fehlerrate und Schadensquote**

Die Fehlerrate sagt, wie oft eine Aktion falsch ist; die Schadensquote, wie viel ihrer Wirkung dann verloren ist. Beispiel: Fehlerrate 0,02, Schadensquote 0,5, Wirkung 80 € ergeben 0,02 · 0,5 · 80 € = 0,80 € erwarteten Schaden je Aktion.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Grunderkennung r0: Erkennungsrate einer Freigabe bis zur Kapazität

0,90

Min 0,00 · Max 1,00 · Schritt 0,05 · Standard 0,90 · aktuell **0,90**. Bewirkt: Anteil der Fehler, den eine Freigabe abfängt, solange die Kapazität reicht. Wirkt nur auf Aktionen mit Freigabe. Das heißt: 9 von 10 Fehlern in einer Freigabe erkannt, solange die Kapazität reicht.

**STATISTIK KURZ Erkennungsrate**

Die Erkennungsrate ist der Anteil fehlerhafter Aktionen, den eine Freigabe stoppt: Bei 0,9 fängt die prüfende Person im Mittel 9 von 10 Fehlern ab, einer geht durch. Aktionen ohne Freigabe prüft niemand; dass eine Prüfung korrekte Aktionen fälschlich ablehnt, kennt das Modell nicht.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Minuten je Freigabe

2

technisch Min 0 min · Max 600 min · Standard 2 min; fachlich sinnvoll: 1–30 min je nach Prüfung. Bewirkt: Arbeitszeit je Freigabe. Wirkt nur auf Prüfstunden und Prüfkosten, nicht auf den Schaden.

Prüfkapazität: Freigaben je Arbeitstag mit voller Sorgfalt

15

technisch Min 0 · Max 10.000 · Standard 15; fachlich sinnvoll: so viele, wie die eingeplanten Personen im eigenen System tatsächlich schaffen; 0 heißt, niemand prüft. Bewirkt: Freigaben je Arbeitstag mit voller Sorgfalt. Liegen die Freigaben je Tag darüber, sinkt die Erkennung; liegen sie darunter, ändert die Kapazität nichts.

**STATISTIK KURZ Kapazität und Überlast**

Die Kapazität ist die Zahl der Freigaben, die je Arbeitstag mit voller Sorgfalt möglich sind; was darüber liegt, ist Überlast. Das Modell senkt dann die Erkennung im Verhältnis, r = r0 · Kapazität / Freigaben je Tag, bei doppelter Last also auf die Hälfte. Das ist eine gesetzte Modellannahme, keine Messung.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

Arbeitstage je Monat

22

Ganze Zahl · technisch Min 1 · Max 31 · Standard 22; fachlich sinnvoll: rund 20–23 bei Fünftagewoche, 30 bei Betrieb an allen Tagen. Bewirkt: Verteilt die Freigaben je Monat auf Arbeitstage. Weniger Tage: mehr Freigaben je Tag.

Stundensatz der Prüfenden in €

45

technisch Min 0 € · Max 10.000 € · Standard 45 €; fachlich sinnvoll: 30–120 € mit Arbeitgeberanteil. Bewirkt: Kosten einer Prüfstunde. Wirkt nur auf Prüfkosten und Gesamtkosten.

Zufallswert (Seed)

11

Ganze Zahl · Min 0 · Max 4.294.967.295 · Standard 11. Bewirkt: Startwert des Zufallsgenerators. Gleicher Seed, gleiche Daten; anderer Seed, andere Stichprobe derselben Verteilung.

**STATISTIK KURZ Zufallszahl und Seed**

Der Simulator zieht Pseudozufallszahlen: Ein festes Rechenverfahren erzeugt aus einem Startwert, dem Seed, eine Folge, die wie Zufall aussieht. Gleicher Seed, gleiche Daten; deshalb lassen sich Ergebnisse vergleichen und nachrechnen. Ändert ein anderer Seed Ihre Schlussfolgerung, ist sie nicht robust.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

## 2 Grenzfälle: voll autonom und alles freigeben (VL 27, 47)

**STATISTIK KURZ Erwartungswert**

Der Erwartungswert ist der Durchschnitt, der sich bei sehr vielen Wiederholungen einstellt: 1.000 Aktionen mit Fehlerrate 0,02 ergeben 20 erwartete Fehler, in einem einzelnen Monat können es mehr oder weniger sein. Der Simulator rechnet nur Erwartungswerte, deshalb erscheinen Kommazahlen wie 31,8 Fehler; wie stark ein einzelner Monat schwankt, zeigt er nicht.

*Mehr: Statistik-Kurzreferenz im OPAL (Statistik_Kurzreferenz_I050_2026-11-05.pdf)*

## 3 Ihre Regel aus Teil A (VL 28, 48)

Legen Sie vor dem Rechnen fest, was „tragfähig“ für Ihr System heißt, etwa Freigaben je Tag unter der Prüfkapazität und eine Mindestsenkung des Schadens gegenüber voll autonom.

Regel aus Teil A, Schritt 4: Freigabe, wenn Wirkung > 100 €.

## 4 Schwellenvergleich (VL 27, 47)

## 5 Bewertung (VL 26, 33)

Trägt Ihre Regel? Was ist der Preis?

Unsere Regel senkt den Schaden um …; dafür … Prüfstunden je Monat; die Kapazität ist zu … ausgelastet; nicht abgedeckt ist …

Urteil (optional)

kein Urteil gewählt

Das Urteil ist freiwillig und keine zusätzliche Abgabeanforderung. Wählen Sie es, steht es in der Ergebnisdatei.

ABGABE // BIS SO 15.11.2026, 23:59 UHR // OPAL

Zeile für die Vergleichsmatrix:

```
erscheint nach Schritt 4
```

**Abgabe bis Ende KW46, So 15.11.2026, 23:59 Uhr, im OPAL:** SOUL.md und Ergebnisdatei. Die Matrixzeile tragen Sie heute im Debrief ein; sie steht auch in der Ergebnisdatei. Die SOUL.md kann als Baustein für Kapitel 5 dienen.

WAS IM HINTERGRUND PASSIERT

- **Lehrmodell:** Der Simulator ist ein konstruiertes Lehrmodell, keine Messung. Er zeigt, wie Ihre Annahmen zusammenwirken, nicht, wie sich ein reales System verhält. Gerechnet werden Erwartungswerte je Monat, keine einzelnen Fehlerereignisse.
- **Daten:** Für jede der n Aktionen eine Wirkung W = exp(ln(Median) + σ · z) mit standardnormalem z, auf Cent gerundet; mit Wahrscheinlichkeit „Anteil“ liegt die Aktion im riskanten Kontext. Fehlerwahrscheinlichkeit p je Aktion: Fehlerrate normal oder riskant. Zufallszahlen aus einem festen Generator (mulberry32, Normalverteilung nach Box-Muller): gleicher Seed, gleiche Daten.
- **Regel:** Eine Aktion geht vor der Ausführung zur Freigabe, wenn W > S ist oder wenn sie im riskanten Kontext liegt und die Zusatzregel gilt. Sonst läuft sie ohne Prüfung. Freigaben je Tag = Freigaben je Monat / Arbeitstage.
- **Kapazität:** Eigene Modellannahme: Eine Freigabe erkennt einen Fehler mit $r = r_0 \cdot \min(1, \text{Kapazität} / \text{Freigaben je Tag})$; ohne Freigaben gilt $r_0$. Wer mehr vorlegt, als geprüft werden kann, prüft im Modell flacher. Motiviert ist die Annahme durch Turan (2026), ein Preprint ohne Begutachtung, nach dem Aufsicht eine Kapazität hat; der Autor nennt seine Befunde selbst „modeling results that motivate a human study“. Die Formel hier ist gesetzt, nicht aus Turan übernommen. Dass zu viele Freigaben den Schaden wieder erhöhen, ist deshalb im Modell angelegt, nicht beobachtet.
- **Kennzahlen:** Erwarteter Schaden = Σ p · Schadensquote · W, bei Aktionen mit Freigabe mal (1 − r). Prüfminuten = Freigaben · Minuten je Freigabe. Gesamtkosten = Schaden + Prüfminuten / 60 · Stundensatz. Nicht im Modell: Wartezeit der Betroffenen, Schwankung über den Tag, Ermüdung über Wochen, Aufteilen von Aktionen unter die Schwelle, Fehlentscheidungen der Prüfenden gegen korrekte Aktionen.
- **Eingaben und Hinweise:** Jedes Zahlenfeld hat einen festen Bereich; liegt ein Wert außerhalb oder ist er keine Zahl, meldet das Blatt das am Feld und rechnet den Schritt nicht. Ändert eine Eingabe am Ergebnis nichts, etwa eine Schwelle über der größten Wirkung oder eine Kapazität, die nicht erreicht wird, nennt ein Hinweis den Grund. Die Rechnung selbst ist seit der Fassung vom 02.11.2026 unverändert.
- **Antworten der Kontrollinstanz:** Das Modell kennt nur zwei: ausführen und rückfragen. Der Agent Control Standard (ACS) sieht fünf vor, `allow`, `deny`, `modify`, `ask`, `defer`; fällt der Guardian aus, ist das Standardverhalten laut Projekt `proceed`, also weiterlaufen (Projektangabe). Saltzer & Schroeder (1975) verlangen dagegen sichere Voreinstellungen (fail-safe defaults) und das kleinste nötige Recht: „Every program and every user of the system should operate using the least set of privileges necessary to complete the job.“
- **Recht (Hochrisiko-KI-Systeme):** Art. 14 Abs. 3 KI-VO: Aufsichtsmaßnahmen müssen „den Risiken, dem Grad der Autonomie und dem Kontext der Nutzung“ angemessen sein; die Schwelle ist eine solche Abstufung. Art. 14 Abs. 4 lit. e: eine „Stopptaste“ oder ein ähnliches Verfahren, „was dem System ermöglicht, in einem sicheren Zustand zum Stillstand zu kommen“; daher der sichere Zustand in Teil A. Art. 12 Abs. 1: automatische Protokollierung von Ereignissen; Betreiber bewahren die Protokolle mindestens sechs Monate auf (Art. 26 Abs. 6). Lehrkontext, keine Rechtsberatung.

- **Aufsichtsmodelle:** HITL (Human-in-the-Loop), HOTL (Human-on-the-Loop) und HIC (Human-in-Command) stammen aus den Ethik-Leitlinien der Hochrangigen Expertengruppe (HLEG 2019); die KI-VO verwendet keinen dieser Begriffe. HITL ist dort die Fähigkeit, in jeden Entscheidungszyklus einzugreifen, „was in vielen Fällen weder möglich noch wünschenswert wäre“; HOTL umfasst Eingriffe in den Entwurfszyklus und die Überwachung des Betriebs; HIC die Gesamtsteuerung bis zur Entscheidung, das System nicht zu verwenden. Die Kurzfassungen in Teil A sind betriebliche Arbeitsdefinitionen.

*VO (EU) 2024/1689, Art. 12, 14, 26, konsolidierte Fassung vom 27.07.2026 · HLEG für KI (2019), Ethik-Leitlinien für eine vertrauenswürdige KI, S. 19 · Saltzer & Schroeder (1975), Proceedings of the IEEE 63(9), 1278–1308 · Turan (2026), arXiv:2606.08919, Preprint · Agent Control Standard, README (Projektangabe) · alle geprüft am 02.11.2026*

*I050 Ethische und vertrauenswürdige KI · HTW Dresden · Übung am 11.11.2026 · Fassung 05.11.2026 · Eingaben bleiben nur in diesem Browser gespeichert.*