W06 // ÜBUNG // 90 MIN

Design-Sprint: Agenten-Verfassung

Am Thema Ihrer Semesterarbeit, im Arbeitsblatt im Browser. Leitfrage: Was darf der Agent in Ihrem System allein tun, und wann entscheidet ein Mensch?

Ablauf und Lernziele

ÜBUNG // 90 MIN

5'	**Start: Themen und Werkzeug**
25'	**Phase 1: Agenten-Verfassung entwerfen** parallel zu Phase 1 und 2: Exposé-Sprechstunden, rund 6 min je Team
35'	**Phase 2: Eskalationsregel prüfen**
15'	**Debrief: Vergleich über die Themen**
10'	**Kapitel 5, Abgabe, 1-Minute-Paper**

LERNZIELE W06

Sie …

(2) bewerten eine Eskalationsregel am Modell,
(3) entwerfen eine Agenten-Verfassung für Ihr System.

Ergebnis: SOUL.md, Ergebnisdatei, Zeile für die Vergleichsmatrix

- BAUSTEIN FÜR KAPITEL 5

START // 5 MIN

Ihre Themen und Ihr Weg durch die Übung

THEMENVERGABE // STAND 26.10.2026

T03 Vorauswahl von Bewerbungen

G01, G02, G03, G04, G07, G12 · Agent lädt ein oder sagt ab

T02 Empfehlungssystem im Online-Handel

G05, G06 · Agent spielt Angebote und Preise aus

T01 Kreditwürdigkeitsprüfung

G10 · Agent fordert Unterlagen an, prüft vor

Übrige Gruppen

Thema aus W04 · Agent oder agentische Komponente

IHR WEG IN SECHS SCHRITTEN

1	Agenten im eigenen System bestimmen	START
2	Zweck, Auftraggeber, Werkzeuge	PHASE 1
3	Rangfolge, Verbote, Eskalation, Stopp	PHASE 1
4	System in Zahlen, Grenzfälle	PHASE 2
5	Eigene Regel und Schwellenvergleich	PHASE 2
6	Regel bewerten: Trägt sie, was kostet sie?	PHASE 2

Werkzeug: das Arbeitsblatt im Browser

ARBEITSBLATT W06 // EINE HTML-DATEI AUS DEM OPAL

Startwerte	Agent E² aus der Vorlesung; passen Sie sie an Ihr System an Geschätzte Werte sind erlaubt, wenn Sie sie begründen.
Teil A	Zweck, Werkzeuge, Rangfolge, Eskalation, Stopp: SOUL.md[1]
Teil B 1–2	Ihr System in Zahlen, Grenzfälle
Teil B 3–5	Eigene Regel, Schwellenvergleich, Bewertung
Abgabe	SOUL.md, Ergebnisdatei, Zeile für die Vergleichsmatrix

OHNE INSTALLATION

Läuft im Browser, auf Laptop und Tablet. Ein Gerät je Gruppe genügt.

Nichts wird gesendet. Eingaben bleiben nur in diesem Browser: Dateien sichern.

Der Simulator ist ein Lehrmodell mit synthetischen Daten.

[1] SOUL.md: Textdatei mit Ihrer Agenten-Verfassung · [2] Agent E: konstruierter Einkaufsagent aus der Vorlesung · Rechnung wie das Modell zu Agent E, mit Python gegengeprüft · Daten synthetisch

PHASE 1 // 25 MIN

Aufgabenkarte 1: Agenten-Verfassung entwerfen

AUFGABENKARTE 1

Ziel: Festlegen, was der Agent in Ihrem System tun darf und wann ein Mensch entscheidet.

1. Nennen Sie Zweck und Auftraggeber des Agenten.
2. Beschreiben Sie seine Werkzeuge, Rechte und Grenzen (Mandat).
3. Entwerfen Sie die Rangfolge bei Konflikten und die Verbote.
4. Entwerfen Sie Eskalationsregel, Aufsicht, Audit-Trail und sicheren Zustand nach der Stopptaste.

Ergebnis: SOUL.md · **Zeit:** 25 Minuten · **Abgabe:** mit der Ergebnisdatei

BEISPIEL // ANDERER FALL

Reisebuchungsagent einer Hochschule

1. Der Agent bucht Dienstreisen nach Antrag, im Auftrag der Reisestelle.
2. Er liest das Portal, bucht stornierbar und zahlt bis 400 €, nicht umkehrbar.
3. Rechtskonformität geht vor Kosten, Kosten vor Bequemlichkeit; ohne Antrag bucht er nie.
4. Über 400 € oder außerhalb der Richtlinie gibt ein Mensch frei (HITL[1]); beim Stopp gehen Anträge an die Reisestelle.

[1] *HITL, Human-in-the-Loop: Die Aktion wartet auf die Freigabe eines Menschen (Vorlesung: Aufsicht durch Menschen).*

Aufgabenkarte 2: Eskalationsregel prüfen

AUFGABENKARTE 2

Ziel: Prüfen, ob Ihre Regel Schaden senkt, ohne die Aufsicht zu überlasten.

1. Beschreiben Sie Ihr System in Zahlen.
2. Erläutern Sie die Grenzfälle voll autonom und alles freigeben.
3. Analysieren Sie Ihre Regel aus Teil A.
4. Nennen Sie die Minima im Schwellenvergleich.
5. Bewerten Sie, ob Ihre Regel trägt und was sie kostet.

Ergebnis: Matrixzeile und Bewertung · **Zeit:** 35 Minuten · **Abgabe:** Ergebnisdatei

BEISPIEL // ANDERER FALL

Reisebuchungsagent: 300 Buchungen im Monat, Prüfkapazität 10 am Tag

1. Ohne Freigaben erwartet das Modell rund 1.122 € Schaden im Monat.
2. Alles freigeben überlastet die Reisestelle: Die Erkennung sinkt auf 0,63.
3. Freigabe über 400 € oder außerhalb der Richtlinie senkt den Schaden auf 502 €.
4. Schwelle 100 €: Schaden nur 280 €, aber über der Kapazität.
5. Urteil: Die Regel trägt; ihr Preis sind 4,6 Prüfstunden im Monat.

Schaden: erwarteter Schaden in € je Monat · Erkennung: Anteil der Fehler, den eine Freigabe abfängt · Prüfkapazität: Freigaben je Tag mit voller Sorgfalt · Beispielwerte mit eigenen Parametern (Seed 12); Ihr Blatt startet mit Agent E.

DEBRIEF // 15 MIN

Debrief: Vergleich über die Themen

VERGLEICHSMATRIX // EINE ZEILE JE GRUPPE, OPAL-TABELLE ODER TAFEL

Gruppe	Thema	Regel	Freigaben/Tag	Erkennung	Schaden	Stopp

ZWEI FRAGEN ANS PLENUM

1. Warum senkt „alles freigeben“ den Schaden nicht am stärksten? (VL-Folien 27 und 28)
2. Was ist nach Ihrer Stopptaste anders als beim bloßen Abschalten? (VL-Folie 32)

Freigaben/Tag: Freigaben je Arbeitstag, zu vergleichen mit Ihrer Prüfkapazität · Erkennung: Anteil der Fehler, den eine Freigabe abfängt · Schaden: erwarteter Schaden in € je Monat · Stopp: was nach der Stopptaste mit offenen Vorgängen geschieht

TRANSFER // 10 MIN

Kapitel 5 und Abgabe

KAPITELKARTE // KAPITEL 5 TRUST-ARCHITEKTUR

Ziel: belegen, mit welchen Maßnahmen Ihr System Vertrauen verdient und was jede Maßnahme kostet.

1 Beschreiben Sie drei Maßnahmen Ihrer Trust-Architektur; Zweierteams zwei.

2 Erläutern Sie je Maßnahme, was sie leistet und was sie kostet.

3 Bewerten Sie je Maßnahme den Trade-off.

Entsteht: in W06 und W09–W12; Ihre SOUL.md kann eine der Maßnahmen sein · **Rubric:** K2 und K4

Trust-Architektur: die Maßnahmen, mit denen Ihr System Vertrauen verdient.

ABGABE BIS SO 15.11. // OPAL

Bis Ende KW46: So 15.11.2026, 23:59 Uhr

SOUL.md und Ergebnisdatei

Ihre Zeile in der Vergleichsmatrix

1-MINUTE-PAPER // ANONYM, OPAL

1. Was nehmen Sie für Ihr System mit?
2. Was ist unklar geblieben?

NEXT // W07 · 25.11.

08:00 Übung: Privacy-Fall vorbereiten
09:45 Vorlesung mit Gast Dr. Gunnar Hempel
Exposé-Abgabe und Midterm-Evaluation
18.11.: kein Termin (Buß- und Bettag)